

Diccionario de columnas — V3 final

Proyecto BBB · generado el 2026-09-25 desde DICCIONARIO_columnas.md

Archivo `snc_activity_crudo_v3_final_2026-09-25.csv`: 225.513 filas y 40 columnas. Cada fila es una medición de actividad de un compuesto en un ensayo. Los datos vienen tal como los entregan ChEMBL, NPASS y CMAUP, sin estandarizar; las columnas marcadas "(añadida)" las agregé este trabajo. Para entrenar conviene usar las columnas de la sección 5.

1. Compuesto

Columna	Qué es	Valores posibles
<code>source</code>	Base de datos de origen	<code>chembl</code> : bioactividad de moléculas tipo fármaco (EMBL-EBI) · <code>npass</code> : actividad de productos naturales · <code>cmaup</code> : plantas medicinales y sus ingredientes
<code>source_compound_id</code>	ID del compuesto en su base	<code>CHEMBL...</code> en ChEMBL; <code>NPC...</code> en NPASS y CMAUP, que usan el mismo código para el mismo compuesto
<code>source_record_id</code>	ID de la medición en ChEMBL (<code>activity_id</code>)	Número. Vacío en NPASS y CMAUP, que no publican un ID por medición
<code>compound_name</code>	Nombre del compuesto	Texto. Solo lo trae CMAUP
<code>smiles_raw</code>	Estructura química en formato SMILES, tal como la entrega la fuente	Texto. Vacío en 1.540 filas sin estructura
<code>inchikey_source</code>	Identificador químico estándar (InChIKey, 27 caracteres)	Texto. Solo en NPASS y CMAUP; vacío en ChEMBL

2. Diana molecular

Columna	Qué es	Valores posibles
<code>target_id_source</code>	ID de la diana en su fuente	UniProt (<code>P...</code> , <code>Q...</code>) en NPASS y CMAUP · <code>CHEMBL...</code> en ChEMBL · <code>NPT...</code> : diana no proteica de NPASS · vacío en la vía neuronal de ChEMBL
<code>target_name</code>	Nombre de la diana	Texto (p. ej. <code>Acetylcholinesterase</code>). <code>Unchecked</code> : ChEMBL no identificó la diana. En NPASS puede ser el nombre de una línea celular
<code>target_gene</code>	Símbolo del gen de la diana	Uno de los 37 genes del proyecto (sección 8). Vacío u otro gen en la vía neuronal
<code>target_type_source</code>	Tipo de diana según la fuente, sin normalizar	<code>SINGLE PROTEIN</code> (ChEMBL: una proteína) · <code>Individual protein / Single protein</code> (NPASS: una proteína) · <code>Therapeutic Target</code> (CMAUP) · <code>Cell line</code> (NPASS: la "diana" es una línea celular; ensayo fenotípico) · <code>Non-molecular</code> (NPASS: efecto fisiológico sin diana concreta) · menores: <code>Protein family</code> , <code>Protein complex</code> , <code>Others</code> , <code>Unchecked</code> , <code>Organism</code> , <code>Nucleic acid</code> · vacío en la vía neuronal de ChEMBL
<code>diana_categoria</code> (añadida)	Enfermedad o proceso principal con que se relaciona la diana	Alzheimer · Parkinson · Huntington · ELA (esclerosis lateral amiotrófica) · Epilepsia · Depresión · Ansiedad · Deterioro cognitivo · Estrés oxidativo (daño por radicales libres) · Neuroinflamación (inflamación del cerebro mediada por microglía y citocinas) · Neurodegeneración (general) · Sin diana de la lista
<code>diana_enfermedades</code> (añadida)	Todas las enfermedades relacionadas con la diana	Lista separada por (p. ej. <code>Alzheimer Demencia Miastenia gravis</code>). Vacío si la diana no es de la lista

Columna	Qué es	Valores posibles
diana_mecanismo (añadida)	Sistema o proceso biológico en el que actúa la diana	Colinérgico (acetilcolina: memoria y atención) · Dopaminérgico (dopamina: movimiento y recompensa) · Monoaminérgico (serotonina y noradrenalina: estado de ánimo) · Glutamatérgico (glutamato: principal señal excitadora) · GABAérgico (GABA: principal señal inhibidora) · Amiloide (péptido Aβ de las placas del Alzheimer) · Tau (proteína de los ovillos neurofibrilares) · Agregación proteica (proteínas que forman agregados tóxicos) · Quinasa (enzima que fosforila otras proteínas) · Antioxidante (defensa frente al estrés oxidativo) · Metabólico (energía y envejecimiento celular) · Inflamatorio (respuesta inmune del cerebro) · Sin diana de la lista
diana_efecto_buscado (añadida)	Qué modulación de la diana se busca como tratamiento. No dice qué hizo el compuesto en el ensayo	Inhibición · Activación · Antagonismo (bloquear un receptor) · Modulación positiva o negativa (aumentar o reducir la respuesta del receptor a su señal natural) · Reducir agregación · Reducir niveles · Agonismo o antagonismo (según enfermedad) · Dirección no establecida · Sin diana de la lista
diana_etiqueta_origen (añadida)	Cómo se asignó la etiqueta de diana	Gen de la lista: target_gene es una de las 37 dianas · Misma diana (por nombre): sin gen, pero la diana tiene el mismo nombre en ChEMBL que una de las 37 (casi siempre la misma proteína en rata o ratón) · Receptor completo: ChEMBL registró el receptor GABA-A o NMDA entero, sin distinguir subunidad · Sin diana de la lista: otra diana o diana no identificada

3. Selección y ensayo

Columna	Qué es	Valores posibles
selection_route	Por qué entró la fila en la tabla	cns_target: la diana es una de las 37 del proyecto · neuronal_assay: el ensayo se hizo en una línea celular o un tejido neuronal (validado) · both: las dos
assay_cell_type_raw	Línea celular del ensayo, tal como la escribe la fuente	Texto, 113 valores; los más frecuentes: SH-SY5Y (neuroblastoma humano), U-87MG ATCC y U-251 (glioblastoma), BV-2 (microglía de ratón), PC-12 (feocromocitoma de rata). n.a.: NPASS sin línea celular
assay_tissue_raw	Tejido del sistema nervioso usado en el ensayo (ChEMBL)	Texto, 22 valores: Brain, Cerebral cortex, Hippocampus, Frontal cortex...
assay_organism	Especie del ensayo	Homo sapiens, Mus musculus, Rattus norvegicus... Vacío en la mayoría de las filas de ChEMBL
assay_chembl_id	ID del ensayo en ChEMBL	CHEMBL.... Vacío en NPASS y CMAUP
assay_type	Tipo de ensayo según ChEMBL (solo en la vía neuronal)	B Binding (unión): cuánto se une el compuesto a la diana · F Funcional: un efecto biológico (actividad de una enzima, respuesta celular) · A ADME: absorción, distribución, metabolismo y excreción, es decir, qué hace el organismo con el compuesto (farmacocinética) · T Toxicidad: daño a células u organismos · vacío en el resto
assay_format	Material biológico en el que se midió (ontología BAO; solo en la vía neuronal)	cell-based format: células vivas · tissue-based format: tejido · cell membrane format: membranas aisladas (típico de ensayos de unión) · subcellular format: fracción de la célula (lisado, sinaptosomas) · organism-based format: animal completo · microsome format: microsomas, fracción con enzimas metabólicas · mitochondrion format: mitocondrias aisladas · assay format: no especificado · vacío en el resto

4. Actividad reportada (valores originales)

Columna	Qué es	Valores posibles
activity_type	Qué se midió	41 tipos. Principales: IC50 (concentración que inhibe el 50 %) · Ki (afinidad de inhibición: menor valor, unión más fuerte) · EC50 (concentración que produce el 50 % del efecto máximo) · Potency (potencia en cribados masivos de PubChem) · Kd (afinidad de unión directa) · AC50 (concentración de activación al 50 %) · GI50 (concentración que inhibe el 50 % del crecimiento celular)
activity_relation	Relación entre el valor real y el reportado	= medido · > / >= el valor real es mayor (sin efecto hasta esa concentración) · < / <= es menor · ~ aproximado · >> mucho mayor · n.a. o vacío: no viene
activity_value	Valor original	Número. Vacío en los inactivos por texto
activity_units	Unidad original	nM en casi todas; también ug.mL-1, uM... Vacío en los inactivos por texto
reference_id	Fuente del dato	Documento de ChEMBL (CHEMBL...), PMID, DOI, patente o nombre de un conjunto de datos
reference_type	Tipo de referencia	chembl_document · PMID (artículo indexado en PubMed) · DOI · Dataset (conjunto de datos, p. ej. PubChem BioAssay) · Patent

5. Actividad para entrenar (añadidas)

Columna	Qué es	Valores posibles
activity_relation_used	Relación que se usa	=, <, <=, >, >=, >>, ~. Siempre presente: la original, = inferida en NPASS o > en los inactivos por texto
activity_value_used	Valor que se usa	Número mayor que 0, siempre presente. 10 en los inactivos por texto
activity_units_used	Unidad que se usa, sin convertir	nM (190.968 filas) · uM (33.733; incluye los 10 µM de los inactivos por texto) · ug.mL-1 y otras menores
relation_origin	De dónde sale la relación usada	fuelle: venía en el dato · inferida: fila de NPASS (PubChem) sin relación a la que se asignó = (regla con 98,4 % de acierto) · texto_chembl: inactivo declarado por texto en ChEMBL
evidence_kind	Tipo de evidencia	concentracion: valor medido con unidad y relación · inactivo_por_texto: ChEMBL lo declara "Not active" (menos del 50 % de inhibición a 10 µM, sin curva dosis-respuesta)
n_registros_identicos	Cuántas copias idénticas de esta medición había	1: única · 2 a 16: había copias y solo se conservó una
es_duplicado_exacto	Marca de copia sobrante	Siempre False en V3: las copias ya se quitaron (se mantiene por trazabilidad)

6. Avisos de calidad de ChEMBL (vacíos en NPASS y CMAUP)

Columna	Qué es	Valores posibles
chembl_potential_duplicate	Si el valor es una cita repetida de otro ya publicado	0: no. En V3 solo quedan ceros (las citas repetidas se quitaron)
chembl_data_validity_comment	Aviso de validez de ChEMBL	Outside typical range: valor fuera del rango habitual para ese tipo de medida (5.918 filas; conviene revisarlas) · Manually validated: revisado a mano (5) · vacío: sin aviso
chembl_pchembl_value	Potencia en escala logarítmica: -log10 de la concentración molar (6 = 1 µM; 9 = 1 nM)	Número, solo cuando ChEMBL lo calcula (143.488 filas)
chembl_standard_text_value	Resultado en texto cuando no hay número	Not active (33.574 filas) o vacío
chembl_activity_comment	Comentario del registro	Texto libre: Inhibition < 50% @ 10 uM..., active, inactive, Antagonist...

7. Cómo leer la relación >

> (y >=) significa que el ensayo llegó hasta esa concentración sin alcanzar el 50 % de efecto: el valor real está **por encima** de ese límite y a dosis mayores sí podría haber efecto. Es un límite inferior, no un valor medido, y solo sirve como negativo si el límite es igual o mayor que el umbral de "activo" que se use.

En V3 hay 61.001 filas > o >= en nM o µM:

Umbral de "activo"	Negativos seguros	Ambiguos
1 µM	59.859 (98 %)	1.142
10 µM	54.419 (89 %)	6.582
100 µM	7.474 (12 %)	53.527

Límites más frecuentes: 10 µM (41.291 filas, 33.574 de ellas de DrugMatrix), 100 µM (5.649) y 1 µM (3.289). En regresión no deben usarse como si el valor fuera exacto: se excluyen o se usa un método para valores censurados.

8. Etiquetas de diana

Curadas a mano a partir de la farmacología conocida; no vienen de las bases de datos. La categoría principal es la enfermedad con más respaldo para esa diana (fármaco aprobado; si no lo hay, evidencia genética o investigación clínica), o el proceso (Neuroinflamación, Estrés oxidativo) cuando la diana es común a varias enfermedades. El detalle, con fármacos de referencia, está en [etiquetas_dianas_2026-09-25.csv](#).

Además de las 121.522 filas con una de las 37 dianas, se etiquetaron 2.581 con la misma diana registrada por nombre (casi siempre en rata o ratón) y 3.112 en las que ChEMBL registró el receptor GABA-A o NMDA completo; se distinguen con [diana_etiqueta_origen](#). La columna Filas cuenta todas.

Gen	Diana	Categoría	Enfermedades relacionadas	Efecto buscado	Filas
ACHE	Acetilcolinesterasa	Alzheimer	Alzheimer, demencia, miastenia gravis	Inhibición	13.270
BCHE	Butirilcolinesterasa	Alzheimer	Alzheimer, demencia	Inhibición	6.169
GRIN1	Receptor NMDA, subunidad GluN1	Alzheimer	Alzheimer, depresión, ictus, epilepsia	Antagonismo	391
PPARG	PPAR-γ	Alzheimer	Alzheimer, Parkinson	Activación	8.274
GSK3B	GSK-3β	Alzheimer	Alzheimer, trastorno bipolar, parálisis supranuclear progresiva	Inhibición	8.312
MAPT	Tau	Alzheimer	Alzheimer, demencia frontotemporal, parálisis supranuclear progresiva	Reducir agregación	2.667
APP	Proteína precursora del amiloide	Alzheimer	Alzheimer	Reducir niveles	2.899
BACE1	β-secretasa 1	Alzheimer	Alzheimer	Inhibición	14.626
NMDA (receptor completo)	Receptor NMDA completo	Alzheimer	Alzheimer, depresión, epilepsia, ictus	Antagonismo	1.601
MAOB	Monoamino oxidasa B	Parkinson	Parkinson, depresión	Inhibición	9.190
SNCA	α-sinucleína	Parkinson	Parkinson, demencia con cuerpos de Lewy, atrofia multisistémica	Reducir agregación	720
LRRK2	Quinasa LRRK2	Parkinson	Parkinson	Inhibición	7.441
DRD2	Receptor de dopamina D2	Parkinson	Parkinson, esquizofrenia	Agonismo o antagonismo (según enfermedad)	18.215
COMT	Catecol-O-metiltransferasa	Parkinson	Parkinson	Inhibición	273
HTT	Huntingtina	Huntington	Huntington	Reducir niveles	174

Gen	Diana	Categoría	Enfermedades relacionadas	Efecto buscado	Filas
SOD1	Superóxido dismutasa 1	ELA	ELA	Reducir niveles	50
TARDBP	TDP-43	ELA	ELA, demencia frontotemporal	Reducir agregación	8
GRIN2A	Receptor NMDA, subunidad GluN2A	Epilepsia	Epilepsia, esquizofrenia, Alzheimer	Antagonismo	159
GABRA1	Receptor GABA-A, subunidad $\alpha 1$	Epilepsia	Epilepsia, insomnio, ansiedad	Modulación positiva	401
GABRB2	Receptor GABA-A, subunidad $\beta 2$	Epilepsia	Epilepsia, esquizofrenia	Modulación positiva	1
GABRG2	Receptor GABA-A, subunidad $\gamma 2$	Epilepsia	Epilepsia, ansiedad	Modulación positiva	0
GABA-A (receptor completo)	Receptor GABA-A completo	Epilepsia	Epilepsia, ansiedad, insomnio	Modulación positiva	1.511
MAOA	Monoamino oxidasa A	Depresión	Depresión, ansiedad	Inhibición	9.584
GRIN2B	Receptor NMDA, subunidad GluN2B	Depresión	Depresión, dolor neuropático, Alzheimer	Antagonismo	2.511
GABRA2	Receptor GABA-A, subunidad $\alpha 2$	Ansiedad	Ansiedad, epilepsia	Modulación positiva	175
GABRA5	Receptor GABA-A, subunidad $\alpha 5$	Deterioro cognitivo	Deterioro cognitivo, Alzheimer	Modulación negativa	545
NFE2L2	Nrf2	Estrés oxidativo	Esclerosis múltiple, ataxia de Friedreich, Parkinson, Alzheimer	Activación	2.036
KEAP1	Keap1	Estrés oxidativo	Esclerosis múltiple, ataxia de Friedreich, Parkinson, Alzheimer	Inhibición	676
SIRT1	Sirtuina 1	Neurodegeneración (general)	Alzheimer, Huntington, Parkinson	Activación	1.247
TSPO	Proteína translocadora (TSPO)	Neuroinflamación	Alzheimer, Parkinson, esclerosis múltiple, ansiedad	Activación	723
TNF	TNF- α	Neuroinflamación	Alzheimer, depresión, esclerosis múltiple	Inhibición	25
IL1B	Interleucina 1 β	Neuroinflamación	Alzheimer, epilepsia	Inhibición	347
IL6	Interleucina 6	Neuroinflamación	Depresión, Alzheimer	Inhibición	135
NOS2	Óxido nítrico sintasa inducible (iNOS)	Neuroinflamación	Parkinson, Alzheimer	Inhibición	1.545
PTGS2	Ciclooxigenasa 2 (COX-2)	Neuroinflamación	Alzheimer, dolor	Inhibición	9.433
NLRP3	Inflamasoma NLRP3	Neuroinflamación	Alzheimer, Parkinson	Inhibición	1.397
TLR4	Receptor tipo Toll 4	Neuroinflamación	Alzheimer, Parkinson, ictus	Inhibición	386
CX3CR1	Receptor de fractalquina	Neuroinflamación	Alzheimer, Parkinson	Dirección no establecida	98
AIF1	Iba1	Neuroinflamación	Varias (marcador)	No aplica (marcador)	0

"Sin diana de la lista" (98.298 filas, 44 %): filas de la vía neuronal cuya diana no es una de las 37 (p. ej. receptores de serotonina u opioides) o que ChEMBL no identifica (*Unchecked*).