

Diccionario de columnas — Permeabilidad BBB

Proyecto BBB · generado el 2026-09-25 desde DICCIONARIO_permeabilidad_bbb.md

Archivo `bbb_permeability_experimental.csv`: 7.811 filas y 16 columnas. Cada fila es un compuesto con su permeabilidad medida a través de la barrera hematoencefálica (BBB). Todo viene de **B3DB** (Blood-Brain Barrier Database), que recopila medidas publicadas; no hay ninguna predicción ni dato calculado por nosotros, salvo la estructura estandarizada y el cruce con COCONUT.

Es una tabla **independiente** de la de actividad en SNC: no comparten filas ni hace falta cruzarlas.

1. Para qué sirve

B3DB publica dos archivos y esta tabla los une por estructura, así que admite dos usos:

Uso	Columna objetivo	Filas disponibles
Clasificar si un compuesto entra al cerebro	<code>bbb_class</code> (BBB+ / BBB-)	7.805
Predecir cuánto entra (valor continuo)	<code>logbb</code>	1.058

Los 1.058 compuestos con `logbb` están también entre los 7.805 con clase: son un subconjunto, no filas aparte.

2. Identificación del compuesto

Columna	Qué es	Valores
<code>inchikey</code>	Identificador químico estándar de la estructura, con estereoquímica (27 caracteres)	Texto. 7.808 distintos (3 repetidos, ver sección 7)
<code>key14</code>	Los primeros 14 caracteres del anterior: solo el esqueleto, sin estereoquímica ni sal	Texto. 4.019 distintos: varios estereoisómeros comparten esqueleto
<code>smiles_std</code>	Estructura en formato SMILES, estandarizada con RDKit (sal retirada, cargas neutralizadas, tautómero canónico)	Texto, presente en las 7.811 filas
<code>compound_name</code>	Nombre del compuesto tal como lo escribe B3DB	Texto en 6.702 filas; vacío en 1.109. Puede estar equivocado : ver sección 7

3. Permeabilidad medida

Columna	Qué es	Valores
<code>bbb_class</code>	Si el compuesto atraviesa la barrera	BBB+ (4.956): entra al cerebro · BBB- (2.849): no entra · vacío (6)
<code>logbb</code>	Cuánto entra: log10 de la concentración en cerebro dividida entre la del plasma. 0 = igual concentración en ambos; negativo = menos en el cerebro	Número entre -2,69 y 1,70 (mediana -0,02) en 1.058 filas; vacío en 6.753
<code>b3db_threshold</code>	Umbral de logBB que B3DB aplicó para decidir la clase de esa fila	-1,0 en 3.621 filas ($\log BB \geq -1 \rightarrow \text{BBB+}$); vacío en 4.190, donde la clase no vino de un umbral numérico

4. Origen y trazabilidad en B3DB

Columna	Qué es	Valores
<code>b3db_uncertainty_classification</code>	Grupo que B3DB asigna en su archivo de clasificación (ver sección 6)	A (1.058) · B (3.621) · C (3.075) · D (51) · vacío (6)
<code>b3db_uncertainty_regression</code>	Grupo en su archivo de regresión. No significa lo mismo que el anterior	B (663) · A (243) · D (149) · C (3) · vacío (6.753)
<code>b3db_reference_classification</code>	Referencias bibliográficas de B3DB que respaldan la clase, como códigos <code>Rxx</code> separados por	Texto (p. ej. <code>R1 R6 R27 R30 </code>). Un mismo <code>Rxx</code> puede repetirse: son varias medidas de esa fuente
<code>b3db_reference_regression</code>	Lo mismo para el valor de <code>logbb</code>	Texto; vacío donde no hay <code>logbb</code>

Columna	Qué es	Valores
source_id_classification	Fila exacta del archivo original de clasificación, para poder volver al dato crudo	b3db_classification:<nº>
source_id_regression	Fila exacta del archivo original de regresión	b3db_regression:<nº>

5. Relación con productos naturales (COCONUT)

COCONUT es un catálogo de productos naturales. Estas tres columnas dicen si el compuesto tiene equivalente ahí; son el único añadido nuestro y **no afectan a la permeabilidad**: sirven para separar naturales de sintéticos.

Columna	Qué es	Valores
coconut_id_exact_match	Productos naturales con la estructura idéntica , estereoquímica incluida	ID(s) CNP... separados por , en 3.366 filas (824 con más de uno); vacío en 4.445
coconut_ids_key14_match	Productos naturales con el mismo esqueleto (key14), aunque cambie la estereoquímica. Incluye también los de la columna anterior	ID(s) CNP..., en 4.371 filas
coconut_matches_key14	Cuántos son, es decir, el tamaño de esa lista	Entero de 0 a 66. 0 en 3.440 filas: sin equivalente natural conocido

Resumen: 3.366 compuestos son productos naturales exactos, 1.005 tienen un análogo natural que difiere solo en la estereoquímica y 3.440 no tienen ninguno.

6. Los grupos A–D

B3DB indica que estas columnas "caracterizan la incertidumbre de las mediciones agrupando los registros", pero no publica el criterio exacto, y no encontré una fuente que lo detalle. **Sí se puede verificar qué distingue a cada grupo dentro de estos datos**, y el patrón es nítido:

Grupo	En clasificación	En regresión
A	Las 1.058 filas que tienen logbb numérico	243 compuestos con una sola referencia
B	Las 3.621 clasificadas con el umbral -1	663 con varias referencias (de 2 a 33, mediana 6)
C	3.075 sin valor ni umbral; casi todas con una sola referencia	3 compuestos, con 2 referencias
D	51 sin valor ni umbral, pero con 3 o más referencias; 47 de 51 son BBB-	149 con muchas referencias (de 3 a 35, mediana 18)

Lo que se deduce, y es interpretación mía sobre los datos, no una afirmación de B3DB:

- **No es una escala de calidad A > B > C > D.** En clasificación el grupo indica **de qué tipo de dato salió la etiqueta** (valor numérico, umbral, o ninguno). En regresión indica **cuántas mediciones independientes hay**, y ahí el grupo A es el de menos respaldo, con una sola medida.
- **Las dos columnas no son comparables entre sí.** Los 1.058 compuestos que están en ambos archivos son todos grupo A en clasificación, pero en regresión se reparten entre los cuatro grupos: difieren en el 77 % de los casos. Por eso se guardan por separado y nunca se promedian.
- **Filtrar "solo A" no tiene respaldo documentado** y en regresión dejaría justo los de una sola medición. Lo defendible es propagar la columna tal cual y que el equipo decida si la usa.

7. Detalles conocidos

- **Faltan 2 compuestos** de los 7.807 del archivo de clasificación de B3DB: mepenzolato y tiotidina. Sus SMILES en B3DB tienen un carbono con una carga imposible ([C+](O)) y RDKit los rechaza. Es un error del archivo original.
- **3 InChIKey aparecen en 2 filas** (6 filas en total): ampicilina y sultamicilina, colestipol dos veces, y probenecid con una fila sin nombre. En los tres casos ambas filas coinciden en la clase. Si necesitas un compuesto por fila, elimina duplicados por *inchikey*.
- **6 filas tienen logbb pero no bbb_class** (zidovudina, miltefosina y otras cuatro). En B3DB sí tienen clase, pero su fila de clasificación registra otra forma estereoquímica, así que el InChIKey no coincidió al unir.

- **131 esqueletos (key14) tienen clases contradictorias**, que afectan a 429 filas. Suelen ser estereoisómeros con etiquetas distintas: por ejemplo, el meso-etambutol es BBB+ y los demás isómeros del etambutol, BBB-. Es relevante si piensas agrupar por key14: la estereoquímica cambia la etiqueta.
- **Los nombres pueden estar equivocados**. En B3DB hay una fila llamada "ritonavir" cuya estructura es en realidad etambutol sin estereoquímica. Usa siempre `inchikey` o `smiles_std` como identificador, nunca `compound_name`.
- **112 esqueletos tienen más de un valor de logbb**, con diferencias de hasta 1,4 unidades logarítmicas entre isómeros del mismo esqueleto.