Tecnológico de Monterrey

Bioactive: cuánto confiar en una predicción depende de la molécula, no del modelo

Ingrid Pamela Ruiz Puga Artemio Santiago Padilla Robles
José Antonio Vázquez Martínez

Proyecto Integrador · Maestría en Inteligencia Artificial Aplicada

Asesora: Dra. Grettel Barceló Alonso · Patrocinadora: Dra. Mariana Martínez Ávila

13 de noviembre de 2026

Resumen

Queríamos saber qué tan lejos podía llegar un modelo para priorizar compuestos naturales con potencial neuroprotector, y encontramos que casi nunca era el modelo lo que importaba. Entrenamos dos modelos en paralelo: uno que decide si una molécula cruza la barrera hemato-encefálica (fase 1) y otro que estima su potencia contra 26 dianas del sistema nervioso central, usando también las mediciones censuradas (fase 2). Comparamos once modelos, de una regresión logística a ensambles, y ninguno mejoró de forma distinguible al mejor modelo individual: entre ellos hay 4.2 puntos de MCC (una medida que pesa los aciertos y errores de las dos clases, entre -1 y 1), contra 33.3 puntos que se pierden al exigir que lo evaluado se parezca menos a lo entrenado. En la prueba reservada el mejor modelo rindió peor de lo que su semejanza predecía (AUROC 0.79 en lugar de 0.89), y tres formas distintas de enseñarle química rara no cerraron la brecha. Lo que sí movió el resultado fue el corte de decisión: igualar la tasa de compuestos declarados permeables a la prevalencia esperada sube el MCC de 0.34 a 0.41. Las huellas moleculares ayudaron en la fase 2 y no en la 1. Concluimos que la confianza en una predicción depende de cuán nueva es la molécula, y que esa distancia conviene medirla y mostrarla junto con cada predicción.

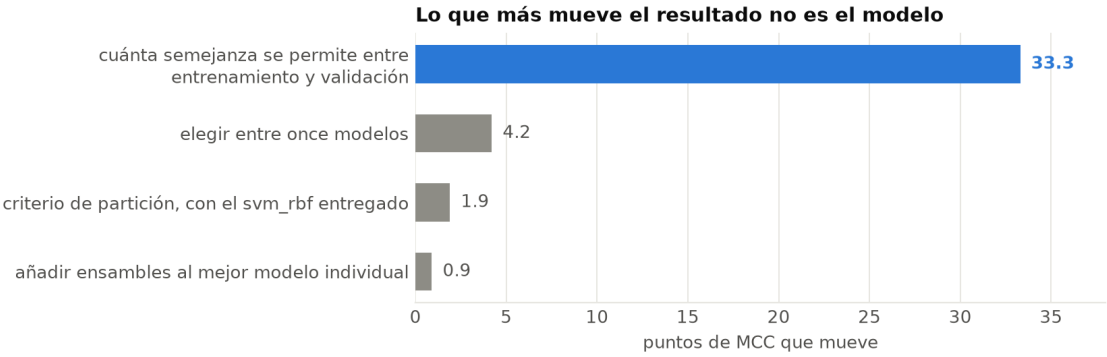


Figura 1: Cada barra viene de una corrida distinta, con otro propósito; indican el orden de magnitud, no miden el efecto de cada factor por separado.

1. Contexto de negocio y problema

1.1. El caso

Una académica del Tec de Monterrey nos presentó un caso de uso: priorizar compuestos naturales con potencial neuroprotector y nootrópico, es decir, que protejan o mejoren la función de las neuronas, antes de dedicarles tiempo y presupuesto de ensayo. Un compuesto así solo sirve si llega al cerebro y si actúa sobre una diana, la proteína a la que se une. El problema tiene entonces dos preguntas. La primera es si la molécula cruza la barrera hematoencefálica, la membrana que protege al cerebro (fase 1, clasificación entre permeable, BBB+, y no permeable, BBB−). La segunda es con qué potencia actúa sobre cada una de 26 dianas del sistema nervioso central (fase 2, regresión). La entrada es la estructura de la molécula escrita como texto (SMILES) y la salida es una lista priorizada, no una decisión automática.

1.2. Por qué dos fases en paralelo y no en cascada

Nuestra primera idea fue encadenarlas: lo que saliera BBB− se descartaba y solo el resto pasaba a estimar su potencia. La abandonamos porque no hay datos para comprobarla. De los 99,585 esqueletos con actividad medida, solo 1,033 tienen además la permeabilidad medida (612 en los archivos que usan los modelos), así que el resto se filtraría con una predicción que nadie ha verificado. Y una predicción de permeabilidad se equivoca: descartar con ella sería perder candidatos reales.

Por eso tratamos las fases en paralelo: cada una se entrena y se evalúa por su cuenta, y sus predicciones son evidencia que se combinará en un solo orden, no filtros encadenados. La primera ayuda a saber si algo puede permear; la segunda estima cuánto actuaría, y esa segunda respuesta sigue siendo útil aunque la primera sea dudosa. Cómo combinarlas queda como trabajo futuro (sección 6).

1.3. Qué significa equivocarse

Un falso permeable gasta tiempo en un compuesto que no llegará al cerebro. Un falso no permeable descarta un candidato real sin que nadie se entere. Cuál de los dos errores cuesta más depende de quien use la lista, y por eso lo que producimos es un orden de prioridad y no un punto de corte.

1.4. Qué puede y qué no puede decir este trabajo

- Los resultados valen para estos datos, con las particiones que describimos y para las familias de modelos que probamos.
- La prueba reservada es una sola, de 1,499 compuestos en la fase 1, y solo la usamos para medir, nunca para elegir un modelo.
- Una cifra de validación cruzada no describe a la química nueva; la sección 4 muestra cuánto cae.
- Quedan preguntas abiertas: por qué las huellas moleculares ayudan en una fase y no en la otra, y qué explica que la prueba rinda menos de lo que su semejanza predice.
- Las limitaciones completas y lo que haríamos después están en la sección 6.

2. Datos y preparación

2.1. Fase 1: permeabilidad

Partimos de 7,805 compuestos con clase, del archivo curado de la patrocinadora (derivado de B3DB y cruzado con COCONUT, una base de productos naturales, lo que permite separar los naturales de los sintéticos). El 65 % son BBB+. Usamos 6,306 para ajustar y validar y reservamos 1,499 como prueba. El archivo trae una columna de confiabilidad (grupos A a D) que decidimos no usar para filtrar: el análisis exploratorio mostró que está mezclada con la clase, y filtrar empeoraba el desbalance en vez de limpiar ruido.

2.2. Fase 2: potencia

Reunimos 202,647 registros de actividad de tres fuentes (ChEMBL, NPASS y CMAUP): 56,241 pares molécula–diana para ajustar y 13,944 reservados. Etiquetamos las tres fuentes con las mismas columnas, porque la medida que solo trae ChEMBL descartaría justo los naturales de NPASS y CMAUP. En lugar de una etiqueta guardamos el intervalo de potencia: el corte de 10 μM viene heredado del cribado y puede cambiar, y la misma molécula pasa de inactiva a activa según la concentración que se pruebe. Reportamos siempre por procedencia, porque un modelo que solo ve de dónde viene un compuesto ya alcanza el 65 % del MCC de la química.

2.3. Variables

Calculamos descriptores 2D con RDKit: 151 después de quitar los casi constantes y los redundantes, elegidos sobre los valores crudos para que el resultado no dependa de cómo se escalen. En la fase 2 se añade la diana. Las huellas moleculares, una cadena de bits que marca qué fragmentos tiene una molécula, las medimos aparte (sección 4.6).

2.4. Partición

Nunca partimos al azar. Agrupamos por andamio de Bemis–Murcko, el esqueleto central de la molécula, unido al esqueleto de conectividad, para que los estereoisómeros de un mismo compuesto no caigan a los dos lados de una partición. En la fase 1 quedan 1,048 grupos.

3. Metodología y modelos

3.1. De dónde partimos

Empezamos por un punto de referencia, el baseline: tres modelos sencillos (boosting por histogramas, bosque aleatorio y regresión logística) con validación cruzada agrupada, 3 semillas $\times$ 5 pliegues, es decir 15 evaluaciones. Sus MCC fueron 0.702, 0.700 y 0.687, con intervalos del 95 % que se solapan, así que ninguno ganó. Eso fijó el listón que había que superar, 0.70 de MCC (y 0.93 de AUROC), contra un piso de 0 de MCC, 0.5 de AUROC y 0.35 de AUPRC que dan los clasificadores triviales.

3.2. Los candidatos y cómo elegimos

Probamos once modelos de clasificación, de la regresión logística a cinco ensambles y dos versiones afinadas. Ninguno superó al mejor modelo individual, así que el modelo final de la fase 1 es ese, una máquina de vectores de soporte con núcleo radial (`svm_rbf`) sobre los 151 descriptores. Lo elegimos por descarte, no porque ganara.

En la fase 2 comparamos nueve modelos de regresión. El final es un modelo de supervivencia acelerada (AFT, XGBoost (Chen & Guestrin, 2016)), que aprende de las mediciones censuradas: las que solo dicen que la potencia es menor que cierto valor.

3.3. Cómo medimos

- *AUROC*: qué tan bien el modelo ordena a los compuestos permeables por encima de los no permeables, sin fijar un corte. 0.5 es el azar.
- *MCC* (coeficiente de correlación de Matthews): resume en un número entre -1 y 1 los aciertos y errores de las dos clases. Sí exige un corte, aquí 0.5, y por eso se mueve más que el AUROC cuando cambian los datos.
- *AUPRC de la clase minoritaria*: se lee contra su tasa base (0.35 en la fase 1), no contra cero.
- *Concordancia de Harrell* (fase 2, donde la respuesta es una potencia con mediciones censuradas): la probabilidad de que, de dos pares, el modelo ordene bien al más potente. 0.5 es el azar.
- *Comparaciones entre modelos*: la diferencia pareada en las mismas 15 evaluaciones, con el intervalo corregido de Nadeau y Bengio (Nadeau & Bengio, 2003).

3.4. Cómo cuidamos no engañarnos

Planteamos cada prueba antes de ver su resultado, y cada corrida empieza reproduciendo una cifra ya registrada. Los intervalos remuestrean grupos de moléculas, no filas. La prueba reservada solo sirvió para medir, nunca para elegir: la abrimos catorce veces, cuatro de ellas sin mirar etiquetas, y todas están registradas en `experimentos/prueba.csv`.

4. Resultados y validación

4.1. El mejor modelo apenas supera al punto de partida

Contra el listón de 0.70 de MCC que fijó el baseline, el modelo final lo iguala en validación cruzada y no lo supera: MCC 0.7017 (el boosting del baseline daba 0.7019), AUROC 0.919 y AUPRC de la clase minoritaria 0.884, contra un piso de 0.35. El lift sobre el baseline, es decir, cuánto mejora el modelo final al punto de partida, es cero, y lo tomamos como un resultado: elegir el modelo no fue la palanca.

Después medimos el modelo final en la prueba reservada. Allí el MCC es 0.339, el AUROC 0.793 y el AUPRC 0.720: una brecha de 0.363 de MCC (52 %) y de 0.126 de AUROC (14 %) frente a la validación cruzada. En la fase 2 la concordancia baja de 0.761 a 0.720. Una precisión: el AUROC de 0.93 del baseline sale de predicciones promediadas entre semillas y no es comparable con el 0.919, que es el promedio de las 15 evaluaciones.

4.2. La escalera de semejanza

Entre los once modelos hay solo 4.2 puntos de MCC. Con el `svm_rbf`, en cambio, pasar de pliegues al azar a pliegues donde ningún compuesto de entrenamiento se parece más de 0.4 a uno de validación cuesta 33.3 puntos (0.752 → 0.419). La lección ya se conocía (Sheridan, 2013) (Roberts et al., 2017); aquí la medimos con sus magnitudes.

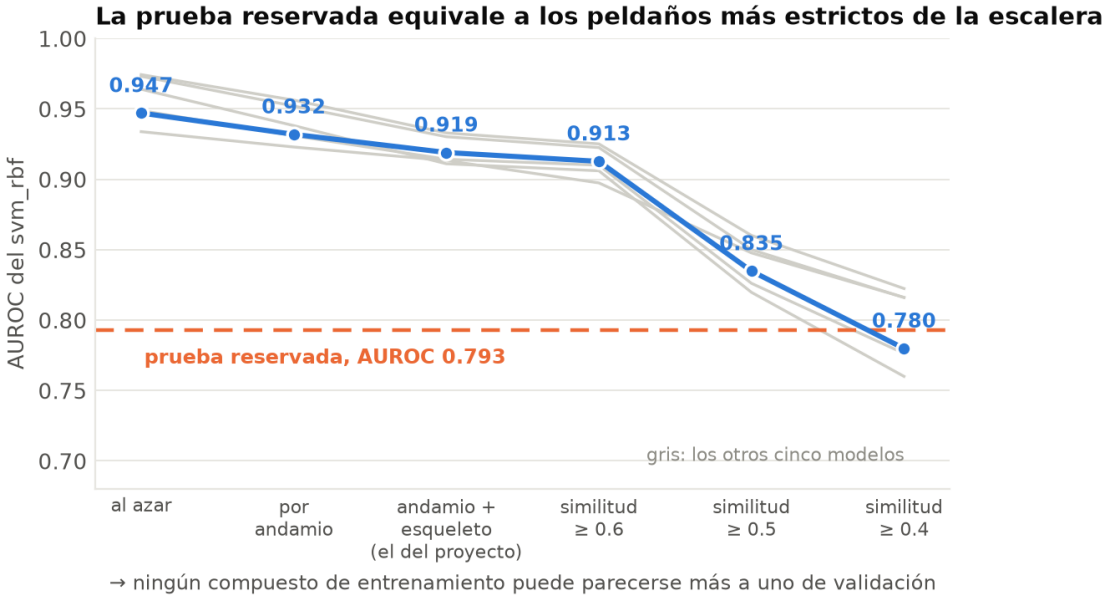


Figura 2: AUROC por peldaño, seis modelos. La línea naranja es la prueba reservada (0.793).

La fase 2 muestra lo mismo, con una limitación del conjunto. La concordancia del `aft` baja de 0.807 (por molécula) a 0.695 con semejanza ≥ 0.6: una caída de 0.112, unas siete veces la dispersión de 0.015 entre los siete modelos competitivos de la fase 2 (el doble, 0.030, era el umbral que fijamos). A 0.5 y 0.4 ni siquiera se puede construir la partición, porque el 69 % y el 90 % de las filas caen en un solo grupo. No hay manera de evaluar la fase 2 con química realmente nueva a esos niveles.

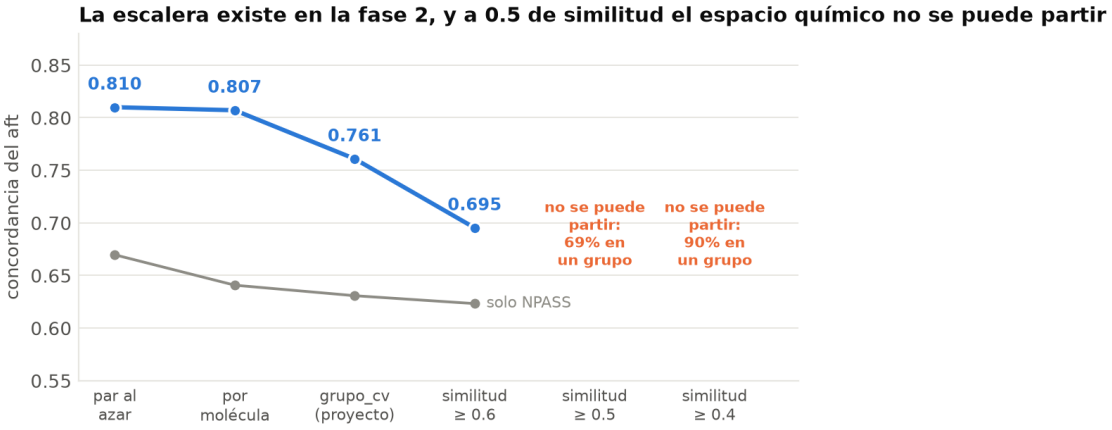


Figura 3: Concordancia del `aft` por peldaño; en gris, solo pares de NPASS.

Dos matices. La forma de la escalera depende de cómo se defina «parecido»: con ECFP6 la caída es gradual y con ECFP4 casi todo ocurre entre 0.6 y 0.5, aunque la caída total es parecida (0.419 contra 0.434 de MCC); con atom-pair no se pueden construir los peldaños estrictos. Y el MCC exagera: con el mejor corte posible sería 0.655 y 0.560 en los dos peldaños estrictos, contra 0.486 y 0.419 con el corte fijo en 0.5. Un corte de igual prevalencia solo recupera +0.047 en el primero, así que ahí no es una solución.

4.3. La prueba reservada es más difícil de lo que su semejanza predice

Esperábamos que la prueba cayera por ser química más nueva, pero no es tan simple. Su semejanza media al vecino más cercano (0.414) es mayor que la de la validación agrupada (0.384), así que por semejanza tendría que rendir mejor. Al reponderar las predicciones de validación a su distribución de semejanza, el AUROC esperado es 0.89 y el real es 0.79. Esa brecha de 0.10 no se explica por qué tan lejos queda la prueba de lo visto, y qué la explica no está medido (candidatos: prevalencia, peso y polaridad, curación de los datos, andamios raros a propósito).

Dentro de la prueba, la ventaja del modelo sobre una línea base de peso molecular y TPSA (una medida de la superficie polar) crece con lo parecido que es cada compuesto: +0.036 en el tercil más raro y +0.106 en el más parecido, una diferencia de +0.069 (IC95 % 0.011 a 0.124). En la fase 2 la diferencia es cuatro veces menor.

La caída baja con la semejanza. Dividimos la prueba en terciles de semejanza al ajuste (cortes 0.31 y 0.46), y el AUROC sube de 0.697 a 0.793 y a 0.875: +0.178 entre el tercil más parecido y el menos parecido (IC95 % [+0.119, +0.238], remuestreando esqueletos). En los compuestos sin equivalente natural la diferencia es +0.223 [+0.142, +0.306]. En los naturales exactos es +0.086 con un intervalo que incluye el cero [−0.029, +0.204], así que con 446 compuestos no se distingue, y en los análogos estereoquímicos el tercil más parecido tiene menos de 20 casos de la minoritaria y no se reporta. Es una correlación dentro de la prueba, y la semejanza no explica toda la brecha.

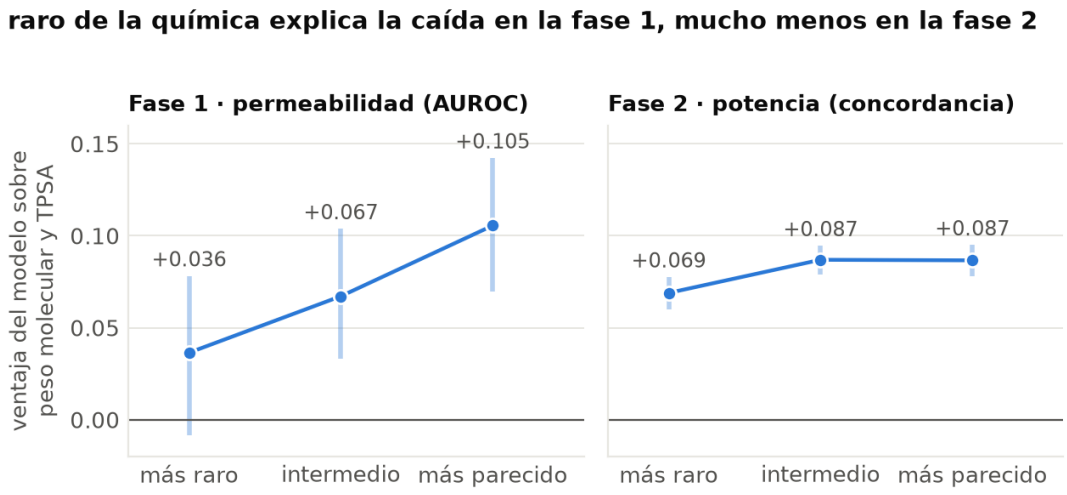


Figura 4: Ventaja sobre la línea base por tercil de rareza, con IC95 % por bootstrap de grupos.

4.4. Enseñarle más química rara no cierra la brecha

Como la ventaja del modelo se pierde justo en lo raro, probamos tres formas de enseñarle más de eso. Las tres tenían la regla escrita antes de correr.

Repesar. Dimos más peso a las filas raras que ya estaban en el ajuste: peso 3, 2 y 1 según el tercil de semejanza al vecino más cercano de otro grupo, dentro de cada tramo de peso molecular (`svm_rbf`, 15 evaluaciones agrupadas, sin leer la prueba). En el tercil más raro de validación la ganancia de AUROC fue −0.0005, positiva en 9 de 15 evaluaciones, cuando la regla pedía más de 0.005 en 12. Un control con los mismos pesos asignados al azar mueve el AUROC global casi igual (+0.0015 contra +0.0022) y el MCC global baja 0.0022. La regla tiene poca potencia para efectos chicos: con la dispersión observada (0.0095) solo detectaría con 80 % de probabilidad una mejora de unos 0.010, así que descarta una mejora grande, no una de 0.005.

Pasar filas de la prueba al entrenamiento. La mitad de los grupos de la prueba de cada tercil de rareza forma un núcleo de evaluación; de la otra mitad pasamos al ajuste las filas del tercil más raro (285 de media) y devolvimos a la prueba otras tantas filas comunes del ajuste, en 15 sorteos (esta prueba usó las lecturas 12 y 13 de la prueba reservada; la segunda solo mide la prevalencia del reparto, sin entrenar). En lo raro del núcleo el AUROC sube +0.003 (mejor en 9 de 15), y pasar el mismo número de filas elegidas al azar da +0.006: lo que ayuda es recibir filas de la prueba, no cuáles. El MCC pasa de 0.33 a 0.36 (+0.035, en los 15 sorteos), pero el AUROC apenas cambia (+0.002): el orden casi no cambia y el corte sí, así que no lo leemos como ganancia. Separado en tres brazos, sin otra lectura de la prueba, se ve de dónde sale: quitar solo las 295 filas comunes del ajuste no lo mueve (−0.001), y recibir filas de la prueba sí, raras (+0.035, 15 de 15 sorteos) o al azar (+0.023, 13 de 15). El MCC sube por recibir filas de la distribución sobre la que se evalúa, no por cuáles; tampoco lo explica la prevalencia del entrenamiento, que casi no se mueve (de 65.0 % a 64.5 % de BBB+). Lo más útil de esta corrida fue otra cosa: los compuestos comunes que pasan a la prueba se miden con AUROC 0.94 y los raros que quedaban en 0.68, con el mismo modelo y sin reentrenar. Recomponer la prueba cambia el número que se reporta, no lo que el modelo sabe.

Recomponer con qué filas se entrena. Fijamos el tamaño, la prevalencia y el número de grupos del ajuste y cambiamos solo su composición. Empezar por lo raro cuesta −0.060 de AUROC contra el orden al azar con el 25 % del ajuste (IC95 % [−0.110, −0.011], a favor en 1 de 15 evaluaciones; es una comparación secundaria, declarada antes y sin corrección por comparaciones múltiples, y el estadístico principal incluye el cero). Con el 75 % la composición deja de importar (±0.0004), y ni siquiera mejora el tercil más raro de la validación (+0.003, 8 de 15).

Ninguna de las tres formas cierra la brecha entre 0.70 y 0.34 de MCC, y añadir filas al azar ya estaba en meseta en la curva de aprendizaje. El límite de la fase 1 no es de cuántas filas ni de cuáles; lo que queda por medir es el punto de operación. Los 15 sorteos de la segunda forma comparten las mismas 1,499 filas, así que ese resultado descarta una ganancia grande y no una pequeña.

4.5. El corte de 0.5 es lo que más se mueve

El MCC cae más que el AUROC porque exige un corte, y el 0.5 es una convención heredada, no una decisión. En la prueba ese corte declara BBB+ al 79.3 % de los compuestos cuando la prevalencia real es 57.3 %: 22 puntos de desajuste, frente a los 6 que hay en el ajuste (70.9 % contra

64.97 %).

Igualar la tasa declarada a una prevalencia supuesta, sin usar las etiquetas de la prueba, sube el MCC de 0.3385 a 0.4095: +0.0712, IC95 % [+0.0303, +0.1099], remuestreando grupos de andamio. Ni siquiera hace falta acertar la prevalencia: supusimos la del ajuste, 65.0 %, cuando la de la prueba era 57.3 %, un error de 7.7 puntos, y la ganancia se sostuvo. En cambio, elegir el corte con las etiquetas de validación no recupera nada, +0.0065 [−0.0224, +0.0341]: se elige donde la prevalencia es 65.0 % y no puede saber que la de llegada es otra.

Tres cosas que estas cifras no dicen. El corte de igual prevalencia necesita tener el lote completo y suponer una prevalencia, así que no sirve para un compuesto suelto. El techo de 0.485 elige el corte con las etiquetas de la prueba, de modo que no es alcanzable: mide el margen que queda, no un resultado. Y las dos lecturas salen del modelo final y de una sola apertura de la prueba, con el corte congelado antes de abrirla, y sus dos controles reproducen el 0.3385 y el AUROC 0.793 ya registrados. El AUROC es el mismo con cualquier corte: lo que cambia es cuántos compuestos declaramos permeables, no la capacidad de ordenarlos. Por eso el cuaderno entrega la probabilidad y no una clase.

4.6. Las huellas moleculares ayudan en una fase y no en la otra

Las huellas Sort & Slice no mejoran a ningún modelo de la fase 1 y bajan el MCC de cinco de seis; en la fase 2 mejoran a cinco de seis en las 15 evaluaciones. Por tramo de peso la media es negativa en la fase 1 y sin tendencia. En la fase 2 la ganancia parece crecer con el peso, pero esa tendencia no se sostiene (su intervalo incluye el cero) y se aplana al igualar los tramos por submuestreo; el detalle está en el Anexo C.

Dos explicaciones simples las descartamos con experimentos propios. No es el tamaño de los datos: con el ajuste de la fase 2 reducido a 5,000 filas (el de la fase 1) la ganancia del `aft` es +0.0105 en 14 de 15 evaluaciones, mayor que con el ajuste completo (+0.0057). Tampoco es la granularidad de la etiqueta: con la etiqueta «molécula activa contra alguna diana» las huellas ayudan a los cuatro modelos probados (AUROC +0.017 a +0.085).

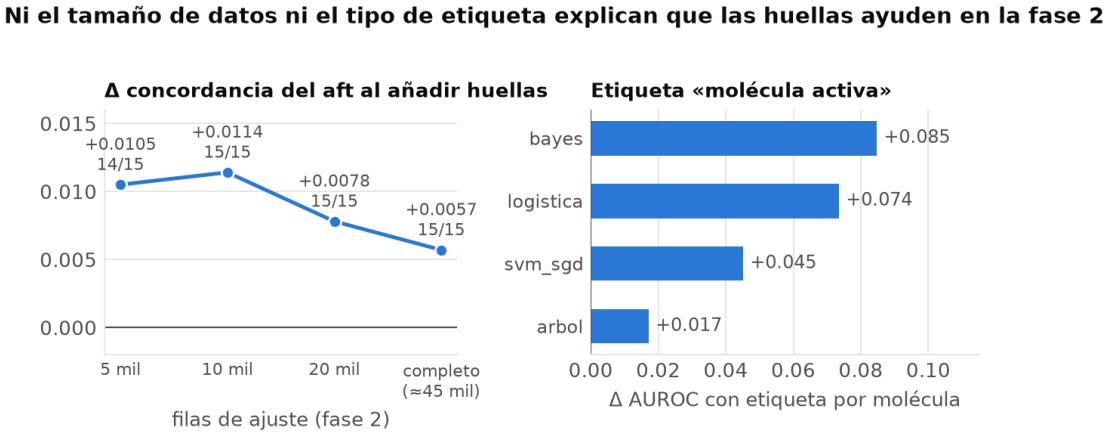


Figura 5: Las huellas ayudan aunque se achiquen los datos o se cambie la etiqueta.

Quedan en pie dos hipótesis. La primera es la densidad del espacio químico, que las huellas ganen donde hay muchos vecinos. La medimos a igual peso molecular y el resultado no es concluyente: la fase 2 es 1.8 veces más densa que la 1 (61.9 contra 33.8 vecinos fuera del grupo), y en la fase 1 la pérdida por añadir huellas se concentra en el tercio más disperso, pero las diferencias no superan su desviación. Igualar los tramos de peso por submuestreo quita el argumento del tamaño de la molécula: la ganancia de las huellas no sigue a cuántos pares tiene cada tramo en el ajuste, y lo que mueve la diferencia entre tramos es la composición del ajuste, no su tamaño total. Con una regla de baja potencia y un efecto original que no excluía el cero, eso es «no se puede sostener» y no «se demostró que es densidad». La segunda hipótesis es que la permeabilidad dependa de propiedades globales que los descriptores ya capturan, mientras la unión depende de subestructuras; no está medida. Los resultados valen para esas familias de modelos y no prueban qué pasa en la fase 1.

4.7. El modelo de potencia en NPASS

Elegimos el AFT porque en los pares que solo tiene NPASS aprende de mediciones censuradas que los demás modelos descartan. En validación cruzada su concordancia ahí es 0.632 contra 0.511 del bosque. En la prueba (117 pares) baja a 0.530 en la corrida registrada (0.511 al reajustarlo, que es lo que muestra la figura) y la línea base de peso y TPSA da 0.565. Con 117 pares no hay potencia para distinguir 0.511 de 0.632, y los pares no son la misma población (12.3 % de activos contra 44.4 %): no refuta el resultado, pero tampoco lo confirma. Además, su ventaja de MCC sobre el bosque (+0.155 con corte fijo) se reduce a +0.028 con un corte de igual prevalencia; sigue siendo positiva en las 15 evaluaciones y coincide con su ventaja de AUROC (+0.012).

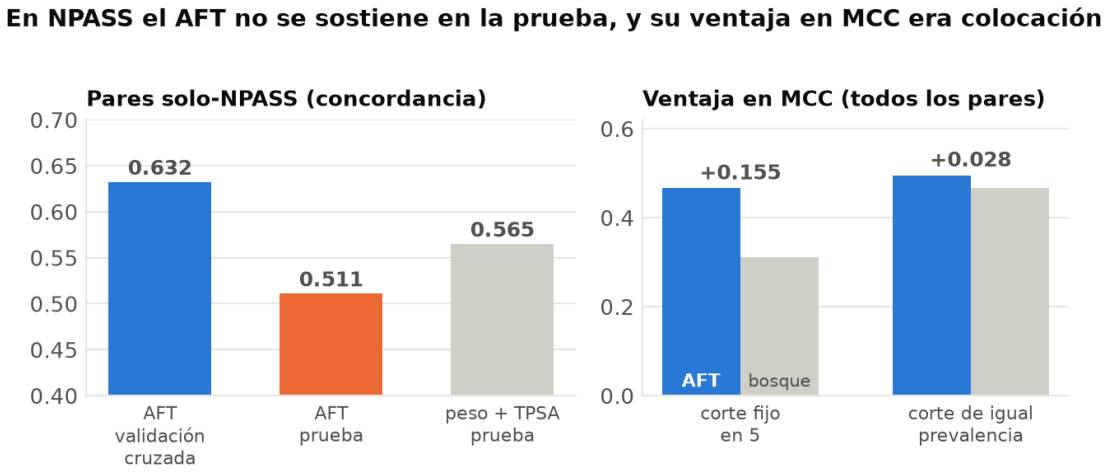


Figura 6: Izquierda: concordancia solo-NPASS. Derecha: ventaja en MCC del AFT sobre el bosque.

Ningún otro brazo supera al `aft` en NPASS (filtrar los descriptores no cambia nada y quitarlos lo empeora 0.041), y dos métodos de atribución independientes concuerdan en lo que pesa, con la diana en primer plano y TPSA y los donadores de hidrógeno lejos (Anexo F).

5. Implementación y operación

5.1. Un cuaderno, no un servicio

Acordamos con la patrocinadora que no habrá un punto de acceso productivo: lo que conviene es un cuaderno que cada persona ejecute con sus propios compuestos. La entrada es una lista de SMILES; la salida, para cada compuesto, es la probabilidad de cruzar la barrera (fase 1), la potencia predicha contra cada una de las 26 dianas (fase 2, una pActividad por diana y sin intervalo) y qué tan cerca queda de lo que los modelos vieron. El cuaderno no combina las dos fases en un ranking: esa combinación sigue pendiente y, cuando exista, será evidencia paralela y no una cascada.

Los dos modelos finales pesan unos 3 MB y se usan con un módulo de inferencia que no necesita los datos de entrenamiento. Comprobamos que los descriptores calculados desde un SMILES coinciden bit a bit con los de entrenamiento (150 moléculas de cada fase) y que el modelo recargado reproduce al entrenado. Se entrenan con las filas de ajuste: en la fase 1 usar el 100 % en lugar del 75 % gana apenas +0.002 de AUROC (meseta), y en la fase 2 sigue subiendo (+0.0076 de concordancia en 15 de 15), ganancia a la que renunciamos para poder evaluar y repetir la cifra registrada.

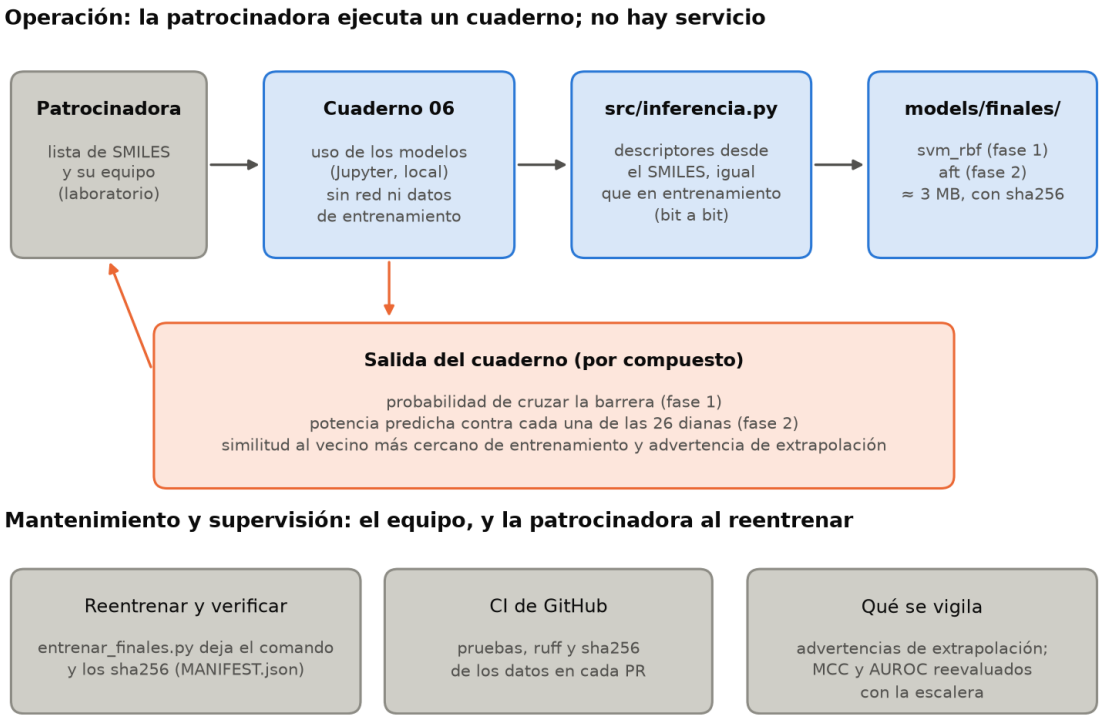


Figura 7: Arquitectura de despliegue: se ejecuta un cuaderno local que llama a un módulo de inferencia y a dos modelos guardados; no hay servicio. Abajo, lo que mantiene el equipo.

5.2. Una herramienta para medir columnas nuevas

Además de los modelos, dejamos una herramienta para comprobar si una tabla de columnas propia (ómicas, propiedades calculadas con otro programa) predice mejor que los descriptores, sin tocar el código del proyecto. La tabla se une a los compuestos por SMILES canónico, se evalúa con

la misma validación cruzada agrupada y se compara contra la referencia pliegue a pliegue, con un control de ruido y el intervalo de Nadeau y Bengio. Es Python y no una interfaz, y mide clasificación, no la regresión de supervivencia de la fase 2.

La acompaña una guía con lo que nos costó aprender sobre dos cosas. Sobre cómo agrupar: nunca al azar, que infla de 7 a 13 puntos, y por andamio y esqueleto juntos y no por andamio solo. Sobre cómo medir: una corrida no decide, las 15 evaluaciones comparten filas, «mejora en 10 de 15» tiene 49 % de potencia en el umbral que esa regla nombra, y el resultado se reporta por subgrupo. La guía dice también lo único que la herramienta no puede verificar: que las columnas no se hayan calculado usando las etiquetas ni usando todas las filas a la vez.

El ejemplo que la acompaña usa datos reales y replica un hallazgo del propio proyecto: las tres propiedades de los filtros de la literatura (TPSA, donadores de hidrógeno y peso) quedan 0.082 de MCC por debajo de los 151 descriptores (IC95 % $[-0.131, -0.034]$, mejoran en 1 de 15 evaluaciones).

5.3. Requisitos para operar

La Tabla 1 lista lo que hace falta para operar los modelos y quién responde de cada cosa.

Tabla 1: Requisitos para operar los modelos, por qué se piden y quién responde de cada uno.

requisito	por qué	responsable
script que entrena y guarda los dos modelos finales, con el comando y los `sha256` de los datos	que cualquiera pueda reconstruirlos (`experimentos/README.md` ya lo hace para las corridas)	equipo, disponible
cuaderno de uso con SMILES propios	es la forma de operación acordada	equipo, disponible
advertencia de extrapolación: la similitud de cada compuesto consultado a su vecino más cercano de entrenamiento	una cifra de validación cruzada no describe a la química nueva; la escalera de la sección 4.2 muestra cuánto	equipo, disponible en el cuaderno
reentrenar al llegar datos nuevos y reevaluar con la escalera, no con un corte al azar	evita celebrar una cifra inflada	patrocinadora, con apoyo del equipo

requisito	por qué	responsable
evaluación externa con su conjunto de prueba	la prueba reservada es nuestra, no la de ella	hecha una vez con el `aft` final: concordancia 0.792 [0.787, 0.797] en 8,134 pares (`solo_npass` 0.667, 249 pares), pero no comparable: el 64.9 % de sus pares tiene andamio ya visto (ver 5.4)

5.4. Qué pasó con la base externa de la patrocinadora

El archivo `Testeo` no comparte identificador ni SMILES canónico con el de entrenamiento. Con el `aft` guardado y sin reentrenar, la concordancia en 8,134 pares de las 26 dianas del modelo es 0.792 (IC95 % remuestreando esqueletos: 0.787 a 0.797), mayor que el 0.720 de la prueba reservada. Por clase de procedencia, `solo_chembl` da 0.786, `mixto` 0.615 y `solo_npass` 0.667 (249 pares, Spearman 0.309).

Esa base no es comparable con la prueba reservada: se separó por compuesto y no por andamio, y el 64.9 % de sus pares tiene un andamio que ya está en el ajuste, contra 0.5 % en el control interno. La semejanza mediana al vecino más cercano es 0.787 (0.679 en la validación de la misma fase). Que salga mejor es justo lo que predice la tesis del artículo, no una prueba de mejor generalización. Los naturales siguen siendo el estrato débil. Es una lectura única, y el control reconstruye los 70,384 pares del entrenamiento sin diferencia.

5.5. Qué se supervisa durante la operación

Como no hay servicio, supervisar es revisar periódicamente lo que el cuaderno ya produce y reevaluar cuando llegan datos etiquetados. Las referencias son cifras medidas en este trabajo; los umbrales de alerta son propuestas y no se midieron (Tabla 2).

Tabla 2: Qué se supervisa durante la operación: la señal, su referencia medida en este trabajo con la alerta propuesta, y el responsable.

aspecto	señal	referencia y alerta propuesta	responsable
extrapolación	proporción de los compuestos consultados cuya similitud al vecino más cercano de entrenamiento es menor que 0.31	0.31 es el corte del tercil más raro de la prueba (sección 4.3); si la mayoría de las consultas cae ahí, las cifras de validación no aplican	patrocinadora, con la advertencia del cuaderno

aspecto	señal	referencia y alerta propuesta	responsable
desempeño	AUROC y MCC (fase 1) y concordancia (fase 2) sobre datos etiquetados nuevos, con intervalo remuestreando grupos	0.793, 0.339 y 0.720 en la prueba reservada; una caída mayor que la desviación entre pliegues pide revisar	equipo, al llegar datos
punto de operación	proporción declarada permeable al cortar en 0.5 contra la prevalencia de los datos nuevos	en el ajuste 70.9 % contra 64.97 %, y en la prueba reservada 79.3 % contra 57.3 %: la diferencia crece cuando la química cambia (sección 4.5)	equipo
integridad	`sha256` de modelos y datos contra `data/MANIFEST.json`; versiones del lock	el CI lo verifica en cada cambio; el reajuste de la fase 2 no repite la cifra de la prueba exactamente (0.7234 contra 0.7200)	equipo
datos y etiquetas	cuántos pares activos aporta cada fuente y qué concentración de corte se usa	el 10 μM es el de cribado heredado del archivo; NPASS es CC BY-NC, solo uso no comercial	patrocinadora y equipo

5.6. Riesgos y cómo los mitigamos

Identificamos cinco, dos de ellos del modelo y de los datos:

1. *Química fuera de lo visto* (del modelo). Una cifra de validación no describe a la química nueva. Mitigación: la advertencia de extrapolación del cuaderno y la reevaluación con la escalera, no con un corte al azar.
2. *Validez de las etiquetas* (de los datos). El corte de 10 μM es el del cribado heredado del archivo, no un umbral biológico, y la misma molécula cambia de clase según la concentración. Mitigación: se guarda el intervalo de potencia y no la etiqueta, de modo que cambiar el corte no reconstruye nada.
3. *Punto de operación.* Un MCC a 0.5 exagera la caída bajo un cambio de distribución. Mitigación: el cuaderno entrega la probabilidad y no una clase.
4. *Reproducibilidad.* La misma regresión logística da 0.481, 0.489 o 0.497 de MCC según el sistema operativo y la versión de Python. Mitigación: un lock de dependencias, `sha256` de los datos y decidir con 15 evaluaciones y su error, no con una corrida.
5. *Licencia.* NPASS es CC BY-NC. Mitigación: declarar el uso no comercial y revisar la licencia con la patrocinadora antes de cualquier otro uso.

Hay además un límite en la propia advertencia de extrapolación: es una heurística, porque la

similitud al vecino más cercano no anticipa bien la dificultad de la prueba (sección 4.3), de modo que una similitud alta no garantiza un buen resultado.

6. Conclusiones clave

6.1. Lo que encontramos

1. *Los ensambles no mejoran al modelo simple en MCC ni en AUPRC, y no es un fracaso:* es el peldaño más bajo de una escalera donde el modelo nunca fue el factor grande. En AUROC, la votación (+0.0139 [+0.0038, +0.0239]) y el stacking (+0.0128 [+0.0023, +0.0233]) sí superan al `svm_rbf` con el intervalo corregido de Nadeau y Bengio, pero al corregir por las diez comparaciones hechas ninguno se sostiene (p = 0.103 y 0.180). Acomodar el escalador dentro de la calibración del SVM no cambia nada (MCC 0.7015 contra 0.7017; AUROC y AUPRC idénticos).
2. *Una cifra de validación cruzada no describe a la química nueva,* y la semejanza al vecino más cercano no basta para anticipar cuánto cae: en la fase 1 la prueba cae 12.6 puntos de AUROC, 10 más de lo que su semejanza predice; en la fase 2 la concordancia agregada baja de 0.761 a 0.720.
3. *La representación no se traslada entre fases,* y no por tamaño de datos, por tipo de etiqueta ni por el peso de la molécula; la densidad del espacio químico queda como pista sin confirmar.
4. *Para quien use los modelos:* priorizar candidatos y no descartarlos (un BBB− no excluye un compuesto); leer la probabilidad de la fase 1 junto con la advertencia de semejanza y no como una clase; y medir cualquier mejora donde el resultado se mueve, que es qué tan lejos queda la química evaluada de la de entrenamiento (Figura 1), no solo con el modelo que se prueba. Ninguna de las formas de aprender de lo raro que probamos cerró la brecha. Para probar columnas nuevas hay una herramienta y una guía (sección 5.2) que aplican la misma validación agrupada.

6.2. Limitaciones

- La prueba reservada se leyó catorce veces, y los modelos finales están guardados a falta de la revisión del equipo.
- Las 151 columnas de la fase 1 se eligieron con etiquetas de entrenamiento, así que su sesgo de selección no es medible contra la dispersión.
- El efecto de agrupar depende del modelo (1.3 puntos de AUROC con el `svm_rbf` y 2.2 con el bosque) y de qué se llame «parecido».
- Los experimentos de la representación usan una o cuatro familias de modelos, no las seis de la fase 1.
- La atribución por subestructura excluye 618 de 2,534 columnas, todas huellas, por existir en menos de cinco pliegues.
- El `mlp` y el bosque varían con la semilla del modelo (desviación de 0.017 y 0.007 de MCC); los otros cuatro modelos de la fase 1, incluido el final, dan la misma predicción con cualquier semilla.

- Ninguna corrida se diseñó para comparar las palancas de la Figura 1, así que sus barras indican el orden de magnitud y no miden el efecto de cada factor por separado.
- Las tres formas de aprender de lo raro (repesar, pasar filas de la prueba al ajuste y recomponer) usan un solo modelo, el `svm_rbf`, y la segunda comparte las mismas 1,499 filas en sus 15 sorteos.

6.3. Trabajo futuro

- *El punto de operación.* Reportar el MCC con un corte de igual prevalencia junto al de 0.5 (0.4095 contra 0.3385 en la prueba) y medirlo con una prevalencia de llegada conocida de los datos de la patrocinadora. El corte elegido en validación no sirve.
- *Una evaluación externa separada por andamio y no por compuesto.* La base externa de la patrocinadora no mide generalización: el 64.9 % de sus pares ya tiene su andamio en el ajuste.
- *Combinar las dos fases en el ranking,* como evidencia paralela, y medir si seleccionar con ambas supera a cada una por separado. Se puede comprobar sobre los 612 esqueletos con medición en los dos archivos que usan los modelos, que son 1,594 pares sobre 23 dianas: poca potencia, así que la regla de lectura tiene que admitir «no alcanza» como veredicto.
- *Confirmar o descartar la densidad del espacio químico* como la razón por la que las huellas ayudan en la fase 2 y no en la 1, separándola de la composición del ajuste con varios sorteos por pliegue. Los tramos de peso ya se igualaron y queda el control de rareza.
- *Medir el modelo de potencia con más pares de NPASS.* Con 117 no hay potencia para distinguirlo de la línea base (sección 4.7).

Referencias y anexos

Fuentes de datos: B3DB (Meng et al., 2021); NPASS (Zhao et al., 2023) y (Lin et al., 2026); CMAUP (Hou et al., 2024); ChEMBL (Zdrazil et al., 2024). Representación y partición: huellas de Morgan / ECFP (Rogers & Hahn, 2010); RDKit (Landrum & RDKit contributors, 2026); andamios de Bemis–Murcko (Bemis & Murcko, 1996). La lección de la escalera: la partición por tiempo como estimación de la predicción prospectiva (Sheridan, 2013), y la validación por bloques que corrige la subestimación del error cuando los datos tienen estructura (Roberts et al., 2017). Modelos y métricas: XGBoost (Chen & Guestrin, 2016); la concordancia de Harrell (Harrell et al., 1982); la corrección de Nadeau y Bengio para los intervalos de la validación cruzada (Nadeau & Bengio, 2003). Código y datos: cada cifra tiene su corrida en `experimentos/` (parámetros, commit, `sha256` de los datos, comando) y se repite con `experimentos/README.md`; las lecturas de la prueba reservada están en `experimentos/prueba.csv`.

Declaración de uso de inteligencia artificial

Se utilizó Anthropic (2026) con los modelos Claude Opus 5 y Claude Sonnet 5.5, y Claude Sonnet 5 cuando las restricciones de seguridad del modelo en temas de biología y química impidieron usar el 5.5, para escribir el código de los experimentos y sus pruebas, generar con ese código las figuras a partir de las corridas registradas y redactar y dar formato al borrador de este artículo. Las preguntas, las reglas de decisión escritas antes de cada corrida, la interpretación de los resultados

y las conclusiones son del equipo, que contrastó cada cifra con su corrida. La responsabilidad final sobre el contenido entregado recae en los autores.

Referencias

Anthropic. (2026). Claude Code [Agente de programación]. https://claude.com/claude-code

Bemis, G. W., & Murcko, M. A. (1996). The Properties of Known Drugs. 1. Molecular Frameworks. *Journal of Medicinal Chemistry*, *39*(15), 2887-2893. https://doi.org/10.1021/jm9602928

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. https://doi.org/10.1145/2939672.2939785

Harrell, F. E., Califf, R. M., Pryor, D. B., Lee, K. L., & Rosati, R. A. (1982). Evaluating the Yield of Medical Tests. *JAMA*, *247*(18), 2543-2546. https://doi.org/10.1001/jama.247.18.2543

Hou, D., Lin, H., Feng, Y., Zhou, K., Li, X., Yang, Y., Wang, S., Yang, X., Wang, J., Zhao, H., Zhang, X., Fan, J., Lu, S., Wang, D., Zhu, L., Ju, D., Chen, Y. Z., & Zeng, X. (2024). CMAUP database update 2024: extended functional and association information of useful plants for biomedical research. *Nucleic Acids Research*, *52*(D1), D1508-D1518. https://doi.org/10.1093/nar/gkad921

Landrum, G., & RDKit contributors. (2026). RDKit: Open-Source Cheminformatics Software.

Lin, H., Hou, D., Jiang, X., Yin, R., Yu, S., Lu, S., Wang, S., Ju, D., Zhao, H., Chen, Y., & Zeng, X. (2026). NPASS database update 2026: comprehensive quantitative composition, bioactivity, and ADME-Tox data of natural products for biomedical research. *Nucleic Acids Research*, *54*(D1), D1519-D1527. https://doi.org/10.1093/nar/gkaf1196

Meng, F., Xi, Y., Huang, J., & Ayers, P. W. (2021). A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors. *Scientific Data*, *8*(1), 289. https://doi.org/10.1038/s41597-021-01069-5

Nadeau, C., & Bengio, Y. (2003). Inference for the Generalization Error. *Machine Learning*, *52*(3), 239-281. https://doi.org/10.1023/A:1024068626366

Roberts, D. R., et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, *40*(8), 913-929. https://doi.org/10.1111/ecog.02881

Rogers, D., & Hahn, M. (2010). Extended-Connectivity Fingerprints. *Journal of Chemical Information and Modeling*, *50*(5), 742-754. https://doi.org/10.1021/ci100050t

Sheridan, R. P. (2013). Time-Split Cross-Validation as a Method for Estimating the Goodness of Prospective Prediction. *Journal of Chemical Information and Modeling*, *53*(4), 783-790. https://doi.org/10.1021/ci400084k

Zdrazil, B., Felix, E., Hunter, F., Manners, E. J., Blackshaw, J., Corbett, S., de Veij, M., Ioannidis, H., Lopez, D. M., Mosquera, J. F., Magarinos, M. P., Bosc, N., Arcila, R., Kizilören, T., Gaulton, A., Bento, A. P., Adasme, M. F., Monecke, P., Landrum, G. A., & Leach, A. R. (2024). The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Research*, *52*(D1), D1180-D1192. https://doi.org/10.1093/nar/gkad1004

Zhao, H., Yang, Y., Wang, S., Yang, X., Zhou, K., Xu, C., Zhang, X., Fan, J., Hou, D., Li, X., Lin, H., Tan, Y., Wang, S., Chu, X.-Y., Zhuoma, D., Zhang, F., Ju, D., Zeng, X., & Chen, Y. Z. (2023). NPASS database update 2023: quantitative natural product activity and species source database for biomedical research. *Nucleic Acids Research*, *51*(D1), D621-D628. https://doi.org/10.1093/nar/gkac1069

Anexos

Cada anexo viene de una corrida registrada; su carpeta está en `experimentos/` del repositorio.

- *A. La escalera con seis modelos y con otra definición de «parecido».* La logística no se degrada menos que el `svm_rbf` de forma distinguible; con ECFP6 la caída es gradual y con atom-pair los peldaños estrictos no se pueden construir. Corridas: `2026-11-03-artemio-1.2-escalera-ampliada-permeabilidad`, `2026-11-04-artemio-1.2-escalera-definicion-de-parecido-permeabilidad`.
- *B. La línea base de peso y TPSA.* Corrida: `2026-11-03-artemio-1.5-prueba-por-rareza`.
- *C. Las huellas por tramo de peso,* con la figura de abajo.
- *D. El ranking de la fase 2 y la curva de aprendizaje.* Corridas: `2026-11-03-artemio-C.5-ranking-fase2-aft`, `2026-11-03-artemio-1.5-curva-aprendizaje-modelos-finales`.
- *E. La densidad del espacio químico a igual peso* (no concluyente), *los tramos de peso igualados por submuestreo* (el control que deja sin sostén la tendencia de la sección 4.6) y *cómo repetir cada corrida,* con tiempos y `sha256` de los datos. Corridas: `2026-11-04-artemio-1.3-huellas-por-densidad-del-espacio-quimico`, `2026-11-08-artemio-1.3-tamano-huellas-actividad-igualado`.

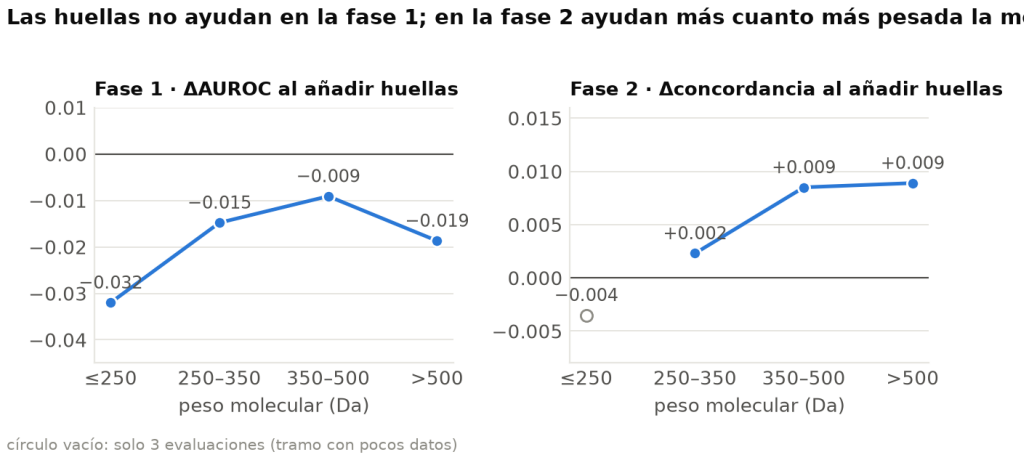


Figura C1: Cambio por añadir huellas, por tramo de peso. Magnitudes menores a 0.01 en la fase 2.

F. Los cuatro brazos del `aft` y la atribución.

Qué ve el modelo. De los cuatro brazos con los mismos pliegues, ninguno supera al `aft` en NPASS: filtrar los descriptores no cambia nada que se distinga del ruido (+0.002), y quitar los descriptores y dejar solo huellas y diana lo empeora en las 15 evaluaciones (−0.041), aunque en el agregado empata. Esto matiza la lectura de que en la fase 2 se pueden tirar los descriptores, porque las huellas solas casi igualaban al brazo ancho: en el estrato por el que se eligió el modelo no se pueden.

Qué pesa. Dos métodos independientes, TreeSHAP (lee los árboles) y permutación (solo la salida), concuerdan (Spearman 0.93; 12 de sus 15 columnas más importantes son las mismas). Pesan

la diana (`MAOA`, `MAOB`, `DRD2`, `LRRK2`, `BCHE`, el 15 % de la atribución) y, en la química, la complejidad topológica (`BertzCT`), la lipofilia y los halógenos. TPSA y los donadores de hidrógeno, que dominan la permeabilidad, no dominan la potencia (lugares 44 y 165).

Qué pesa en la fase 1. Los dos métodos (permutación y KernelSHAP) miran el mismo `svm_rbf`. Coinciden en seis descriptores entre sus quince primeros (`fr_lactam`, `NumHDonors`, `NumAliphaticCarbocycles`, `VSA_EState3`, `fr_Ar_OH`, `fr_ether`), estables entre dos muestras de compuestos; la correlación entre los dos rankings completos es 0.37. Los donadores de hidrógeno entran (puesto 4 en ambos); TPSA no (40 por permutación y 10 por SHAP), porque comparte información con un racimo de columnas. No afirmamos ninguna estructura: son seis nombres de descriptor, no un mecanismo.

Por subestructura. El modelo final no usa huellas, así que repetimos el diseño con el brazo que sí (`aft_huellas`, que no mejora en NPASS). Con cinco repeticiones de permutación sobre las 11,248 filas, los dos métodos concuerdan según la regla declarada (Spearman 0.577 sobre la unión de los 100 primeros, contra el 0.50 fijado de antemano, y 11 de 15 en común). Una medición previa con una repetición sobre 1,500 filas había dado 0.378 y «no concuerdan»; era ruido de la permutación, no un resultado. En la intersección hay dos subestructuras, un nitrógeno de anillo tipo piridina y un CH aromático vecino a ese nitrógeno, genéricas y frecuentes (en el 57 % y 21 % de las moléculas): indican que el modelo usa heterociclos nitrogenados, no un farmacóforo específico. No afirmamos ninguna subestructura específica. Un límite declarado: 618 de 2,534 columnas (24.4 %, todas huellas) existen en menos de cinco pliegues y se excluyen de la intersección; ninguna estaba arriba.