

Tecnológico de Monterrey

Escuela de Ingeniería y Ciencias

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador · TC5035.10

Avance 0. Propuesta de proyecto

Bioactive AI

Predicción y priorización de compuestos bioactivos con potencial neuroprotector a partir de su estructura molecular

Profesora

Dra. Mariana Martínez Ávila

Equipo 7

Ingrid Pamela Ruiz Puga	A01021209
Artemio Santiago Padilla Robles	A01796613
José Antonio Vázquez Martínez	A01797208

27 de septiembre de 2026

Índice

1	Antecedentes	3
1.1	La organización	3
1.2	El proceso que el proyecto impacta	3
2	Entendimiento del negocio	4
2.1	Formulación del problema	4
2.2	Contexto	5
2.3	Objetivos comerciales y su traducción a objetivos del proyecto	5
2.4	Preguntas clave	6
2.5	Involucrados	7
2.6	Alcance, supuestos y riesgos	7
3	Entendimiento de los datos	8
3.1	Origen y contexto	8
3.2	Auditoría preliminar de calidad	10
3.3	Técnica de aprendizaje automático	11
3.4	Variables de entrada y salida	11
3.5	Consideraciones metodológicas de validación	12
3.6	Alineación con la metodología	13
	Bibliografía	15

1 Antecedentes

Conceptos básicos. Antes de describir el proyecto conviene fijar el vocabulario que se usa a lo largo del documento. Un **compuesto** (o **molécula**) es una sustancia química definida por su estructura atómica; aquí ambos términos se usan como sinónimos. Un **producto natural** es un compuesto producido por un organismo vivo —en este proyecto, principalmente plantas—, por oposición a uno obtenido por síntesis química. Una **colección** es una base de datos que reúne, de forma curada, las estructuras de muchos compuestos (por ejemplo, COCONUT agrega compuestos de 71 colecciones distintas). Un **registro de actividad experimental** es el resultado de un ensayo de laboratorio que midió si un compuesto tuvo efecto sobre una diana biológica, y con qué magnitud. La relación entre estos términos recorre el documento: las colecciones agrupan compuestos, entre ellos productos naturales, y de los ensayos sobre esos compuestos surgen los registros de actividad que alimentan la etapa 2 del modelo (ver Entendimiento de los datos).

1.1 La organización

El proyecto se desarrolla con el **Departamento de Bioingeniería** de la Escuela de Ingeniería y Ciencias del Tecnológico de Monterrey, bajo el patrocinio de la **Dra. Mariana Martínez Ávila**, Profesora Investigadora con nivel 1 en el Sistema Nacional de Investigadoras e Investigadores (SNII).

La línea de investigación del departamento en la que se inserta este trabajo estudia **compuestos bioactivos de origen natural** —principalmente de origen vegetal— con potencial neuroprotector y nootrópico. Esa línea combina trabajo experimental de laboratorio con revisión de literatura especializada para identificar compuestos candidatos que justifiquen una evaluación biológica más profunda.

1.2 El proceso que el proyecto impacta

El proceso de negocio afectado es la **identificación y priorización de compuestos candidatos** previa al trabajo experimental. En su forma actual sigue tres pasos:

1. **Revisión de literatura.** El equipo de investigación identifica compuestos reportados con actividad relevante, a partir de publicaciones y bases de datos de productos naturales.
2. **Selección por criterio experto.** Se eligen compuestos para ensayar, combinando el conocimiento farmacológico del grupo con criterios fisicoquímicos clásicos.
3. **Evaluación experimental.** Los compuestos seleccionados se prueban en ensayos de laboratorio.

Este proceso tiene tres limitaciones que el proyecto busca atender:

El espacio de búsqueda es inabarcable manualmente. Solo las bases públicas de productos naturales contienen cientos de miles de estructuras: COCONUT reúne 738,829 moléculas provenientes de 71 colecciones (Chandrasekhar et al., 2025) y NPASS registra 204,023 productos naturales con más de un millón de registros de actividad experimental (Lin et al., 2026). Revisar ese volumen compuesto por compuesto no es viable.

La barrera hematoencefálica descarta a la mayoría de los candidatos. Un compuesto con actividad demostrada *in vitro* no sirve como terapia del sistema nervioso central (SNC) si no alcanza el tejido cerebral. Esta barrera es una interfaz celular activa que restringe severamente el paso de moléculas (Daneman & Prat, 2015), y el flujo activo mediado por glicoproteína-P¹ puede impedir la entrada de compuestos

¹Bomba de la familia de transportadores ABC, situada en la membrana del endotelio cerebral, que expulsa de vuelta a la sangre compuestos que ya habían cruzado por difusión pasiva, impidiendo que alcancen concentraciones terapéuticas en el cerebro (Löscher & Potschka, 2005).

que, por sus propiedades fisicoquímicas, parecerían permeables (Löscher & Potschka, 2005). Evaluar experimentalmente la permeabilidad de cada candidato es costoso.

La tasa histórica de éxito es baja. Una revisión de 1,026 tratamientos neuroprotectores evaluados experimentalmente en isquemia cerebral encontró que solo 114 llegaron a ensayos en humanos y que **ninguno demostró eficacia clínica establecida** (O'Collins et al., 2006). Priorizar mejor antes de invertir en experimentación no es una optimización marginal: es el cuello de botella del campo.

Existe, sin embargo, precedente de que la ruta funciona. La galantamina, alcaloide aislado de *Galanthus nivalis*, es un inhibidor de acetilcolinesterasa aprobado para el tratamiento de la enfermedad de Alzheimer, con una trayectoria documentada desde el conocimiento etnobotánico hasta el registro sanitario (Heinrich & Teoh, 2004). El proyecto busca acelerar el reconocimiento de candidatos con ese perfil.

2 Entendimiento del negocio

2.1 Formulación del problema

¿Es posible predecir, a partir únicamente de la estructura molecular de un compuesto, si llegará al cerebro y si tendrá actividad neuroprotectora, y explicar qué característica estructural sustenta esa predicción?

El problema se descompone en dos etapas independientes, ambas con el SMILES del compuesto como única entrada. El SMILES es una representación textual del grafo molecular, estándar en quimioinformática: por ejemplo, la cadena CCO representa el etanol —dos carbonos encadenados y un oxígeno— sin necesidad de dibujar la molécula.

Etapla 1 — Permeabilidad. Clasificar si el compuesto atraviesa la barrera hematoencefálica (BBB+) o no (BBB-).

Etapla 2 — Actividad. Predecir si el compuesto presenta actividad sobre dianas moleculares asociadas a neuroprotección, y estimar cuál. Se evalúa sobre todos los compuestos, no solo sobre los que la etapa 1 marca como permeables.

Una precisión de diseño que condiciona la arquitectura: **la etapa 1 no opera como filtro duro sobre la etapa 2**. Un resultado BBB- no descarta al compuesto, porque existen estrategias consolidadas para favorecer el cruce —profármacos, lipidización, aprovechamiento de transportadores endógenos, nanoacarreadores— y por eso la información de ambas etapas se conserva por separado.




Figura 1: Arquitectura del sistema propuesto. El SMILES se convierte en un vector de longitud fija que alimenta dos modelos supervisados independientes. La etapa 1 no filtra a la etapa 2: sus salidas se combinan en la priorización final, acompañadas de la atribución a fragmentos químicos.

Sobre ambas etapas pesa un requisito que la patrocinadora planteó como no negociable: **la explicabilidad a nivel de subestructura**. No basta con predecir correctamente; el modelo debe permitir afirmar qué fragmento químico sustenta la predicción, para que el resultado sea interpretable biológicamente y accionable en el laboratorio.

2.2 Contexto

La barrera hematoencefálica es el obstáculo central del desarrollo de fármacos para el sistema nervioso central. Las moléculas pequeñas la atraviesan por difusión pasiva en cantidades farmacológicamente relevantes solo cuando su masa molecular es inferior a 400–500 Da y forman menos de 8–10 puentes de hidrógeno con el agua (Pardridge, 2005).

Es frecuente encontrar la afirmación de que el 98% de las moléculas pequeñas no atraviesan la barrera. Al rastrear su origen se observa que la cifra se presenta sin cita en la fuente donde alcanzó mayor difusión, y que su sustento cuantitativo proviene de dos estudios que miden qué fracción de los fármacos comercializados tiene indicación clínica para el sistema nervioso central —un indicador indirecto— y no de una medición sistemática de permeabilidad (Pardridge, 2005). **Este trabajo la trata como una aproximación de orden de magnitud, no como una estadística empírica.**

El problema tiene además una dimensión de salud pública: las enfermedades neurodegenerativas —Alzheimer, Parkinson, esclerosis lateral amiotrófica— carecen de tratamientos que modifiquen su curso. El **amiloide- β** es un péptido cuya acumulación en forma de placas en el tejido cerebral es la marca distintiva de la enfermedad de Alzheimer; la **hipótesis de la cascada amiloide** postula que esa acumulación es el evento que desencadena el resto de la patología (Hardy & Selkoe, 2002). Los anticuerpos anti-amiloide aprobados recientemente muestran una reducción robusta de la carga amiloide pero un beneficio clínico modesto y un riesgo no trivial de anomalías de imagen (van Dyck et al., 2023), y la hipótesis de la cascada amiloide, dominante durante dos décadas, ha sido cuestionada de forma explícita en la literatura (Herrup, 2015). La búsqueda de mecanismos y compuestos alternativos sigue abierta.

2.3 Objetivos comerciales y su traducción a objetivos del proyecto

La Tabla 1 traduce los objetivos de la organización en objetivos técnicos verificables, que es el paso que la metodología CRISP-ML(Q) sitúa en la fase de entendimiento del negocio (Visengeriyeva et al., 2023).

Tabla 1: Traducción de objetivos comerciales a objetivos del proyecto

Objetivo comercial	Objetivo del proyecto	Criterio de verificación
Reducir el tiempo dedicado a revisar literatura compuesto por compuesto	Modelo de clasificación de permeabilidad que puntúe bases completas de productos naturales	El modelo procesa las 738,829 moléculas de COCONUT sin intervención manual
Disminuir el gasto en ensayos sobre candidatos que no alcanzan el cerebro	Clasificador BBB+/BBB- con desempeño medido bajo partición estructural	Coefficiente de correlación de Matthews sobre partición por andamio ² , con intervalo de confianza reportado
Orientar la selección de compuestos con criterio mecanístico, no solo estadístico	Atribución de la predicción a fragmentos químicos concretos	Coincidencia entre dos métodos de atribución independientes, reportando solo lo concordante
Generar hipótesis publicables sobre relación estructura-actividad	Análisis de enriquecimiento de subestructuras entre compuestos activos	Fragmentos enriquecidos con significancia estadística tras corrección por comparaciones múltiples
Extender la búsqueda a compuestos no descritos previamente	Priorización de candidatos con medida explícita de confianza	Evaluación del dominio de aplicabilidad del modelo sobre los compuestos puntuados

Un objetivo explícitamente admitido como resultado válido: si el análisis muestra que no existe un patrón estructural aprendible que distinga a los compuestos permeables o activos, documentarlo con rigor constituye un resultado del proyecto. La patrocinadora lo planteó así desde la primera reunión, y el historial de fracasos de traducción del campo (O'Collins et al., 2006) hace que reportar la ausencia de señal sea más valioso que ajustar el modelo hasta obtener una cifra favorable.

2.4 Preguntas clave

1. ¿Qué características estructurales determinan que un compuesto atraviese la barrera hematoencefálica, y coinciden con las reglas fisicoquímicas establecidas en química medicinal?
2. ¿Qué desempeño alcanza un modelo evaluado sobre compuestos estructuralmente distintos a los de entrenamiento, que es el escenario real de aplicación?
3. ¿Es posible identificar conjuntos de compuestos que compartan un fragmento químico y presenten el mismo comportamiento, de forma estadísticamente sustentada?
4. ¿Qué tan lejos del dominio de entrenamiento se encuentran los productos naturales que se pretende puntuar, y cómo se degrada la confianza del modelo en esa región?
5. ¿Qué compuestos de las bases de productos naturales presentan el perfil más favorable, y con qué nivel de confianza puede afirmarse?

²Andamio (*scaffold*) de Bemis-Murcko: el esqueleto de anillos y los enlaces que los conectan, sin los grupos sustituyentes que cuelgan de él. Dos compuestos comparten andamio si tienen el mismo esqueleto de anillos (Bemis & Murcko, 1996).

2.5 Involucrados

Tabla 2: Participantes en el proyecto y su nivel de involucramiento

Participante	Rol	Etapas	Nivel de involucramiento
Dra. Mariana Martínez Ávila	Patrocinadora y profesora	Todas	Como patrocinadora: define el problema y los criterios de éxito; provee los conjuntos de datos curados; valida la interpretación biológica. Como profesora: evalúa los entregables conforme a las rúbricas del curso
Depto. de Bioingeniería	Organización receptora	Inicio/cierre	Aporta el contexto de la línea de investigación y recibe los resultados
Ingrid Pamela Ruiz Puga	Integrante	Todas	Desarrollo del proyecto
Artemio S. Padilla Robles	Integrante	Todas	Desarrollo del proyecto
José A. Vázquez Martínez	Integrante	Todas	Desarrollo del proyecto

La asignación de responsabilidades específicas por integrante se definirá al inicio de la fase de modelado, cuando el alcance técnico esté cerrado.

2.6 Alcance, supuestos y riesgos

Dentro del alcance. Un clasificador de permeabilidad de la barrera hematoencefálica (etapa 1); un modelo de actividad sobre las 39 dianas curadas por la patrocinadora (etapa 2); la atribución de las predicciones a fragmentos químicos; y la priorización de candidatos de las bases de productos naturales, con una medida explícita de confianza.

Fuera del alcance. El proyecto no genera moléculas nuevas y no incluye ensayos de laboratorio: la evaluación experimental de los candidatos es el paso posterior que realiza el equipo de investigación (ver el proceso descrito en los Antecedentes). Tampoco filtra compuestos con la etapa 1, por lo señalado en la formulación del problema.

Supuestos.

1. La estructura molecular contiene información suficiente para predecir la permeabilidad y la actividad. Es la hipótesis de trabajo y se contrasta con los datos, no se da por cierta; si no se sostiene, se reporta como resultado.
2. Los conjuntos entregados por la patrocinadora son la fuente de datos del proyecto.
3. Las etiquetas describen una clase bajo las condiciones de ensayo y el umbral declarado, no una propiedad intrínseca del compuesto (ver la auditoría de calidad).

La Tabla 3 reúne los riesgos que ya se identificaron y la forma en que se atiende cada uno.

Tabla 3: Riesgos identificados y su tratamiento

Riesgo	Por qué importa	Cómo se atiende
Fuga de información entre entrenamiento y prueba	Estereoisómeros ³ y andamios repetidos inflan el desempeño medido	Partición por andamio de Bemis-Murcko y verificación de que ningún esqueleto de conectividad ⁴ cruce entre particiones
Ruido en las etiquetas	Las etiquetas provienen de ensayos heterogéneos y dependen de la concentración	Etiquetado en dos niveles (pChEMBL ≥ 5 y ≥ 6) y uso de la columna de grupo de B3DB como variable de estratificación
Productos naturales fuera del dominio de entrenamiento	El modelo podría extrapolar sin aviso sobre el tipo de compuesto que se busca priorizar	Evaluación explícita del dominio de aplicabilidad al puntuar
Falsos positivos por interferencia en ensayos	Compuestos como la curcumina aparecen como activos sin serlo	Filtros de subestructura antes de reportar cualquier candidato
Cobertura desigual entre dianas	Algunas de las 39 dianas tienen muy pocos registros para entrenar un modelo	Se definirá en la preparación de datos qué dianas cuentan con registros suficientes para modelarse
Ausencia de patrón aprendible	Puede que la estructura no explique el comportamiento	Se reporta como resultado del proyecto, sin ajustar el modelo hasta obtener una cifra favorable

3 Entendimiento de los datos

3.1 Origen y contexto

La patrocinadora entregó el 25 de septiembre de 2026 dos conjuntos de datos curados, acompañados de sus respectivos diccionarios de columnas. Ambos se construyeron a partir de bases públicas de acceso abierto y fueron estandarizados, documentados y anotados para este proyecto.

Los datos **no contienen información confidencial ni propiedad de terceros**: provienen de repositorios científicos de acceso abierto. Por esa razón no se requiere convenio de privacidad y esta propuesta no incluye anexos.

3.1.a Conjunto 1 — Permeabilidad de la barrera hematoencefálica

Deriva de **B3DB** (Blood-Brain Barrier Database), compilación de medidas publicadas de permeabilidad procedentes de 50 fuentes independientes (Meng et al., 2021). Los datos se distribuyen bajo licencia CC0. A la versión original se le añadió el cruce estructural con **COCONUT**, el catálogo abierto de productos naturales (Chandrasekhar et al., 2025), lo que permite distinguir compuestos de origen natural de los sintéticos sin trabajo adicional de integración.

³Molécula con la misma fórmula y conectividad de átomos que otra, pero con distinta disposición espacial (por ejemplo, distinta quiralidad); dos estereoisómeros del mismo compuesto pueden tener actividad biológica distinta.

⁴La estructura de una molécula sin su información de estereoquímica, calculada a partir de los primeros 14 caracteres de su InChIKey. Varios estereoisómeros de un mismo compuesto comparten el mismo esqueleto de conectividad.

Tabla 4: Composición del conjunto de permeabilidad

Característica	Valor
Filas	7,811 (un compuesto por fila)
Con etiqueta de clase BBB+/BBB-	7,805
Con valor numérico de logBB	1,058
Compuestos BBB+ (permeables)	4,956 (63.5%)
Compuestos BBB- (no permeables)	2,849 (36.5%)
Esqueletos de conectividad distintos	4,019
Productos naturales con estructura idéntica en COCONUT	3,366
Con análogo natural que difiere en estereoquímica	1,005
Sin equivalente natural conocido	3,440

La variable **logBB** es el logaritmo de la razón entre la concentración del compuesto en cerebro y en plasma. La etiqueta categórica se deriva de ese valor mediante el umbral convencional $\logBB \geq -1$.

3.1.b Conjunto 2 — Actividad en sistema nervioso central

Integra registros de actividad experimental de tres fuentes: **ChEMBL**, base de bioactividad de moléculas tipo fármaco (Zdrazil et al., 2024); **NPASS**, de actividad de productos naturales (Lin et al., 2026); y **CMAUP**, de plantas medicinales y sus ingredientes (Hou et al., 2024).

Tabla 5: Composición del conjunto de actividad en SNC

Característica	Valor
Registros de actividad	202,647
Compuestos únicos (InChIKey calculado desde la estructura)	105,583
Provenientes de ChEMBL	103,877
Provenientes de NPASS y CMAUP (productos naturales)	4,472
Compuestos en ambos grupos	2,766
Dianas moleculares anotadas	39
Registros con valor de potencia (pChEMBL)	129,243
Registros de inactividad declarada	29,730

Las 39 dianas fueron curadas manualmente a partir de la farmacología conocida, con anotación de enfermedad asociada, mecanismo biológico y efecto terapéutico buscado. Se agrupan en cuatro categorías: sistema nervioso central clásico (20 dianas, entre ellas acetilcolinesterasa, monoamino oxidasa B y β -secretasa 1), neuroinflamación (10, incluyendo COX-2 e inflammasoma NLRP3), Parkinson/ELA/Huntington (7) y receptores completos (2).

La disponibilidad de **29,730 registros de inactividad declarada**, más 54,419 mediciones censuradas que constituyen negativos válidos bajo el umbral de 10 μ M, resuelve un problema habitual en estos datos:

las bases de bioactividad tienden a publicar resultados positivos, y sin negativos confiables no puede entrenarse un clasificador.




Figura 2: Composición de los conjuntos de datos. A la izquierda, la distribución de clases del conjunto de permeabilidad. Al centro, la diferencia entre el número de filas y el número de entidades químicas independientes. A la derecha, el origen de los compuestos del conjunto de actividad, donde los productos naturales representan una fracción minoritaria pero son el objetivo final de la priorización.

3.2 Auditoría preliminar de calidad

Se realizó una verificación independiente de ambos conjuntos, cuyos hallazgos condicionan el diseño metodológico. Se reportan aquí porque afectan la interpretación de cualquier resultado posterior.

El tamaño efectivo de muestra es menor que el número de filas. En el conjunto de permeabilidad, las 7,805 filas etiquetadas corresponden a 4,018 esqueletos de conectividad distintos; el archivo completo tiene 4,019 `key14` distintos al incluir las seis filas sin clase. Numerosos compuestos aparecen varias veces como estereoisómeros. La morfina, por ejemplo, figura ocho veces. **Al reportar el tamaño del conjunto deben darse ambas cifras**, porque el número de filas sobreestima la información independiente por un factor cercano a dos.

Hay registros con estructuras químicamente inválidas. Dos compuestos del archivo original de B3DB contienen un carbono con carga imposible y son rechazados por RDKit. El diccionario entregado por la patrocinadora documenta el mismo problema de forma independiente, lo que confirma el hallazgo.

Los nombres de compuesto no son identificadores confiables. Se detectaron filas cuyo nombre no corresponde a la estructura registrada. **Toda deduplicación y todo cruce entre fuentes debe hacerse por InChIKey recalculado a partir de la estructura**, nunca por nombre ni por cadena SMILES, dado que la notación SMILES no es única entre herramientas.

Las etiquetas dependen de la concentración del ensayo. Un compuesto puede clasificarse como inactivo a una concentración y activo a otra mayor. El fenómeno está documentado: a concentración baja domina el flujo activo y el compuesto se comporta como no permeable, mientras que a concentración alta el flujo se satura (Spielsvogel et al., 2025). En consecuencia, **la etiqueta BBB+/BBB- no se interpretará como una propiedad intrínseca del compuesto**, sino como una clase bajo las condiciones de ensayo y la convención de umbral de la literatura fuente.

Las columnas de agrupamiento de B3DB no constituyen una escala de calidad. El diccionario de la patrocinadora señala que B3DB no publica el criterio con que asigna sus grupos A–D, y la verificación sobre los datos lo confirma: el grupo D tiene más respaldo bibliográfico que el C. Además, el grupo está

correlacionado con la etiqueta, por lo que filtrar por él sesga la distribución de clases. Se usará como variable de estratificación y no como criterio de exclusión.

El conjunto de actividad tiene cobertura desigual y valores sin homogeneizar. Tres hallazgos sobre el archivo entregado condicionan la preparación de datos:

- **No todas las filas pertenecen a una de las dianas del proyecto.** Una parte considerable de los registros corresponde a ensayos neuronales sobre otras dianas o sobre dianas no identificadas. Además, entre las dianas curadas la cobertura es muy desigual: algunas tienen miles de registros y otras casi ninguno.
- **El valor de pChEMBL existe únicamente para los registros de ChEMBL.** Las filas de NPASS y CMAUP, que son las de los productos naturales, no lo traen, de modo que habrá que derivarlo del valor y la unidad originales para que ambos grupos usen la misma escala.
- **Las unidades no están convertidas.** Coexisten varias formas de expresar la unidad (nM, uM, ug .mL⁻¹, entre otras), y las expresadas por masa no pueden pasarse a concentración molar sin el peso molecular del compuesto.

3.3 Técnica de aprendizaje automático

El problema corresponde a **aprendizaje supervisado de clasificación binaria**, en dos modelos independientes. La justificación de esa elección se apoya en tres consideraciones.

Por qué supervisado y no no supervisado. Ambos conjuntos traen etiquetas experimentales: la clase de permeabilidad en el primero y los valores de actividad medidos en el segundo. El objetivo es predecir esas etiquetas para compuestos nuevos, no descubrir estructura latente.

Por qué clasificación y no regresión. Solo 1,058 de los 7,805 compuestos tienen valor numérico de logBB, mientras que los 7,805 tienen clase. La pregunta de la organización —si un compuesto llega al cerebro— es además categórica. Se contempla un modelo de regresión sobre el subconjunto con logBB como análisis complementario.

Por qué modelos de ensamble y no aprendizaje profundo. Un estudio comparativo evaluó 25 modelos preentrenados de representación molecular frente a *fingerprints* estructurales clásicos, sobre 25 conjuntos de datos y con partición estructural, y concluyó que casi todos los modelos neuronales muestran una mejora insignificante o nula respecto al *fingerprint* base (Praski et al., 2026). A eso se suma el requisito de explicabilidad: los modelos de ensamble sobre descriptores interpretables permiten atribuir la predicción a fragmentos químicos concretos, mientras que los *embeddings* densos no (Rudin, 2019).

3.4 Variables de entrada y salida

La entrada disponible es una cadena de texto —el SMILES— de **longitud variable**: en el conjunto de permeabilidad va de 1 a 383 caracteres, con mediana de 49. Los modelos de ensamble requieren que todas las observaciones tengan el mismo número de variables, por lo que la estructura debe convertirse en un vector de longitud fija.

Tabla 6: Variables de entrada del modelo

Bloque	Variables	Descripción
Descriptores físicoquímicos	217	Propiedades calculadas con RDKit: área de superficie polar topológica, coeficiente de partición, peso molecular, donadores y aceptores de puente de hidrógeno, entre otras
<i>Fingerprint</i> estructural Morgan/ECFP4	2,048	Vector binario donde cada posición indica la presencia de un fragmento químico, trazable a la subestructura que lo activó (Rogers & Hahn, 2010)
Metadatos de procedencia	Variable	Origen del registro y tipo de ensayo, para estratificar y auditar

Tabla 7: Variables de salida del modelo

Etapas	Variable de salida	Tipo	Valores
1	<code>bbb_class</code>	Binaria	BBB+ / BBB−
1 (complementaria)	<code>logBB</code>	Continua	−2.69 a 1.70
2	Actividad por diana	Binaria	Activo / inactivo, con umbral declarado sobre la escala pChEMBL

Para la etapa 2 se adoptará un **etiquetado en dos niveles**: $\text{pChEMBL} \geq 5$ (equivalente a 10 μM) como umbral primario, siguiendo la convención de ExCAPE-DB (Sun et al., 2017), y $\text{pChEMBL} \geq 6$ (1 μM) como comprobación de robustez. Hacer explícita la dependencia del umbral responde directamente a la advertencia sobre la concentración de ensayo.

3.5 Consideraciones metodológicas de validación

Tres decisiones tomadas antes de modelar, derivadas de la revisión de literatura.

Partición por andamio molecular, nunca aleatoria. Los andamios frecuentes del conjunto presentan pureza de clase extrema —uno de ellos agrupa 410 compuestos de los cuales el 99.5% son BBB+—, de modo que una partición aleatoria permitiría al modelo reconocer el andamio en lugar de aprender la relación estructura-propiedad. La partición por andamio de Bemis-Murcko (Bemis & Murcko, 1996) separa estructuras distintas entre entrenamiento y evaluación, y es la práctica establecida para este tipo de datos (Wu et al., 2018). Una auditoría reciente de 51 configuraciones de conjuntos de referencia mostró que al endurecer las particiones el modelo mejor clasificado perdió su posición en 15 de 28 casos (Schuh et al., 2026).

Métricas apropiadas al desbalance. El conjunto presenta una razón cercana a 1.74 compuestos permeables por cada no permeable. La exactitud resulta engañosa bajo desbalance, por lo que se emplearán el coeficiente de correlación de Matthews (Chicco & Jurman, 2020) y el área bajo la curva de precisión-exhaustividad calculada sobre la clase minoritaria (Saito & Rehmsmeier, 2015).

No se adoptarán cifras de desempeño de la literatura como referencia. Los valores publicados para un mismo conjunto de referencia varían entre 0.681 y 0.7194 según la fuente, por diferencias en la implementación de la partición. El proyecto construirá su propia línea base (Golbraikh & Tropsha, 2002).

Adicionalmente, la interpretación de resultados considerará que compuestos ampliamente estudiados como la curcumina se comportan como falsos positivos recurrentes en ensayos bioquímicos: acumulan más de 120 ensayos clínicos sin un solo resultado positivo controlado con placebo (Nelson et al., 2017), y son detectables mediante filtros de subestructura (Baell & Holloway, 2010). Ese filtrado se aplicará antes de reportar cualquier candidato.

3.6 Alineación con la metodología

La propuesta sigue la estructura de CRISP-ML(Q) (Visengeriyeva et al., 2023). Las fases de entendimiento del negocio y de los datos corresponden a este Avance 0; la preparación de datos, el modelado y la evaluación se desarrollarán en los avances subsecuentes. El marco de la OCDE para la validación de modelos QSAR (OECD, 2007) aporta cinco principios complementarios —criterio definido, algoritmo inequívoco, dominio de aplicabilidad declarado, medidas de ajuste y capacidad predictiva, e interpretación mecanística— que se usarán como lista de verificación del entregable final.

CRISP-ML(Q) organiza el proyecto en seis fases y añade a cada una un paso de aseguramiento de calidad (Visengeriyeva et al., 2023). La Tabla 8 sitúa cada fase en el calendario de entregas del curso. Las fechas de los avances son las del programa; los hitos internos son una propuesta del equipo para llegar a cada entrega con la libreta ejecutada de principio a fin, y pueden ajustarse.

Tabla 8: Fases de CRISP-ML(Q) en el calendario del proyecto

Fase de CRISP-ML(Q)	Actividades en este proyecto	Entrega y fecha	Hitos internos propuestos
1. Entendimiento del negocio y de los datos	Formulación del problema, objetivos, involucrados, descripción de los datos y auditoría preliminar de calidad	Avance 0, 27 sep	Reunión con los asesores (22 sep) y recepción de los datos de la patrocinadora (25 sep), ambas realizadas
2. Ingeniería de datos (a)	Análisis exploratorio de los dos conjuntos; manejo de valores faltantes, atípicos y alta cardinalidad; conclusiones del EDA	Avance 1, 4 oct	1 oct: EDA de permeabilidad. 3 oct: EDA de actividad y ejecución completa de la libreta
2. Ingeniería de datos (b)	Descriptores y <i>fingerprints</i> a partir del SMILES; escalamiento y transformaciones; selección y extracción de características; partición por andamio con verificación de fuga; conclusiones de la preparación de datos	Avance 2, 11 oct	8 oct: partición verificada. 10 oct: matriz de características final
3. Ingeniería del modelo (a)	Modelo de referencia (<i>baseline</i>); métrica alineada al desbalance; análisis de sub/sobreajuste; desempeño mínimo aceptable	Avance 3, 18 oct	15 oct: <i>baseline</i> de la etapa 1. 17 oct: <i>baseline</i> de la etapa 2
3. Ingeniería del modelo (b)	Al menos seis modelos individuales de algoritmos distintos; comparación con al menos dos métricas y tiempos de entrenamiento; ajuste fino de los dos mejores; elección del modelo individual	Avance 4, 25 oct	22 oct: tabla comparativa de los seis modelos. 24 oct: ajuste fino terminado
3. Ingeniería del modelo (c)	Ensamblados homogéneos y heterogéneos con los mejores modelos individuales; optimización de hiperparámetros; comparativa final	Avance 5, 1 nov	29 oct: ensambles entrenados
4. Aseguramiento de calidad del modelo	Evaluación sobre datos no vistos con partición por andamio; gráficos de desempeño con su interpretación; atribución a fragmentos con dos métodos independientes; dominio de aplicabilidad; lista de verificación de la OCDE	Avance 5, 1 nov	30 oct: gráficos de desempeño. 31 oct: verificación contra la lista de la OCDE

Las fases 5 (despliegue) y 6 (monitoreo y mantenimiento) quedan fuera del calendario de entregas del curso.

Bibliografía

- Baell, J. B., & Holloway, G. A. (2010). New substructure filters for removal of pan assay interference compounds (PAINS) from screening libraries and for their exclusion in bioassays. *Journal of Medicinal Chemistry*, 53(7), 2719-2740. <https://doi.org/10.1021/jm901137j>
- Bemis, G. W., & Murcko, M. A. (1996). The Properties of Known Drugs. 1. Molecular Frameworks. *Journal of Medicinal Chemistry*, 39(15), 2887-2893. <https://doi.org/10.1021/jm9602928>
- Chandrasekhar, V., Rajan, K., Kanakam, S. R. S., Sharma, N., Weißenborn, V., Schaub, J., & Steinbeck, C. (2025). COCONUT 2.0: a comprehensive overhaul and curation of the collection of open natural products database. *Nucleic Acids Research*, 53(D1), D634-D643. <https://doi.org/10.1093/nar/gkae1063>
- Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21, 6. <https://doi.org/10.1186/s12864-019-6413-7>
- Daneman, R., & Prat, A. (2015). The Blood-Brain Barrier. *Cold Spring Harbor Perspectives in Biology*, 7(1), a020412. <https://doi.org/10.1101/cshperspect.a020412>
- Golbraikh, A., & Tropsha, A. (2002). Beware of q²!. *Journal of Molecular Graphics and Modelling*, 20(4), 269-276. [https://doi.org/10.1016/S1093-3263\(01\)00123-1](https://doi.org/10.1016/S1093-3263(01)00123-1)
- Hardy, J., & Selkoe, D. J. (2002). The Amyloid Hypothesis of Alzheimer's Disease: Progress and Problems on the Road to Therapeutics. *Science*, 297(5580), 353-356. <https://doi.org/10.1126/science.1072994>
- Heinrich, M., & Teoh, H. L. (2004). Galanthamine from snowdrop—the development of a modern drug against Alzheimer's disease from local Caucasian knowledge. *Journal of Ethnopharmacology*, 92(2–3), 147-162. <https://doi.org/10.1016/j.jep.2004.02.012>
- Herrup, K. (2015). The case for rejecting the amyloid cascade hypothesis. *Nature Neuroscience*, 18(6), 794-799. <https://doi.org/10.1038/nn.4017>
- Hou, D., Lin, H., Feng, Y., Zhou, K., Li, X., Yang, Y., Wang, S., Yang, X., Wang, J., Zhao, H., Zhang, X., Fan, J., Lu, S., Wang, D., Zhu, L., Ju, D., Chen, Y. Z., & Zeng, X. (2024). CMAUP database update 2024: extended functional and association information of useful plants for biomedical research. *Nucleic Acids Research*, 52(D1), D1508-D1518. <https://doi.org/10.1093/nar/gkad921>
- Lin, H., Hou, D., Jiang, X., Yin, R., Yu, S., Lu, S., Wang, S., Ju, D., Zhao, H., Chen, Y., & Zeng, X. (2026). NPASS database update 2026: comprehensive quantitative composition, bioactivity, and ADME-Tox data of natural products for biomedical research. *Nucleic Acids Research*, 54(D1), D1519-D1527. <https://doi.org/10.1093/nar/gkaf1196>
- Löscher, W., & Potschka, H. (2005). Blood-brain barrier active efflux transporters: ATP-binding cassette gene family. *NeuroRx*, 2(1), 86-98. <https://doi.org/10.1602/neurorx.2.1.86>
- Meng, F., Xi, Y., Huang, J., & Ayers, P. W. (2021). A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors. *Scientific Data*, 8(1), 289. <https://doi.org/10.1038/s41597-021-01069-5>

- Nelson, K. M., Dahlin, J. L., Bisson, J., Graham, J., Pauli, G. F., & Walters, M. A. (2017). The Essential Medicinal Chemistry of Curcumin. *Journal of Medicinal Chemistry*, 60(5), 1620-1637. <https://doi.org/10.1021/acs.jmedchem.6b00975>
- O'Collins, V. E., Macleod, M. R., Donnan, G. A., Horky, L. L., van der Worp, B. H., & Howells, D. W. (2006). 1,026 experimental treatments in acute stroke. *Annals of Neurology*, 59(3), 467-477. <https://doi.org/10.1002/ana.20741>
- OECD. (2007). *Guidance Document on the Validation of (Quantitative) Structure-Activity Relationship [(Q)SAR] Models* (technical report ENV/JM/MONO(2007)2, OECD Series on Testing and Assessment No. 69).
- Pardridge, W. M. (2005). The Blood-Brain Barrier: Bottleneck in Brain Drug Development. *NeuroRx*, 2(1), 3-14. <https://doi.org/10.1602/neurorx.2.1.3>
- Praski, M., Adamczyk, J., & Czech, W. (2026). Benchmarking Pretrained Molecular Embedding Models For Molecular Representation Learning. *arXiv preprint arXiv:2508.06199*.
- Rogers, D., & Hahn, M. (2010). Extended-Connectivity Fingerprints. *Journal of Chemical Information and Modeling*, 50(5), 742-754. <https://doi.org/10.1021/ci100050t>
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206-215. <https://doi.org/10.1038/s42256-019-0048-x>
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLoS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Schuh, M. G., Daniluk, A., & Sieber, S. A. (2026). Auditing widely used biomolecular benchmarks reveals systematic data inconsistencies. *Chemical Science*. <https://doi.org/10.1039/d6sc01799a>
- Spielvogel, C. P., Schindler, N., Schröder, C., Stellnberger, S. L., Wadsak, W., Mitterhauser, M., Papp, L., Hacker, M., Pichler, V., & Vracka, C. (2025). Enhancing Blood-Brain Barrier Penetration Prediction by Machine Learning-Based Integration of Novel and Existing, In Silico and Experimental Molecular Parameters from a Standardized Database. *Journal of Chemical Information and Modeling*, 65(6), 2773-2784. <https://doi.org/10.1021/acs.jcim.4c02212>
- Sun, J., Jeliaskova, N., Chupakhin, V., Golib-Dzib, J. F., Engkvist, O., Carlsson, L., Wegner, J. K., Ceulemans, H., Georgiev, I., Jeliaskov, V., Kochev, N., Ashby, T. J., & Chen, H. (2017). ExCAPE-DB: an integrated large scale dataset facilitating Big Data analysis in chemogenomics. *Journal of Cheminformatics*, 9, 17. <https://doi.org/10.1186/s13321-017-0203-5>
- van Dyck, C. H., Swanson, C. J., Aisen, P., Bateman, R. J., Chen, C., Gee, M., Kanekiyo, M., Li, D., Reyderman, L., Cohen, S., Froelich, L., Katayama, S., Sabbagh, M., Vellas, B., Watson, D., Dhadda, S., Irizarry, M., Kramer, L. D., & Iwatsubo, T. (2023). Lecanemab in Early Alzheimer's Disease. *New England Journal of Medicine*, 388(1), 9-21. <https://doi.org/10.1056/NEJMoa2212948>
- Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., & Plöd, M. (2023). *CRISP-ML(Q). The ML Lifecycle Process*. INNOQ. <https://ml-ops.org/content/crisp-ml>

- Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., Leswing, K., & Pande, V. (2018). MoleculeNet: A Benchmark for Molecular Machine Learning. *Chemical Science*, 9(2), 513-530. <https://doi.org/10.1039/C7SC02664A>
- Zdrazil, B., Felix, E., Hunter, F., Manners, E. J., Blackshaw, J., Corbett, S., de Veij, M., Ioannidis, H., Lopez, D. M., Mosquera, J. F., Magarinos, M. P., Bosc, N., Arcila, R., Kizilören, T., Gaulton, A., Bento, A. P., Adasme, M. F., Monecke, P., Landrum, G. A., & Leach, A. R. (2024). The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Research*, 52(D1), D1180-D1192. <https://doi.org/10.1093/nar/gkad1004>