

Tecnológico de Monterrey

Escuela de Ingeniería y Ciencias

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador · TC5035.10

Avance 1. Análisis exploratorio de datos

Bioactive AI

Predicción y priorización de compuestos bioactivos con potencial
neuroprotector a partir de su estructura molecular

Profesora

Dra. Mariana Martínez Ávila

Equipo 7

Ingrid Pamela Ruiz Puga	A01021209
Artemio Santiago Padilla Robles	A01796613
José Antonio Vázquez Martínez	A01797208

4 de octubre de 2026

Índice

1 Alcance de este reporte	3
2 Estructura de los datos	3
2.1 Variable objetivo y variables de agrupamiento	3
2.2 Valores faltantes por columna	4
2.3 El tamaño efectivo es menor que el número de filas	5
3 Análisis univariante	5
4 Análisis bi/multivariante	6
4.1 Poder discriminante individual contra la etiqueta	6
4.2 Correlación entre descriptores	7
4.3 Productos naturales contra sintéticos	8
5 Preprocesamiento	9
5.1 Estructuras inválidas	9
5.2 Deduplicación	9
5.3 Valores atípicos: ¿ruido o diversidad real?	9
5.4 Alta cardinalidad	11
6 Conclusiones	11
7 Próximos pasos: Avance 2	11
Bibliografía	12

1 Alcance de este reporte

El entregable formal de este avance, según las especificaciones de la actividad, es la liga al notebook ejecutado de principio a fin: [notebooks/01_EDA.ipynb](#). Este documento es un acompañante en el mismo formato de reporte que el Avance 0: recoge los hallazgos del notebook organizados según los criterios de la rúbrica, con las cifras tomadas directamente de su ejecución, no recalculadas aparte.

La fuente primaria es el conjunto curado por la patrocinadora, [bbb_permeability_experimental.csv](#), entregado el 25 de septiembre junto con su diccionario de columnas. Deriva de B3DB (Meng et al., 2021) pero viene procesado: SMILES estandarizados con RDKit, esqueleto de conectividad precalculado y, sobre todo, **cruzado estructuralmente con COCONUT** (Chandrasekhar et al., 2025), el catálogo abierto de productos naturales.

Los archivos de B3DB que el equipo descargó por su cuenta se conservan como **verificación complementaria**: permiten contrastar conteos y confirmar de forma independiente los problemas de calidad, pero no son la base del análisis.

Esa elección no es solo de procedencia. El cruce con COCONUT habilita la pregunta central del proyecto —si los productos naturales, que son los compuestos a priorizar, se comportan distinto frente a la barrera— y es la que produce el hallazgo de la sección correspondiente.

El EDA del conjunto de actividad en SNC (etapa 2) queda pendiente para un avance posterior.

2 Estructura de los datos

El archivo de la patrocinadora tiene **7,811 filas y 16 columnas**, un compuesto por fila, uniendo por estructura los archivos de clasificación y regresión que B3DB publica por separado. De ellas, **7,805 tienen clase asignada** y constituyen el conjunto de trabajo; las 6 restantes traen [logbb](#) numérico pero su fila de clasificación registró otra forma estereoquímica y no empató al unir.

De esas 16 columnas, la mayoría son de texto (identificadores, estructura, clase, referencias y los tres campos del cruce con COCONUT), dos son numéricas continuas ([logbb](#) y [b3db_threshold](#)) y una es un conteo ([coconut_matches_key14](#)). Ninguna es propiamente numérica-continua de entrada al modelo todavía: los descriptores fisicoquímicos —*TPSA* (área de superficie polar topológica, en Å²), *logP* (coeficiente de partición octanol-agua, mide lipofiliidad), *MW* (peso molecular), entre otros— se calculan a partir del SMILES¹ en la sección de Análisis univariante, no vienen en el archivo original.

2.1 Variable objetivo y variables de agrupamiento

Tabla 1: Frecuencia de las variables categóricas principales

Variable	Valores	Frecuencia
BBB+/BBB- (clase)	BBB+ / BBB-	4,956 (63.5%) / 2,849 (36.5%) — razón 1.74:1
group (confiabilidad)	A / B / C / D	1,058 / 3,621 / 3,075 / 51

B3DB agrupa sus registros en cuatro categorías pero **no publica el criterio con que las asigna**; el diccionario de la patrocinadora lo señala y advierte que filtrar “solo A” no tiene respaldo documentado. Lo verificable es el patrón dentro de estos datos:

¹Representación textual de una molécula como cadena de caracteres, sin necesidad de dibujarla; por ejemplo, [CCO](#) representa el etanol —dos carbonos encadenados y un oxígeno—.

Grupo	Significado
A	Tiene logBB numérico medido
B	Las fuentes declararon el umbral -1 y coincidieron
C	No hay valor ni umbral; casi todas con una sola referencia
D	No hay valor ni umbral, pero con 3 o más referencias




Figura 1: Distribución de clases, de grupos de confiabilidad, y balance de clases dentro de cada grupo.

2.2 Valores faltantes por columna

De las 16 columnas, 8 tienen huecos:

Tabla 2: Valores faltantes por columna, conjunto de trabajo (n=7,805)

Columna	Faltantes	%
logbb	6,753	86.5
b3db_uncertainty_regression	6,753	86.5
b3db_reference_regression	6,753	86.5
source_id_regression	6,753	86.5
coconut_id_exact_match	4,439	56.9
b3db_threshold	4,184	53.6
coconut_ids_key14_match	3,436	44.0
compound_name	1,109	14.2

Los huecos no son errores: son estructurales. Las cuatro columnas que faltan en el 86.5% son las del lado de **regresión**, y faltan exactamente en los compuestos que no traen logBB medido —solo 1,058 lo traen—. `b3db_threshold` falta en los grupos A, C y D, que no declaran un umbral numérico. Los dos campos de COCONUT faltan en los compuestos sin equivalente natural conocido, lo cual es información en sí misma y se explota más adelante. `compound_name` es el único hueco de metadato puro, y no se usa para modelar.

Las columnas que sí importan para el modelo —`smiles_std`, `bbb_class`, `inchikey`, `key14` y `b3db_uncertainty_classification`— **no tienen ningún faltante**.

2.3 El tamaño efectivo es menor que el número de filas

Al recalcular el InChIKey² desde el SMILES con RDKit quedan **3 pares duplicados por InChIKey completo** —ampicilina con sultamicilina (un profármaco cuya estructura estandarizada colapsa en la del fármaco), más colestipol y probenecid repetidos—, los tres con la misma etiqueta en ambas filas, así que no introducen conflicto.

El problema real está un nivel más abajo: **3,787 duplicados por esqueleto de conectividad** (los primeros 14 caracteres del InChIKey, que ignoran estereoquímica). El conjunto tiene **4,018 esqueletos únicos en 7,805 filas**: una molécula como el ácido fusídico aparece nueve veces, como estereoisómeros³ o con nombres distintos. **131 esqueletos (429 compuestos, 5.5%) tienen etiquetas BBB+/BBB- contradictorias entre sus propios estereoisómeros.**

Consecuencia directa: reportar “7,805 compuestos” sin más sobreestima la información independiente por un factor cercano a dos, y un split aleatorio pondría estereoisómeros del mismo compuesto en entrenamiento y en prueba.

3 Análisis univariante

Se calcularon 9 descriptores fisicoquímicos por compuesto con RDKit: **TPSA**, **logP** y **MW** (glosados arriba), **HBD** (donadores de puente de hidrógeno), **HBA** (aceptores de puente de hidrógeno), **RotB** (enlaces rotables), **Arom** (anillos aromáticos), **Fsp3** (fracción de carbonos con hibridación sp³) y **HeavyAtoms** (átomos distintos de hidrógeno).

Tabla 3: Estadísticas descriptivas de los 9 descriptores, por clase

Descriptor	Media BBB+	Media BBB-	Mediana BBB+	Mediana BBB-	DE BBB+	DE BBB-
TPSA	60.02	133.74	53.85	114.99	37.50	81.44
logP	2.87	1.45	2.92	1.46	1.58	2.75
MW	339.85	464.22	330.48	424.53	121.13	210.08
HBD	1.23	3.37	1.00	3.00	1.09	3.01
HBA	3.97	7.59	4.00	6.00	2.21	4.46
RotB	3.92	6.25	4.00	6.00	2.82	4.35
Arom	1.27	1.40	1.00	1.00	1.03	1.16
Fsp3	0.50	0.50	0.50	0.46	0.22	0.24
HeavyAtoms	23.91	32.07	23.00	29.00	8.54	14.96

²Identificador químico estándar derivado de la estructura molecular; a diferencia del SMILES, la misma molécula siempre produce el mismo InChIKey sin importar qué herramienta lo calcule.

³Molécula con la misma fórmula y conectividad de átomos que otra, pero con distinta disposición espacial (por ejemplo, distinta quiralidad); dos estereoisómeros del mismo compuesto pueden tener actividad biológica distinta.




Figura 2: Distribución de TPSA, logP, MW, HBD, HBA y Fsp3, separada por clase. Las líneas verticales en TPSA marcan los umbrales de 66.8 y 90 Å² reportados en la literatura.

Las distribuciones de TPSA, HBD y HBA se separan visiblemente entre BBB+ y BBB-; Fsp3 y Arom casi no lo hacen, lo cual se confirma cuantitativamente en la sección siguiente.

4 Análisis bi/multivariante

4.1 Poder discriminante individual contra la etiqueta

El AUC (área bajo la curva ROC) mide qué tan bien un solo descriptor separa las dos clases por sí mismo, sin necesidad de un modelo: 0.5 equivale a adivinar al azar y 1.0 a una separación perfecta.

Tabla 4: Área bajo la curva ROC de cada descriptor contra la clase BBB+/BBB-, calculada sobre los datos, contra la cifra publicada sobre el subconjunto con logBB (Tiwari et al., 2026)

Descriptor	AUC (A+B, n=4,679)	AUC (completo, n=7,805)	AUC publicado (n=1,058)
TPSA	0.850	0.813	0.746
HBD	0.811	0.777	0.699
HBA	0.803	0.763	0.673
MW	0.729	0.703	0.583
logP	0.728	0.681	0.617
HeavyAtoms	0.709	0.683	—
RotB	0.683	0.695	—
Arom	0.501	0.525	—
Fsp3	0.501	0.516	—

4.2 Correlación entre descriptores

El orden de la tabla anterior no implica que TPSA, HBD, HBA, MW y HeavyAtoms aporten cinco señales independientes. La Figura 3 muestra la correlación de Spearman entre los 9 descriptores —se usa Spearman, no Pearson, porque varios son conteos enteros de distribución sesgada—.




Figura 3: Correlación de Spearman entre los 9 descriptores fisicoquímicos.

Dos pares destacan:

- **MW y HeavyAtoms: $\rho = 0.98$.** Son casi la misma variable medida dos veces, lo que explica que tengan un poder discriminante casi idéntico en la Tabla 4: no son dos señales independientes, sino una sola vista desde dos ángulos.
- **TPSA con HBA ($\rho = 0.89$) y con HBD ($\rho = 0.76$).** El TPSA se calcula de forma aditiva sobre los mismos átomos polares que definen a los donadores y aceptores de puente de hidrógeno. Que los tres encabezan la Tabla 4 no son tres hallazgos independientes: es un solo eje de polaridad medido de tres formas distintas.
- Adicionalmente, **Arom y Fsp3: $\rho = -0.74$,** con sentido químico directo: más anillos aromáticos implica una molécula más plana, con menos carbonos de hibridación sp^3 .

Consecuencia para el Avance 2. Al construir la matriz de características no conviene tratar estos descriptores como señales independientes; un método de selección debería descartar la redundancia entre MW y HeavyAtoms antes de entrenar, en vez de dejar que el modelo la absorba sin control.

4.3 Productos naturales contra sintéticos

El cruce con COCONUT que trae el conjunto de la patrocinadora permite separar los compuestos de origen natural de los sintéticos. Es la pregunta central del proyecto: los compuestos que se quieren priorizar son productos naturales.

Tabla 5: Permeabilidad según el origen del compuesto

Grupo	n	% BBB+	% BBB-
Sintético (sin equivalente natural conocido)	4,439	71.7	28.3
Producto natural (estructura idéntica en COCONUT)	3,366	52.7	47.3

Los productos naturales cruzan la barrera bastante menos: 52.7% contra 71.7%, una diferencia de 18.9 puntos.




Figura 4: Permeabilidad y perfil fisicoquímico según el origen del compuesto. A la izquierda, la clase por grupo. Al centro y a la derecha, las distribuciones de TPSA y de donadores de puente de hidrógeno; la línea marca el umbral de 67 Å².

4.3.a ¿Hay explicación química, o es sesgo de qué se ensayó?

Los productos naturales son en efecto más polares, que es la dirección que predicen las reglas fisicoquímicas:

Tabla 6: Perfil fisicoquímico según el origen

Descriptor (mediana)	Sintético	Producto natural
TPSA (Å ²)	67.8	78.4
Donadores de puente de H	1.0	2.0
Aceptores de puente de H	4.0	5.0
Peso molecular	366.5	359.4
logP	2.79	2.13

Pero la explicación es **parcial**. Al aplicar la regla de dos parámetros derivada de estos mismos datos (TPSA < 67 Å² y HBD ≤ 1), la cumple el 41.2% de los sintéticos y el 34.6% de los naturales: una brecha de **6.6 puntos**, frente a los **18.9 puntos** de diferencia en la tasa real de cruce.

La química da cuenta de aproximadamente un tercio de la diferencia. El resto podría deberse a mecanismos no capturados por estos descriptores —el flujo activo, por ejemplo— o a sesgo en qué compuestos han llegado a ensayarse. **No conviene sobreinterpretarlo**; queda como pregunta para la patrocinadora.

Dos implicaciones para el modelado:

1. **El modelo debe evaluarse por separado en ambos grupos.** Un desempeño global puede ocultar que funciona peor justamente sobre los compuestos a priorizar.
2. **Refuerza la necesidad de medir el dominio de aplicabilidad.** Si los productos naturales ocupan otra región del espacio químico, puntuar una base completa de ellos con un modelo entrenado mayoritariamente sobre sintéticos es extrapolación, no interpolación.

5 Preprocesamiento

5.1 Estructuras inválidas

Los 7,811 SMILES del archivo de la patrocinadora parsean en RDKit sin excepción. La curación ya retiró las estructuras rotas, y eso se puede verificar de forma independiente: en el archivo crudo de B3DB que el equipo descargó por su cuenta, dos SMILES de los 7,807 no parsean ([C+] con cuatro enlaces explícitos, una carga imposible; ambos del grupo C, el de menor confiabilidad, y con la misma estructura inválida bajo nombres de fármacos sin relación entre sí). Ninguno de los dos sobrevive en el archivo de la patrocinadora.

La reducción de 7,811 a **7,805** no viene entonces de estructuras inválidas, sino de las 6 filas sin clase asignada señaladas en Estructura de los datos.

5.2 Deduplicación

Como se documentó en Estructura de los datos, la deduplicación por InChIKey completo encuentra solo 3 pares, todos con etiquetas coincidentes, pero el esqueleto de conectividad sí revela redundancia estructural real (4,018 esqueletos en 7,805 filas). **No se eliminan filas por esto:** el **scaffold split**⁴ que se construirá en el Avance 2 agrupa por esqueleto, lo cual resuelve el problema sin perder información.

5.3 Valores atípicos: ¿ruido o diversidad real?

La regla de Tukey marca como atípico todo valor fuera de $[Q1 - 1.5 \times RIC, Q3 + 1.5 \times RIC]$, donde **RIC** es el rango intercuartílico: la distancia entre el percentil 25 (Q1) y el 75 (Q3) de cada descriptor.

⁴Partición que agrupa las moléculas por su **andamio de Murcko** —el esqueleto de anillos y los enlaces que los conectan, sin los grupos sustituyentes que cuelgan de él— y reparte andamios completos entre entrenamiento y prueba, en vez de repartir filas al azar (Bemis & Murcko, 1996).

Tabla 7: Valores atípicos por descriptor según la regla de Tukey

Descriptor	Atípicos (regla de Tukey, 1.5×RIC)	%	Rango real
HBA	783	10.0	[0, 33]
HeavyAtoms	441	5.7	[1, 136]
TPSA	404	5.2	[0.0, 662.4]
MW	389	5.0	[6.9, 1882.3]
HBD	297	3.8	[0, 24]
logP	216	2.8	[−8.9, 12.6]
RotB	178	2.3	[0, 53]
Arom	13	0.2	[0, 8]
Fsp3	0	0.0	[0.0, 1.0]




Figura 5: Dispersión de los 6 descriptores principales por clase, con los valores atípicos marcados.

Los extremos corresponden a estructuras reales, no a errores: ya pasaron el filtro de validez de SMILES. En el extremo superior de MW aparecen antibióticos glicopeptídicos (*teichomycin*, gramicidina), grandes y polares, casi todos BBB-. En el inferior están gases y elementos (metano, agua, nitrógeno, litio, neón), BBB+ por su tamaño mínimo. En el extremo de logP aparecen carotenoides y ésteres de retinol, compuestos naturales muy lipofílicos y BBB-.

Decisión: no se recortan ni transforman. Tres razones: (1) son estructuras válidas, no errores de parseo; (2) los modelos de ensamble que adopta este proyecto (Random Forest, XGBoost) son robustos a valores extremos por construcción; y (3) recortarlos sesgaría el conjunto en contra de los productos naturales, que tienden a ser más grandes y complejos que los sintéticos —justo el tipo de compuesto que el proyecto quiere puntuar—.

Nota sobre HBA. Su 10% de atípicos por la regla de Tukey es la proporción más alta de la tabla, pero HBA es un conteo entero de distribución sesgada a la derecha: la regla es más agresiva en variables así, no es evidencia de más error.

5.4 Alta cardinalidad

No aplica: la única variable categórica relevante, `group`, tiene 4 clases.

6 Conclusiones

1. **El tamaño efectivo del conjunto es ~4,018 entidades, no 7,805.** Hay que reportar ambas cifras y construir la partición del Avance 2 por esqueleto de conectividad, no de forma aleatoria.
2. **Los grupos A–D no sirven como filtro de calidad.** El grupo D tiene más respaldo bibliográfico que el C (mediana de 3 referencias contra 1) y no hay un solo registro duplicado con etiquetas contradictorias (las contradicciones que sí existen son entre estereoisómeros, no entre copias del mismo compuesto). Además, el grupo está correlacionado con la etiqueta: filtrar a A+B baja la clase minoritaria del 36.5% al 27.0%, empeorando el desbalance en vez de limpiar ruido. **Se usará como variable de estratificación, no de exclusión.**
3. **TPSA, HBD y HBA discriminan bien, pero miden en buena parte lo mismo** (ρ hasta 0.89 entre ellos), y MW/HeavyAtoms son casi la misma variable ($\rho = 0.98$). El umbral óptimo de TPSA no es transferible entre subconjuntos: 66.6 Å² en el grupo A, 83.6 Å² en A+B, 101.9 Å² en el completo.
4. **Los valores atípicos son diversidad estructural real** (antibióticos grandes, gases pequeños, carotenoides lipofílicos), no errores, y se conservan sin transformar dado que el proyecto usa modelos de ensamble.
5. **Desbalance de 1.74:1** (2.70:1 en A+B): se usarán MCC (coeficiente de correlación de Matthews) y AUPRC (área bajo la curva de precisión-exhaustividad) como métricas principales (Chicco & Jurman, 2020; Saito & Rehmsmeier, 2015), no exactitud ni AUROC solos.
6. **El scaffold split es viable:** 2,126 andamios de Murcko distintos, 53.2% únicos, sin andamio dominante (Wu et al., 2018).
7. **Los productos naturales cruzan la barrera menos que los sintéticos** (52.7% contra 71.7% BBB+) y las reglas fisicoquímicas explican solo un tercio de esa diferencia. Como son los compuestos a priorizar, el desempeño debe reportarse por separado en ambos grupos.
8. **El conjunto de validación externa (Spieltogel et al.) necesita trabajo previo:** no trae SMILES ni InChI, solo nombres; hay que resolverlos antes de poder usarlo.

Ningún número de este documento se toma de la literatura como meta de desempeño; el Avance 3 construirá su propio baseline, siguiendo la validación externa genuina que recomienda la metodología (Golbraikh & Tropsha, 2002).

7 Próximos pasos: Avance 2

1. Descriptores RDKit (217) más Morgan/ECFP4 de 2048 bits.
2. Construir el scaffold split agrupando por andamio de Murcko, verificando que los estereoisómeros del mismo esqueleto no se separen.
3. Resolver la redundancia entre descriptores (MW/HeavyAtoms, TPSA/HBA/HBD) antes de seleccionar variables.
4. Rederivar los umbrales de verificación sobre A+B, no usar los publicados.

Bibliografia

- Bemis, G. W., & Murcko, M. A. (1996). The Properties of Known Drugs. 1. Molecular Frameworks. *Journal of Medicinal Chemistry*, 39(15), 2887-2893. <https://doi.org/10.1021/jm9602928>
- Chandrasekhar, V., Rajan, K., Kanakam, S. R. S., Sharma, N., Weißenborn, V., Schaub, J., & Steinbeck, C. (2025). COCONUT 2.0: a comprehensive overhaul and curation of the collection of open natural products database. *Nucleic Acids Research*, 53(D1), D634-D643. <https://doi.org/10.1093/nar/gkae1063>
- Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21, 6. <https://doi.org/10.1186/s12864-019-6413-7>
- Golbraikh, A., & Tropsha, A. (2002). Beware of q²!. *Journal of Molecular Graphics and Modelling*, 20(4), 269-276. [https://doi.org/10.1016/S1093-3263\(01\)00123-1](https://doi.org/10.1016/S1093-3263(01)00123-1)
- Meng, F., Xi, Y., Huang, J., & Ayers, P. W. (2021). A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors. *Scientific Data*, 8(1), 289. <https://doi.org/10.1038/s41597-021-01069-5>
- Saito, T., & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLoS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Tiwari, S., Mądra-Gackowska, K., Gackowski, M., & Szeleszczuk, Ł. (2026). Quantitative Structural Thresholds for Blood-Brain Barrier Permeability Derived from Experimental logBB Measurements. *Pharmaceutics*, 18(8), 967. <https://doi.org/10.3390/pharmaceutics18080967>
- Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., Leswing, K., & Pande, V. (2018). MoleculeNet: A Benchmark for Molecular Machine Learning. *Chemical Science*, 9(2), 513-530. <https://doi.org/10.1039/C7SC02664A>