Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Maestría en Inteligencia Artificial Aplicada

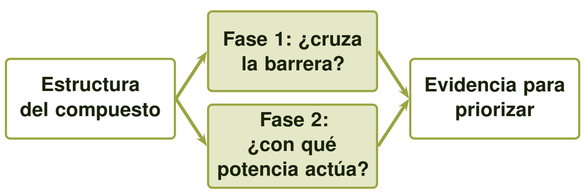
Ingrid Pamela Ruiz Puga Artemio Santiago Padilla Robles José Antonio Vázquez Martínez

Asesora: Dra. Grettel Barceló Alonso · Patrocinadora: Dra. Mariana Martínez Ávila · Noviembre 2026

El problema

Probar en el laboratorio cada compuesto natural con potencial neuroprotector es lento y caro. Para decidir cuáles probar primero, dos modelos estiman, a partir de su estructura química, si un compuesto:

- cruza la barrera que protege al cerebro (fase 1);
- actúa sobre alguna de 26 proteínas del sistema nervioso, y con qué potencia (fase 2).



La salida es evidencia para decidir en qué orden probar, no una decisión automática.

Datos

7,805 compuestos (fase 1)

202,647 mediciones (fase 2)

- Fase 1: archivo curado de la patrocinadora (63.5 % permeables). Fase 2: ChEMBL, NPASS y CMAUP, con mediciones acotadas (por ejemplo, mayores que 10 µM).
- Prueba reservada de 1,499 compuestos que ningún modelo vio; la separación es por familia química, nunca al azar.

Métodos

- Descriptores de RDKit (propiedades calculadas de cada molécula) y, en la fase 2, huellas de Morgan. Once modelos comparados, de la regresión logística a los ensambles.
- En la fase 2, un modelo que aprovecha también las mediciones acotadas, que solo dicen que el valor es mayor o menor que un límite.

Lo que encontramos

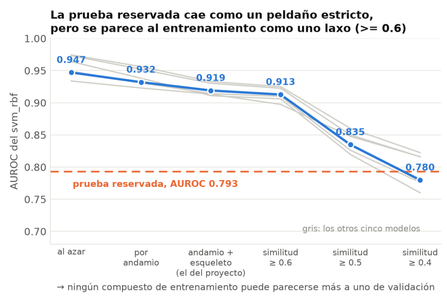


Figura 1. Al exigir que lo evaluado se parezca menos a lo entrenado, el acierto baja; la prueba reservada (0.793) cae como un caso muy exigente.

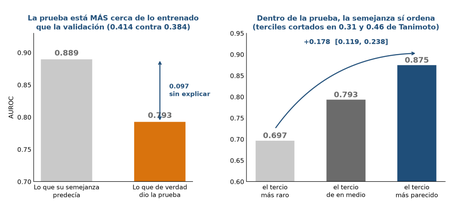


Figura 2. La prueba está más cerca de lo entrenado que la validación, pero rinde 0.097 menos de lo esperado. Dentro de la prueba, la semejanza sí ordena.

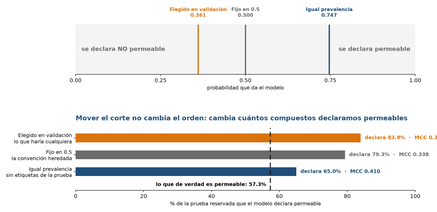


Figura 3. Mover el corte no cambia el orden: cambia cuántos compuestos se declaran permeables (de 84 % a 65 %) y el MCC (de 0.346 a 0.410).

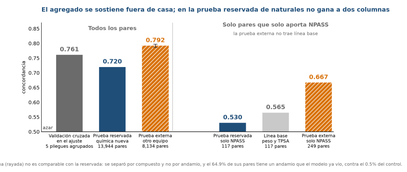


Figura 4. Fase 2: la concordancia se sostiene en la prueba (0.720). En los 117 pares de naturales, 0.530 (0.511 al reajustar) no se distingue de un modelo de peso y TPSA (0.565).



Figura 5. Lo que más mueve el resultado es cuánta novedad se exige, no el modelo.

Conclusiones

- La confianza en una predicción depende de qué tan nueva es la molécula, no del modelo.
- De 0.70 a 0.34 de MCC (el acierto) con moléculas nuevas: unos 0.07 eran el corte, que se puede ajustar; el resto sigue sin explicar.
- Sirve para ordenar: probar el 70 % mejor ordenado conserva el 85.3 % de los permeables, 15.3 puntos más que un sorteo.
- En naturales el orden de potencia no está demostrado (117 pares). Sigue medirlo con muestras propias y combinar las dos fases.

Qué características pesan

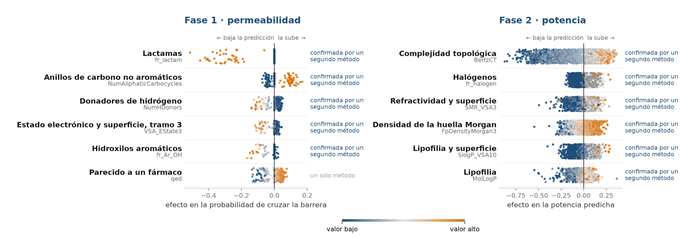


Figura 6. Cada punto es un compuesto o par compuesto-diana. TPSA no domina.

Qué entregamos



- Una lista exploratoria de naturales (hipótesis, no resultados) y un cuaderno para moléculas propias, con aviso si son muy distintas de lo conocido, y una guía para medir columnas nuevas. La continuidad queda con la patrocinadora.

Referencias

- Meng, F., Xi, Y., Huang, J., y Ayers, P. W. (2021). *A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors*. Scientific Data, 8(1), 289.
- Zdrazil, B., et al. (2024). *The ChEMBL Database in 2023*. Nucleic Acids Research, 52(D1), D1180–D1192.
- Zhao, H., et al. (2023). *NPASS database update 2023*. Nucleic Acids Research, 51(D1), D621–D628.

Declaración de uso de inteligencia artificial. Anthropic. (2026). *Claude Code* [Agente de programación], con los modelos Claude Opus 5, Claude Sonnet 5.5 y Claude Sonnet 5, https://claude.com/claude-code. Se utilizó para redactar el texto, generar las figuras y calcular las cifras. Las decisiones, la interpretación y las conclusiones son del equipo. La responsabilidad final sobre el contenido entregado recae en los autores.