Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Maestría en Inteligencia Artificial Aplicada

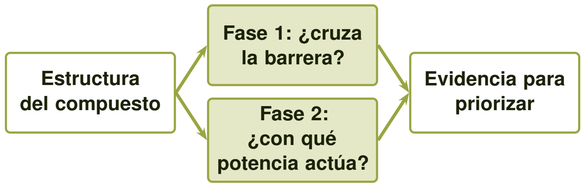
Ingrid Pamela Ruiz Puga Artemio Santiago Padilla Robles José Antonio Vázquez Martínez

Asesora: Dra. Grettel Barceló Alonso · Patrocinadora: Dra. Mariana Martínez Ávila · Noviembre 2026

El problema

Probar en el laboratorio cada compuesto natural con potencial neuroprotector es lento y caro. Para decidir cuáles probar primero, dos modelos estiman, a partir de su estructura química, si un compuesto:

- cruza la barrera que protege al cerebro (fase 1);
- actúa sobre alguna de 26 proteínas del sistema nervioso, y con qué potencia (fase 2).



La salida es evidencia para decidir en qué orden probar, no una decisión automática.

Datos

7,805 compuestos (fase 1)

202,647 mediciones (fase 2)

- Fase 1: archivo curado de la patrocinadora (63.5 % permeables). Fase 2: ChEMBL, NPASS y CMAUP, con mediciones acotadas, como «mayor que 10 µM».
- Prueba reservada de 1,499 compuestos que ningún modelo vio; la separación es por familia química, nunca al azar.

Métodos

- Descriptores de RDKit (propiedades calculadas de cada molécula) y, en la fase 2, huellas de Morgan. Once modelos comparados, de la regresión logística a los ensambles.
- En la fase 2, un modelo que aprovecha también las mediciones «mayores que» o «menores que».

Lo que encontramos

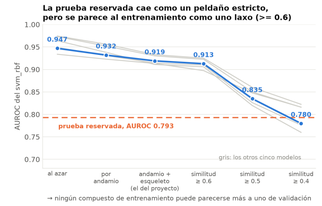


Figura 1. Al exigir que lo evaluado se parezca menos a lo entrenado, el acierto baja; la prueba reservada (0.793) rinde como un caso muy exigente.

0.761 fase 2: validación cruzada

0.720 fase 2: prueba reservada

Figura 2. Fase 2: de dos compuestos, acierta cuál es más potente el 76 % de las veces (azar: 50 %). En los 117 pares de naturales baja a 0.511, sin distinguirse de un modelo de peso, polaridad y diana (0.565).



Figura 3. Lo que más mueve el resultado es cuánta novedad se exige, no el modelo.

Qué características pesan

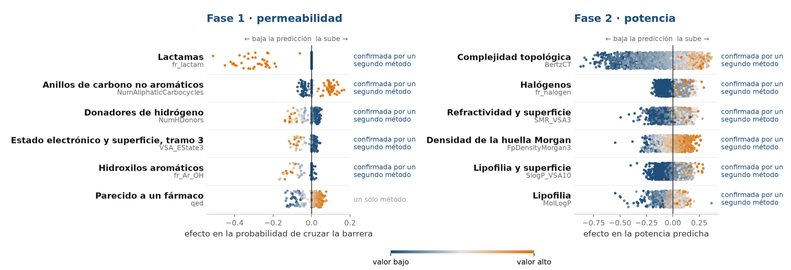
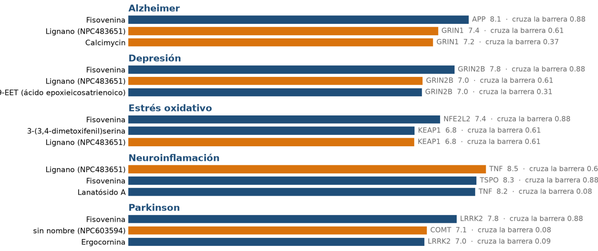


Figura 4. Cada punto es un compuesto o un par compuesto-diana: su posición dice cuánto empuja esa característica la predicción; su color, qué valor tiene. TPSA, el filtro clásico, no domina. La diana aporta otro 15 % en la fase 2.

Conclusiones

- La confianza en una predicción depende de qué tan nueva es la molécula, no del modelo.
- De 0.70 a 0.34 de MCC (el acierto) con moléculas nuevas: unos 0.07 eran el corte, que se puede ajustar; el resto sigue sin explicar.
- Sirve para ordenar: probar el 70 % mejor ordenado conserva el 85.3 % de los permeables, 15.3 puntos más que un sorteo.
- En naturales el orden de potencia no está demostrado (117 pares).

Qué entregamos



Los tres primeros por enfermedad: potencia predicha (número junto a la diana) y probabilidad de cruzar la barrera. En naranja, se parece poco a lo que el modelo conoce.

- Una lista exploratoria de naturales (hipótesis, no resultados) y un cuaderno que, para moléculas propias, devuelve la probabilidad de cruzar la barrera, la potencia por diana y un aviso si son muy distintas de lo conocido.
- Una guía para medir columnas nuevas. La continuidad queda con la patrocinadora y su grupo.

Trabajo futuro

- Medir la potencia con muestras propias de naturales.
- Combinar las dos fases en un solo orden.

Referencias

- Meng, F., Xi, Y., Huang, J., y Ayers, P. W. (2021). *A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors.* Scientific Data, 8(1), 289.
- Zdrazil, B., et al. (2024). *The ChEMBL Database in 2023.* Nucleic Acids Research, 52(D1), D1180–D1192.
- Zhao, H., et al. (2023). *NPASS database update 2023.* Nucleic Acids Research, 51(D1), D621–D628.

Declaración de uso de inteligencia artificial. Anthropic. (2026). *Claude Code* [Agente de programación], con los modelos Claude Opus 5, Claude Sonnet 5.5 y Claude Sonnet 5, https://claude.com/claude-code. Se utilizó para redactar el texto, generar las figuras y calcular las cifras. Las decisiones, la interpretación y las conclusiones son del equipo. La responsabilidad final sobre el contenido entregado recae en los autores.