Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Maestría en Inteligencia Artificial Aplicada

Ingrid Pamela Ruiz Puga Artemio Santiago Padilla Robles José Antonio Vázquez Martínez

Asesora: Dra. Grettel Barceló Alonso · Patrocinadora: Dra. Mariana Martínez Ávila · Noviembre 2026

El problema

Hay muchos compuestos naturales con potencial neuroprotector y probar cada uno en el laboratorio cuesta tiempo y dinero. Un compuesto solo sirve si:

- cruza la barrera hematoencefálica (fase 1, clasificación);
- actúa sobre una de 26 dianas del sistema nervioso, y con qué potencia (fase 2, regresión).

La entrada es la estructura escrita como texto (SMILES). La salida es evidencia para priorizar, no una decisión automática.

Datos

7,805 compuestos con clase (fase 1)

202,647 registros de actividad (fase 2)

- Fase 1: archivo curado de la patrocinadora (B3DB y COCONUT); 63.5 % permeables. Fase 2: ChEMBL, NPASS y CMAUP, con mediciones censuradas.
- Prueba reservada de 1,499 compuestos, fuera del entrenamiento. Partición por andamio y esqueleto, nunca al azar.

Métodos

- Descriptores de RDKit, y huellas de Morgan en la fase 2.
- Once modelos comparados, de la regresión logística a los ensambles. En la fase 2, un modelo de supervivencia (AFT) que aprovecha las mediciones censuradas.

Qué pesa en cada fase

- Con dos métodos de atribución independientes. Fase 1: los donadores de hidrógeno y otros cinco descriptores; TPSA no domina.
- Fase 2: la diana pone el 15 % y el resto es química (complejidad, halógenos). Sin afirmar ningún mecanismo.

Lo que encontramos

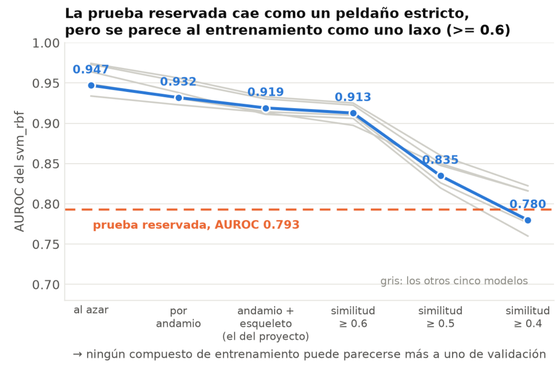


Figura 1. El AUROC cae al exigir que lo evaluado se parezca menos a lo entrenado; la prueba reservada (0.793) cae como un peldaño estricto, aunque se parece al entrenamiento como uno laxo.

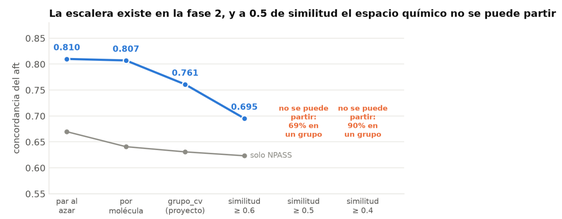


Figura 2. En la fase 2 la concordancia también baja al exigir menos parecido, y los pares que solo aporta NPASS, los productos naturales (gris), quedan siempre más abajo. Los peldaños estrictos no se pueden construir en este conjunto.

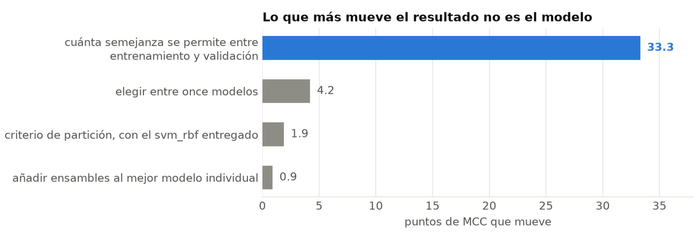


Figura 3. Lo que más mueve el resultado es cuánta novedad se exige, no el modelo. Cada barra viene de una corrida distinta.

Palabras clave. MCC: medida de acierto, de -1 a 1 (0 es el azar). **AUROC**: qué tan bien se ordenan los permeables por encima de los que no. **TPSA**: superficie polar. **Andamio**: el núcleo de anillos de una molécula. **Huella**: bits que marcan los fragmentos que contiene.

Conclusiones

- La confianza en una predicción depende de qué tan nueva es la molécula, no del modelo.
- De 0.70 a 0.34 de MCC: unos 0.07 eran el corte, que se puede ajustar. El orden cayó 12.6 puntos de AUROC y el resto sigue sin explicar.
- Sirve para ordenar: confirmar el 70 % mejor ordenado conserva el 85.3 % de los permeables, 15.3 puntos más que un sorteo.
- En productos naturales el orden de potencia no está demostrado: 0.511 en 117 pares (0.530 registrada), sin distinguirse de la línea base de peso, polaridad y diana (0.565).

Transferencia y continuidad

Lista de SMILES → **Cuaderno con los dos modelos** → **Probabilidad, potencia y advertencia**

Un cuaderno recibe estructuras propias y devuelve, por compuesto, la probabilidad de cruzar la barrera, la potencia por diana y qué tan cerca queda de lo conocido, con una advertencia de extrapolación. Se entrega también una lista priorizada exploratoria de naturales, y los dos modelos, el procedimiento para reentrenar y una guía para medir columnas propias. La continuidad queda en manos de la patrocinadora y su grupo.

Trabajo futuro

- Medir la potencia con los primeros lotes propios de productos naturales.
- Combinar las dos fases en un solo orden y comprobar si elige mejor que cada una; hoy el cuaderno las ordena por separado.
- Evaluar representaciones adicionales con la herramienta incluida.

Referencias

- Meng, F., Xi, Y., Huang, J., y Ayers, P. W. (2021). *A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors.* Scientific Data, 8(1), 289.
- Zdrazil, B., et al. (2024). *The ChEMBL Database in 2023.* Nucleic Acids Research, 52(D1), D1180–D1192.
- Zhao, H., et al. (2023). *NPASS database update 2023.* Nucleic Acids Research, 51(D1), D621–D628.

Declaración de uso de inteligencia artificial. Anthropic. (2026). *Claude Code* [Agente de programación], con los modelos Claude Opus 5, Claude Sonnet 5.5 y Claude Sonnet 5, https://claude.com/claude-code. Se utilizó para redactar el texto, generar las figuras y calcular las cifras. Las decisiones, la interpretación y las conclusiones son del equipo. La responsabilidad final sobre el contenido entregado recae en los autores.