Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Maestría en Inteligencia Artificial Aplicada

Ingrid Pamela Ruiz Puga Artemio Santiago Padilla Robles José Antonio Vázquez Martínez

Asesora: Dra. Grettel Barceló Alonso · Patrocinadora: Dra. Mariana Martínez Ávila · Noviembre 2026

El problema

Hay muchos compuestos naturales con potencial neuroprotector y probar cada uno en el laboratorio cuesta tiempo y dinero. Un compuesto solo sirve si:

- cruza la barrera hematoencefálica (fase 1, clasificación);
- actúa sobre una de 26 dianas del sistema nervioso, y con qué potencia (fase 2, regresión).

La entrada es la estructura escrita como texto (SMILES). La salida es evidencia para priorizar, no una decisión automática.

Datos

7,805 compuestos con clase (fase 1)

202,647 registros de actividad (fase 2)

- Fase 1: archivo curado de la patrocinadora (B3DB cruzado con COCONUT). 63.5 % son permeables.
- Fase 2: ChEMBL, NPASS y CMAUP, con mediciones censuradas (“mayor que”).
- Prueba reservada de 1,499 compuestos, fuera del entrenamiento.
- Partición por andamio y esqueleto, nunca al azar.

Métodos

- Descriptores de RDKit, y huellas de Morgan en la fase 2.
- Once modelos comparados, de la regresión logística a los ensambles. En la fase 2, un modelo de supervivencia (AFT) que aprovecha las mediciones censuradas.
- Atribuciones con dos métodos independientes.

Lo que encontramos

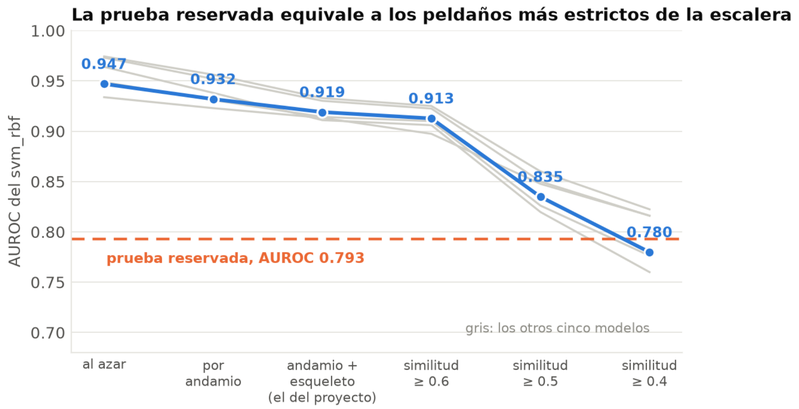


Figura 1. El AUROC cae al exigir que lo evaluado se parezca menos a lo entrenado; la prueba reservada (0.793) equivale a los peldaños más estrictos.

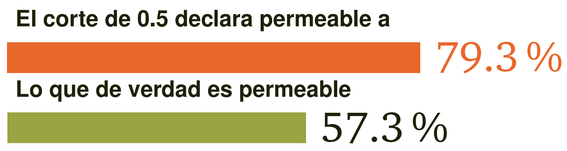


Figura 2. Compuestos de la prueba reservada. Igualar la tasa de permeables a la real sube el MCC de 0.339 a 0.410.

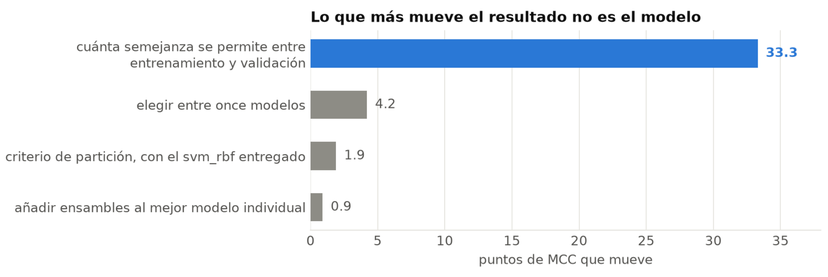


Figura 3. Lo que más mueve el resultado es cuánta novedad se exige, no el modelo. Cada barra viene de una corrida distinta.

Conclusiones

- La confianza en una predicción depende de qué tan nueva es la molécula, no del modelo.
- De 0.70 a 0.34 de MCC: unos 0.07 eran el corte, que se puede ajustar. El orden cayó 12.6 puntos de AUROC y el resto sigue sin explicar.
- Sirve para ordenar: confirmar el 70 % mejor ordenado conserva el 85.3 % de los permeables, 15.3 puntos más que un sorteo.
- En productos naturales el orden de potencia no está demostrado: 0.530 en 117 pares, bajo la línea base de peso y superficie polar (0.565).

Transferencia y continuidad

Lista de SMILES → **Cuaderno con los dos modelos** → **Probabilidad, potencia y advertencia**

Un cuaderno recibe estructuras propias y devuelve, por compuesto, la probabilidad de cruzar la barrera, la potencia por diana y qué tan cerca queda de lo conocido, con una advertencia de extrapolación. Se entregan los dos modelos, el procedimiento para reentrenar y una guía para medir columnas propias. La continuidad queda en manos de la patrocinadora y su grupo.

Trabajo futuro

- Medir la potencia con los primeros lotes propios de productos naturales.
- Evaluar representaciones adicionales con la herramienta incluida.

Referencias

- Meng, F., Xi, Y., Huang, J., y Ayers, P. W. (2021). *A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors.* Scientific Data, 8(1), 289.
- Zdrazil, B., et al. (2024). *The ChEMBL Database in 2023.* Nucleic Acids Research, 52(D1), D1180–D1192.
- Zhao, H., et al. (2023). *NPASS database update 2023.* Nucleic Acids Research, 51(D1), D621–D628.

Declaración de uso de inteligencia artificial. Anthropic. (2026). *Claude Code* [Agente de programación], con los modelos Claude Opus 5, Claude Sonnet 5.5 y Claude Sonnet 5, https://claude.com/claude-code. Se utilizó para redactar el texto, generar las figuras y calcular las cifras. Las decisiones, la interpretación y las conclusiones son del equipo. La responsabilidad final sobre el contenido entregado recae en los autores.