Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Equipo 7 · Ingrid Pamela Ruiz Puga · Artemio Santiago Padilla Robles · José Antonio Vázquez Martínez

Maestría en Inteligencia Artificial Aplicada · TC5035.10 · Tecnológico de Monterrey

13 de noviembre de 2026

Qué buscamos

- Priorizar **compuestos naturales** con potencial neuroprotector.
- Para servir, un compuesto tiene que **llegar al cerebro** y **actuar sobre su diana**.
- Lo que producimos es *evidencia para priorizar*, no una decisión automática.

Dos preguntas, en paralelo

Fase 1

¿**Cruza la barrera** hematoencefálica?

Clasificación: permeable o no.

Fase 2

¿Con qué **potencia** actúa sobre cada una de **26 dianas**?

Regresión.

> **Nota**
>
> Pensamos **encadenarlas**. No hay datos para comprobarlo: solo **612 esqueletos** están medidos en las dos. Y un «no permeable» predicho se equivoca: descartar con él perdería candidatos reales.

Dos números que no cuadran

Validación

0.70

MCC

→

Prueba reservada

0.34

MCC

Fase 1, permeabilidad, con el modelo final. El **MCC** resume aciertos y errores de las dos clases, y 0 es azar.

La fase 2 se cae de otro modo. La concordancia apenas baja, de 0.76 a 0.72, pero en los **117 pares** que solo tiene la base de productos naturales llega a **0.53**, bajo una línea base de peso y superficie polar (0.565).

¿Por qué se cae a la mitad una, y la otra solo donde importa? El resto de la charla busca la respuesta.

Los datos

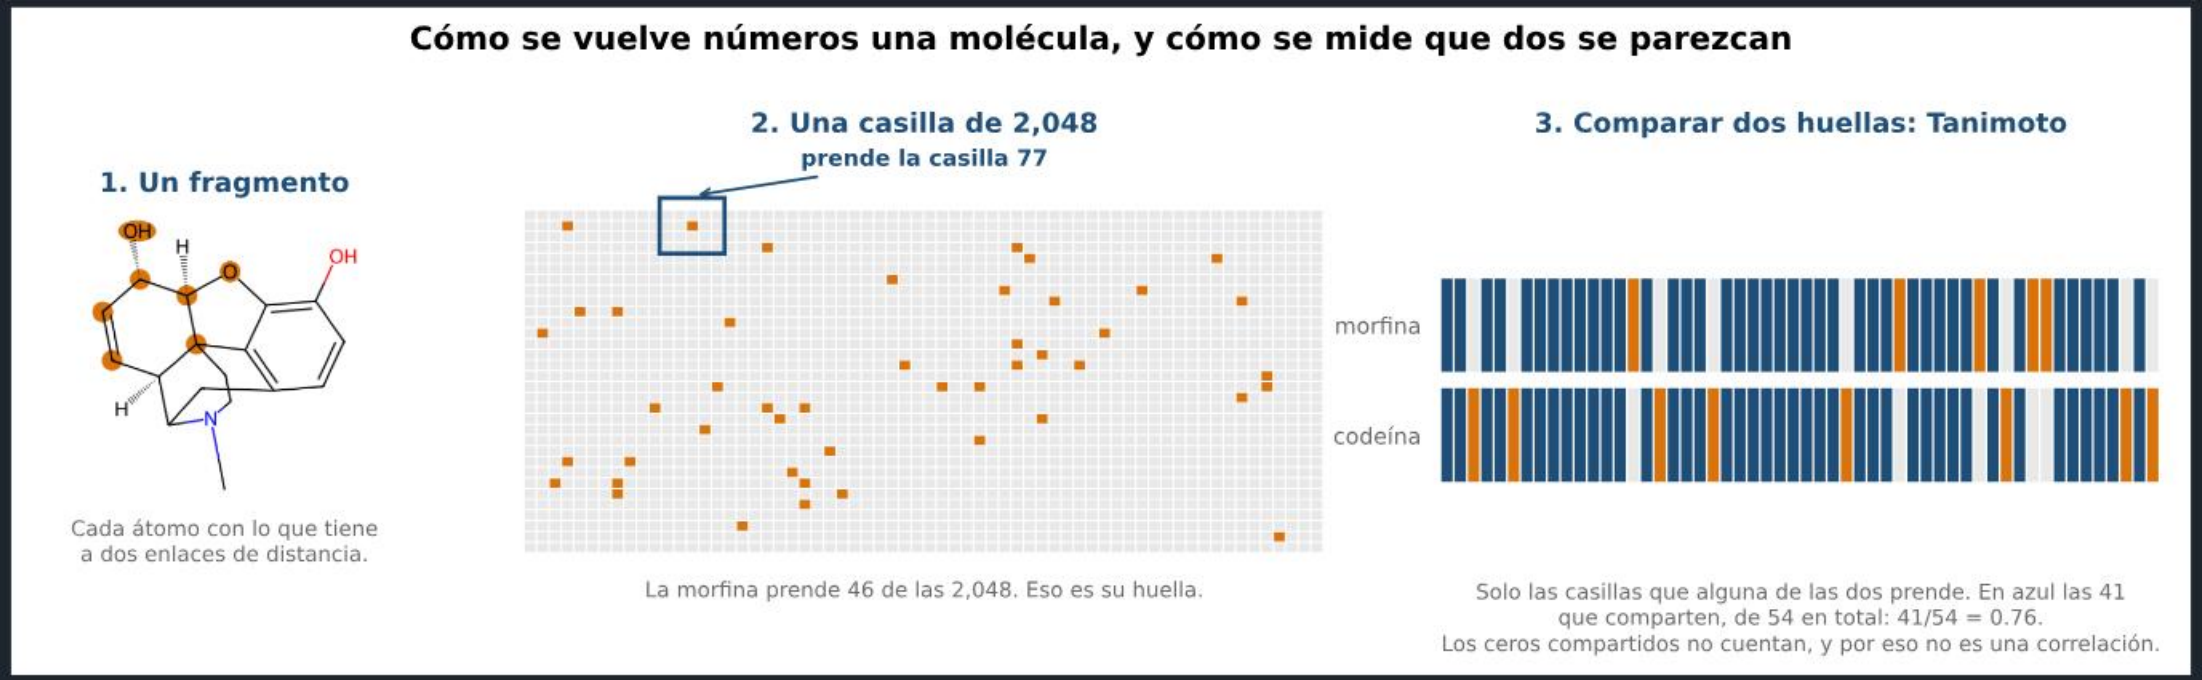
Fase 1 · permeabilidad

- **7,805** compuestos con clase; **63.5%** permeables (65.0% en las filas de ajuste).
- **1,499** reservados para la prueba.

Fase 2 · potencia

- **202,647** registros de tres fuentes: ChEMBL, NPASS y CMAUP.
- Guardamos el **intervalo de potencia**, no una etiqueta: el corte de «activo» puede cambiar.

Cómo se vuelve números una molécula

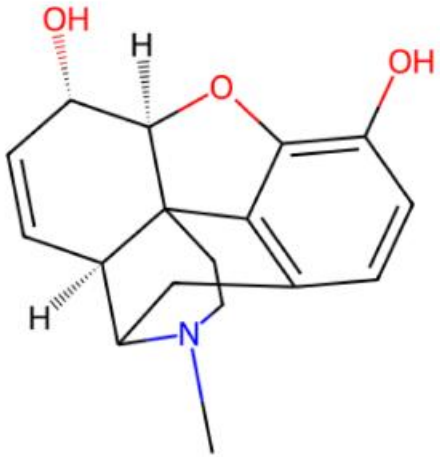


- **Descriptores:** propiedades que calcula RDKit (peso, superficie polar, donadores de hidrógeno y doscientas más). Quedan **151**: fuera las casi constantes y las redundantes, elegidas sobre los **valores crudos** para que la selección no cambie si cambia el escalado.
- **Huellas:** las medimos aparte, y ayudan en la fase 2 y en la fase 1 no (respaldo). Los dos modelos finales corren sobre descriptores; en la fase 2 se suma la diana.

Cómo medimos sin engañarnos

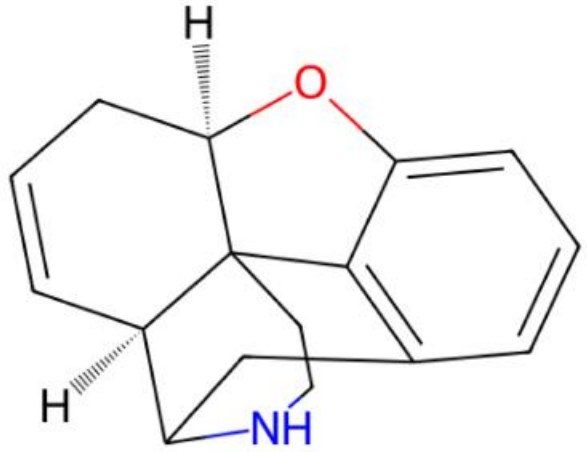
Dos formas de agrupar la misma molécula, y ninguna contiene a la otra

La molécula



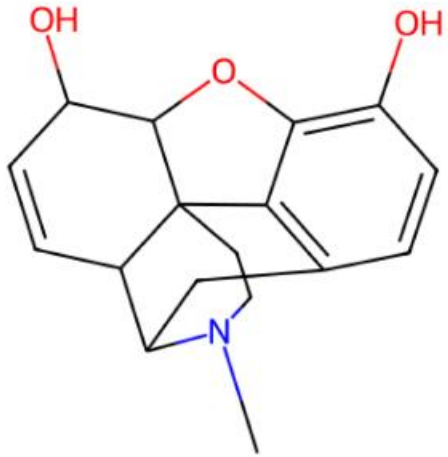
Morfina, un alcaloide natural que sí llega al cerebro. Entra como SMILES, una cadena de texto.

Su andamio (Bemis-Murcko)



Los anillos, sin las cadenas colgantes. Lo comparten 7 compuestos del archivo (codeína, heroína, nalorfina…): 39 registros, y los 39 son BBB+. Si cae entero de un lado, al modelo le basta con reconocerlo.

Su esqueleto de conectividad



La misma molécula sin estereoquímica. Junta los 8 registros de la morfina, que el andamio repartiría en 6 grupos. Por eso agrupamos por los dos.

- **Agrupamos por andamio y por esqueleto, nunca al azar.** Quedan **1,048 grupos**. Partir al azar da cifras demasiado optimistas (Sheridan, 2013): con el `svm_rbf`, el MCC baja de 0.752 con pliegues al azar a 0.702 al agrupar.
- **Qué medimos, y qué dice cada medida. Fase 1**, clasificar: el **MCC** resume en un número los aciertos y los errores de las dos clases, y el **AUROC** dice si pone a los permeables por encima sin fijar ningún corte. También el AUPRC. **Fase 2**, predecir potencia: la **concordancia**, que mide si ordena bien los pares, donde el azar da 0.5.
- Cada prueba se **planteó antes** de ver su resultado, y la prueba reservada solo sirvió **para medir**.

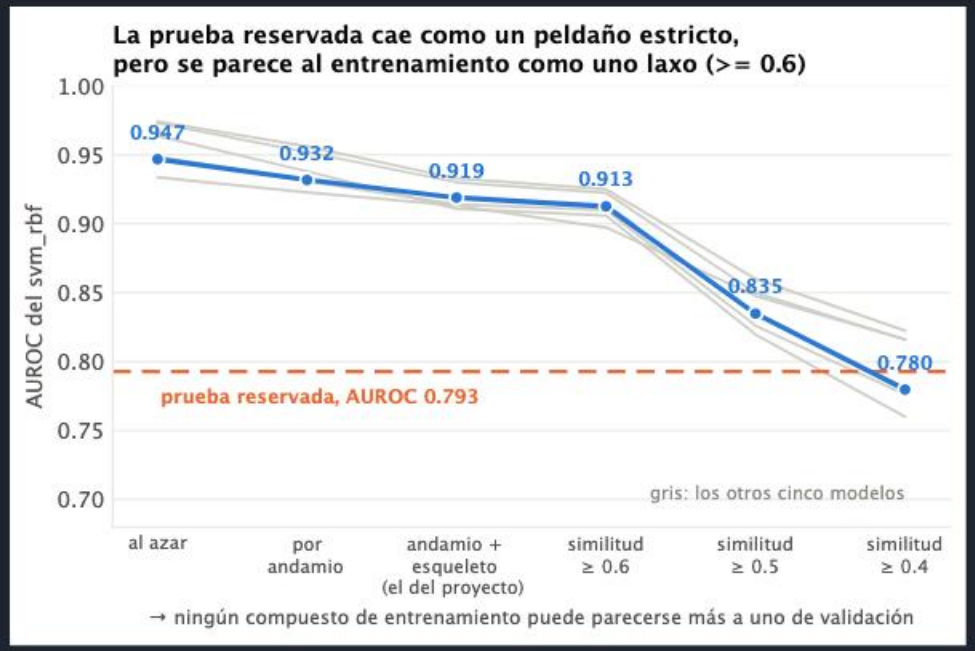
El modelo no es la palanca

- **Permeabilidad: probamos once modelos y todos valen casi lo mismo.** Del mejor al peor hay **4.2 puntos** de MCC, y el mejor **iguala** al modelo sencillo de referencia (0.70) sin superarlo.
- **Potencia: pasa igual.** De los nueve modelos, los siete que compiten de verdad caben en **0.015** de concordancia. Pedirle química más nueva cuesta **siete veces más**.

Pista 1

No es el modelo.

La escalera de semejanza · fase 1



Cómo se parte	Parecido al vecino	AUROC	MCC
Al azar	0.90	0.947	**0.752**
Por andamio	0.75	0.932	0.721
Andamio + esqueleto	0.50	0.919	0.702
Tanimoto < 0.6	0.42	0.913	0.688
Tanimoto < 0.5	0.33	0.835	0.486
Tanimoto < 0.4	0.28	0.780	**0.419**

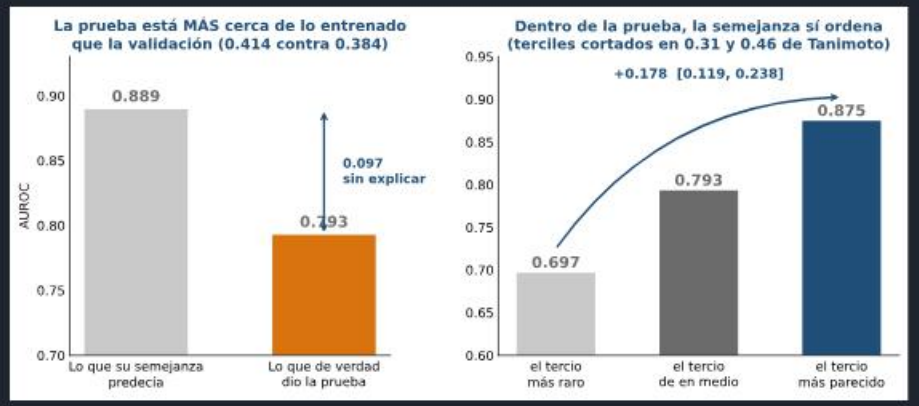
33 puntos de MCC y 17 de AUROC, contra **4.2** de MCC y **2.2** de AUROC entre los once modelos.

En azul el `svm_rbf`, el modelo que entregamos; en gris los otros cinco.

Pista 2

Importa qué tan nueva es la molécula.

La semejanza ordena, pero no clasifica · fase 1



La prueba es **más familiar** que la validación, no más nueva. Debería haber dado 0.889 y dio 0.793.

En los de equivalente natural exacto rinde parecido: AUROC **0.780** en 446 compuestos, contra 0.793 en toda la prueba. Ahí la semejanza también ordena, pero con 446 no se distingue: +0.086, con el cero dentro.

Tres formas de darle más química rara, las tres con la **regla escrita antes de correr**:

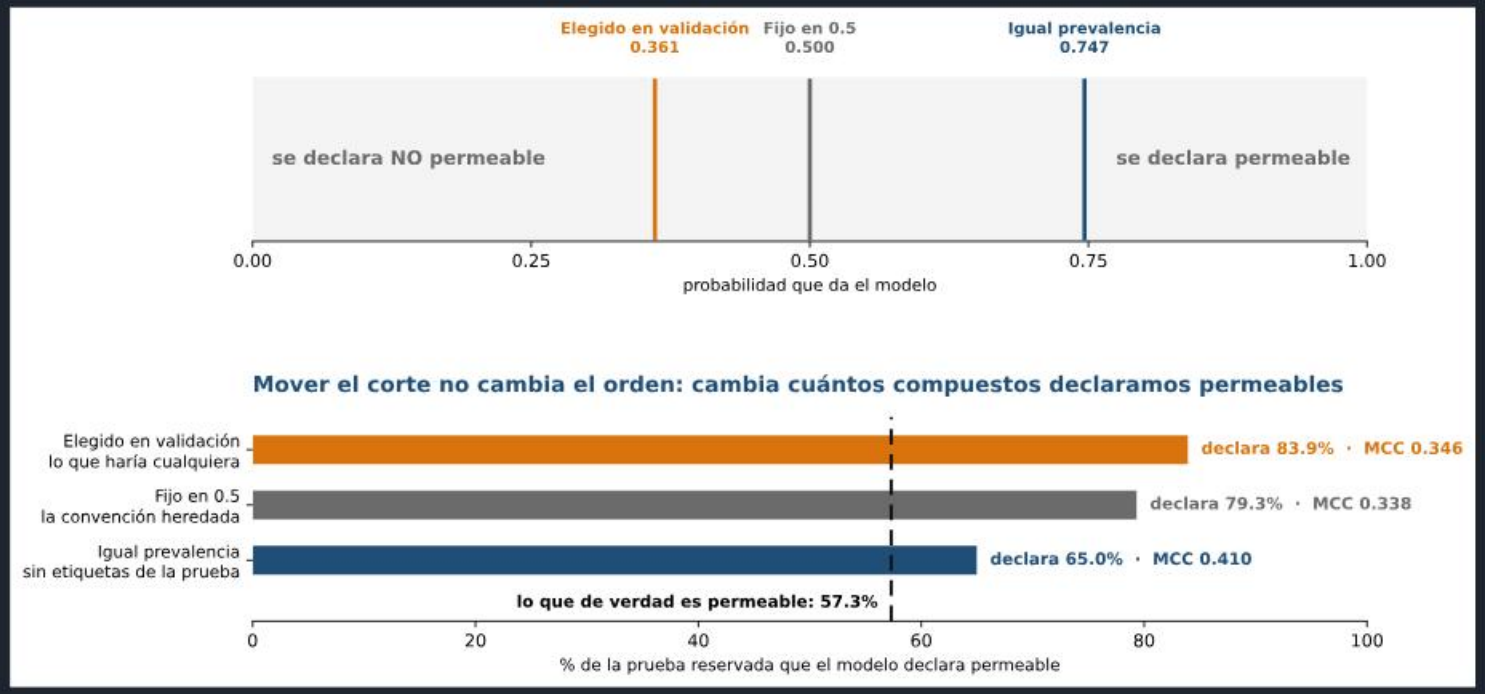
Qué le dimos	Qué pasó
Más peso a las filas raras que ya tenía	**−0.0005**; los mismos pesos al azar mueven igual
Filas raras de la prueba, devolviendo comunes	MCC +0.035 pero AUROC **+0.002**: movió el corte
Otra composición del ajuste, mismo tamaño	**−0.060** con el 25%; con el 75% da igual

Y de paso, lo más útil: con el mismo modelo y sin reentrenar, las filas **comunes** se miden con AUROC **0.94** y las **raras** con **0.68**.

Pista 3

La semejanza dice **qué compuestos** serán más difíciles, no **cuánto** rinde el conjunto: ordena, pero no clasifica. Y recomponer la prueba cambia el número que se reporta, no lo que el modelo sabe.

El corte explica una parte, no la caída · fase 1



- El corte en **0.5** es la convención que trae la librería, no una decisión: con él el modelo declara permeable al **79.3%** de la prueba, cuando lo real es **57.3%**.
- Igualar la tasa declarada a una prevalencia supuesta sube el MCC de **0.34 a 0.41**, sin usar etiquetas de la prueba. Y supusimos la prevalencia del ajuste, 65%, cuando era 57%: aguanta el error.
- Elegir el corte con validación **no sirve** (+0.0065): lo mueve hacia abajo, y la prueba lo necesitaba hacia arriba.

Qué explica la caída: el corte explica una parte y se puede corregir: recupera 0.07 de los 0.36 de MCC que perdimos. El resto es real: el orden también cayó, 12.6 puntos de AUROC (0.919 a 0.793).

El modelo de potencia · fase 2



La misma escalera: de 0.807 por molécula a 0.695 con semejanza menor de 0.6. En gris, solo los pares de NPASS.

Predice la **potencia de cada par compuesto-diana**, no una clase. El `aft` aprende de las mediciones **censuradas**, las que solo dicen «menos potente que esto», y que los otros nueve modelos descartan.

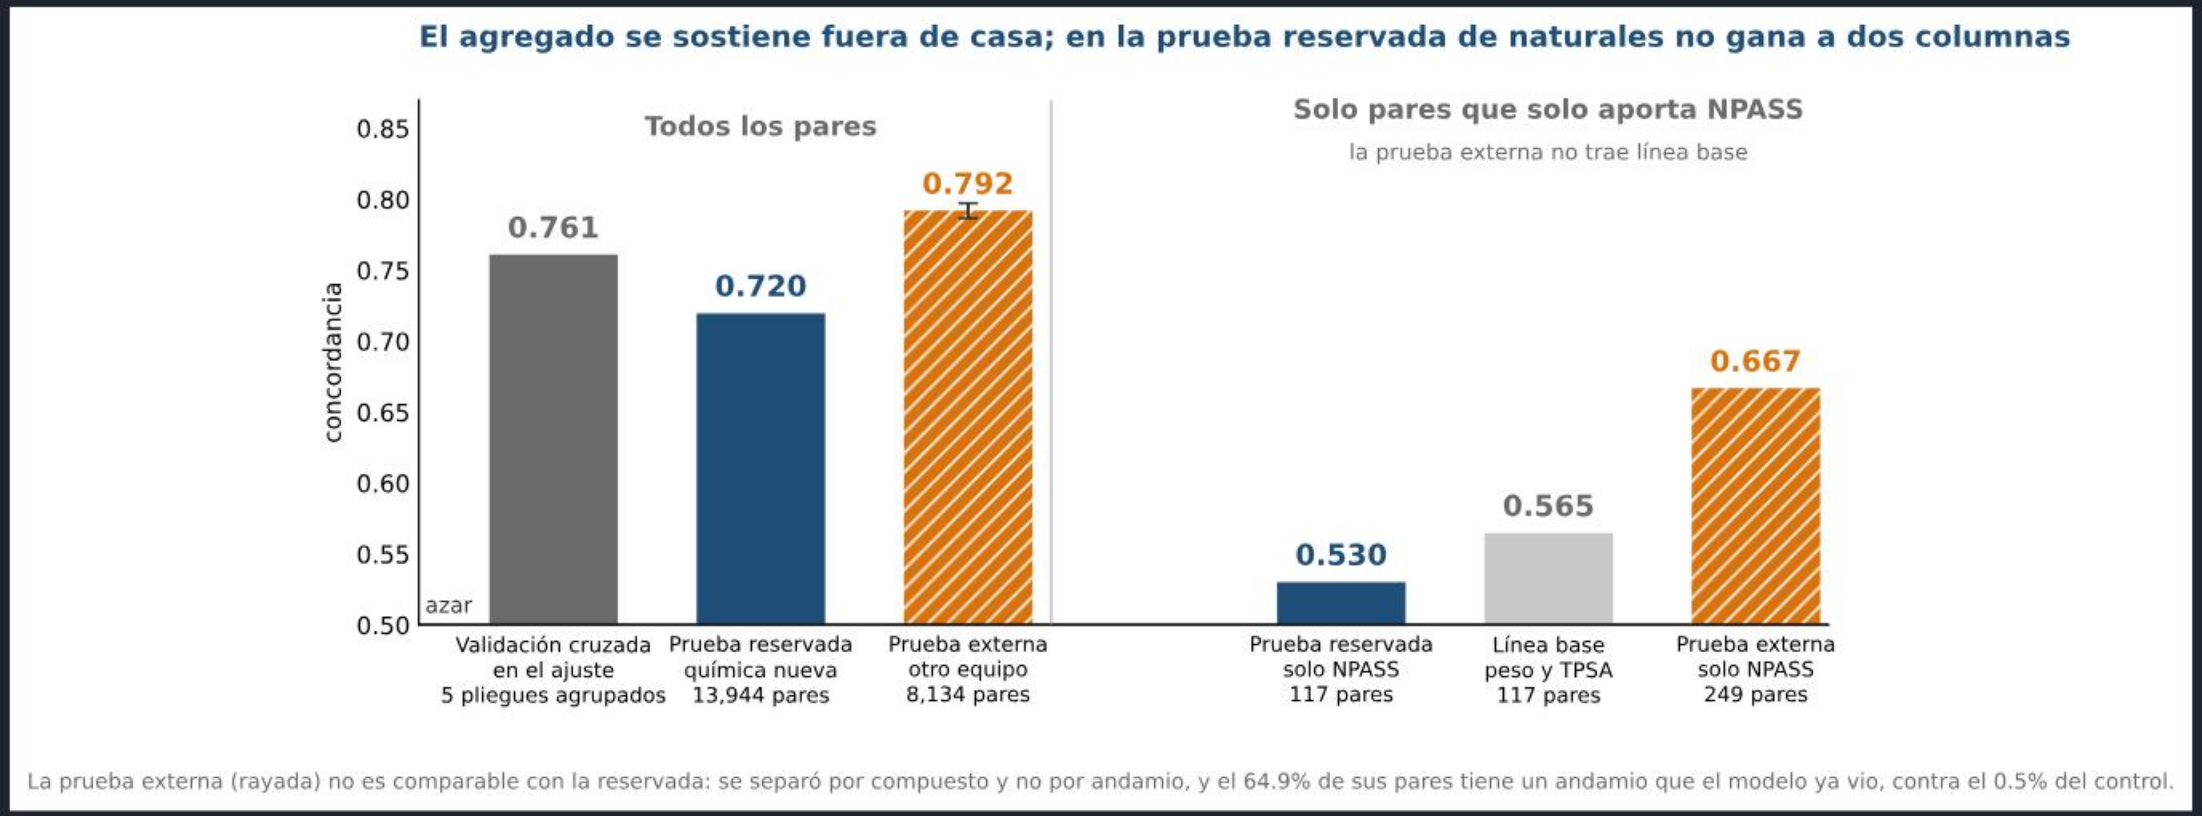
Concordancia	
Validación cruzada	0.761
Prueba reservada	**0.720**
117 pares naturales	**0.530**
Línea base de peso y TPSA	0.565

Acierta cuál de dos pares es más potente. El azar da 0.5.

Pista 4

El agregado lo domina ChEMBL. En productos naturales el orden de potencia **no está demostrado**.

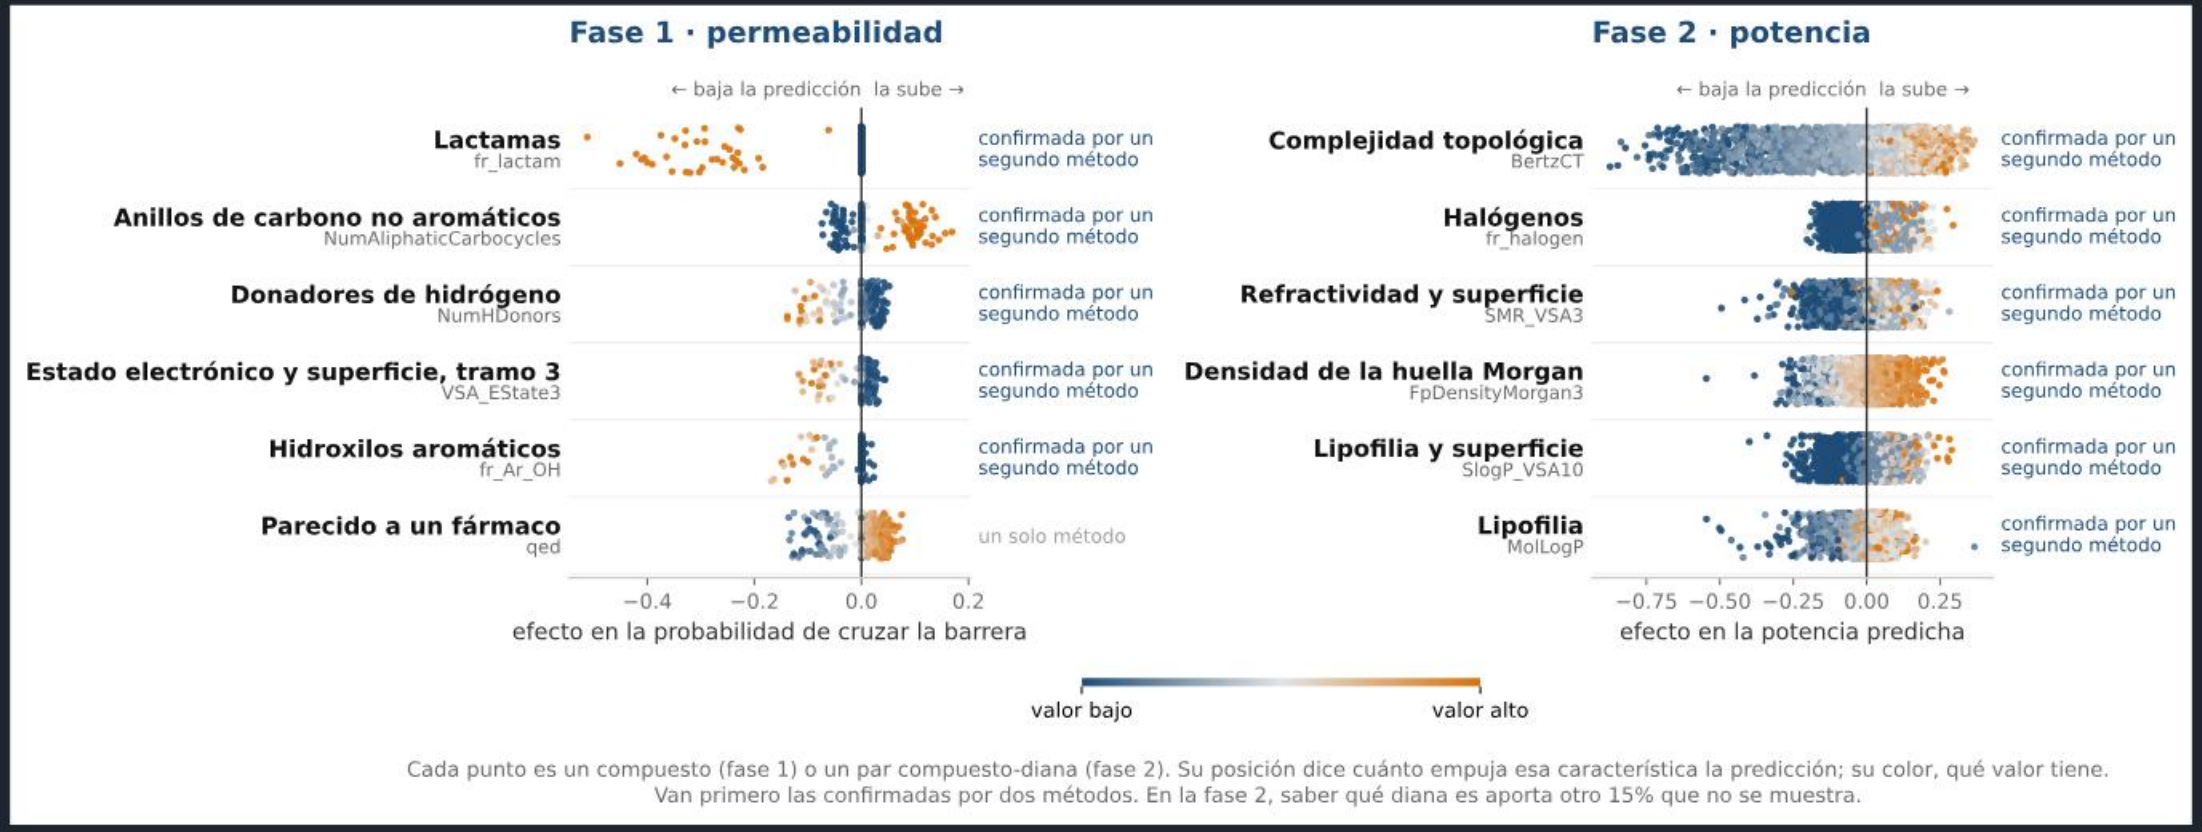
Qué mide de verdad · fase 2



La prueba externa (rayada) no es comparable con la reservada: se separó por compuesto y no por andamio, y el 64.9% de sus pares tiene un andamio que el modelo ya vio, contra el 0.5% del control.

- **La diana manda.** El enriquecimiento del `aft` ya está en el techo (1.40 con 71.4% de activos) y un control que **solo usa la diana** llega a 1.36: el orden global mide sobre todo **qué diana es**, no qué molécula.
- **La procedencia lleva señal de la etiqueta.** Un modelo que solo ve **de dónde viene** el compuesto, sin mirar la molécula, llega a 0.280 de MCC: el **65%** de lo que logra la química (0.428), en la versión de clasificación. Por eso cada métrica se reporta por procedencia.

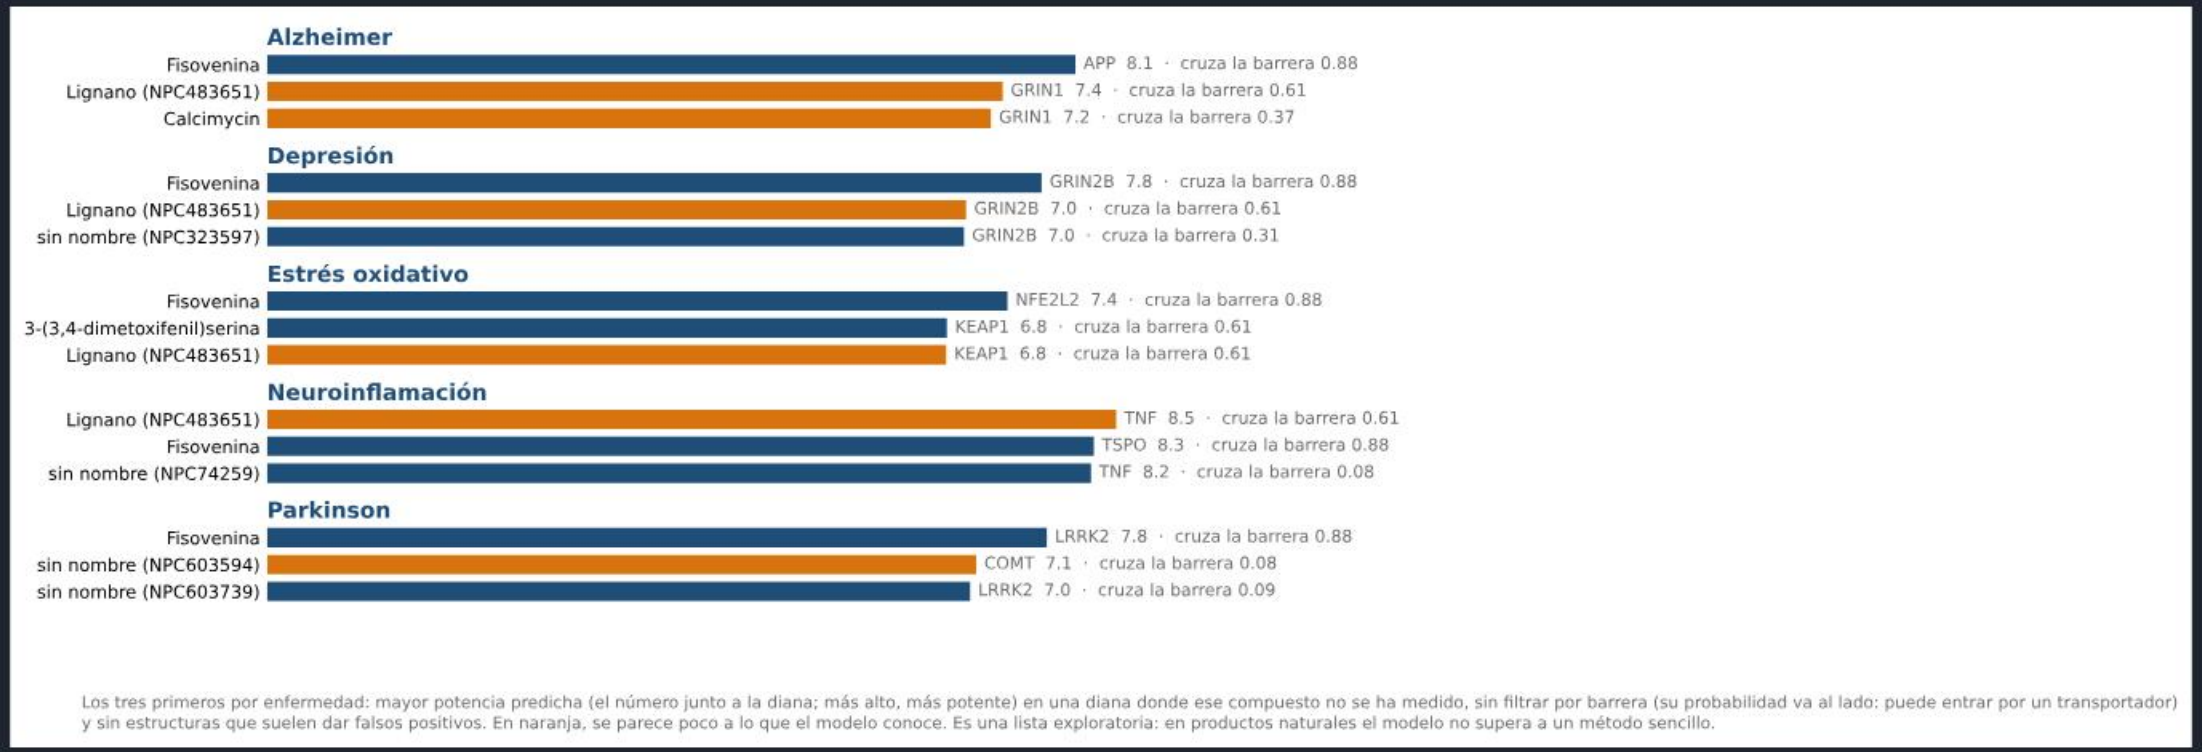
Qué características pesan en cada fase



Cada punto es un compuesto (fase 1) o un par compuesto-diana (fase 2). Su posición dice cuánto empuja esa característica la predicción; su color, qué valor tiene. Van primero las confirmadas por dos métodos. En la fase 2, saber qué diana es aporta otro 15% que no se muestra.

- **Permeabilidad:** tener lactamas (un tipo de anillo) o más grupos que ceden hidrógeno **baja** la probabilidad de cruzar la barrera.
- **Potencia:** pesa sobre todo la **complejidad de la molécula**, y es casi igual para todas las dianas. Es lo que usa el modelo, no una explicación del mecanismo.

Lo que entregamos



- **Un cuaderno** para usar los modelos con compuestos propios: da la probabilidad de cruzar la barrera, la potencia contra cada diana y un aviso si la molécula es muy distinta de lo conocido. Está en el sitio.
- **Una lista de naturales para probar primero**, por enfermedad y por diana (completa en el sitio). Son **hipótesis**, no resultados: en naturales el modelo no supera a un método sencillo.
- **Una guía** para medir si unas columnas nuevas mejoran la predicción.

Qué concluimos

- **Qué encontramos:** podemos estimar si un compuesto cruza la barrera y con qué potencia actúa sobre cada diana. Con moléculas nuevas el acierto (MCC) cae de 0.70 a 0.34 y **no sabemos explicar** buena parte de esa caída.
- **Qué no está demostrado:** en productos naturales, el orden de potencia no supera a un método sencillo (0.530 frente a 0.565). Es evidencia para priorizar, no una decisión.
- **Qué entregamos:** el cuaderno, la lista y la guía. La continuidad queda en manos de la patrocinadora y su grupo.
- **Qué sigue:** medir la potencia con muestras propias de productos naturales, y combinar las dos fases en un solo orden.

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos