Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Equipo 7 · Ingrid Pamela Ruiz Puga · Artemio Santiago Padilla Robles · José Antonio Vázquez Martínez

Maestría en Inteligencia Artificial Aplicada · TC5035.10 · Tecnológico de Monterrey

13 de noviembre de 2026

Qué buscamos

- Priorizar **compuestos naturales** con potencial neuroprotector.
- Para servir, un compuesto tiene que **llegar al cerebro** y **actuar sobre su diana**.
- Lo que producimos es *evidencia para priorizar*, no una decisión automática.

Dos preguntas, en paralelo

Fase 1

¿**Cruza la barrera** hematoencefálica?

Clasificación: permeable o no.

Fase 2

¿Con qué **potencia** actúa sobre cada una de **26 dianas**?

Regresión.

> **Nota**
>
> Pensamos **encadenarlas**. No hay datos para comprobarlo: solo **612 esqueletos** están medidos en las dos. Y un «no permeable» predicho se equivoca: descartar con él perdería candidatos reales.

Dos números que no cuadran

Validación

0.70

MCC

→

Prueba reservada

0.34

MCC

Fase 1, permeabilidad, con el modelo final. El **MCC** resume aciertos y errores de las dos clases, y 0 es azar.

La fase 2 se cae de otro modo. La concordancia apenas baja, de 0.76 a 0.72, pero en los **117 pares** que solo tiene la base de productos naturales llega a **0.53**, bajo una línea base de peso y superficie polar (0.565).

¿Por qué se cae a la mitad una, y la otra solo donde importa? El resto de la charla busca la respuesta.

Los datos

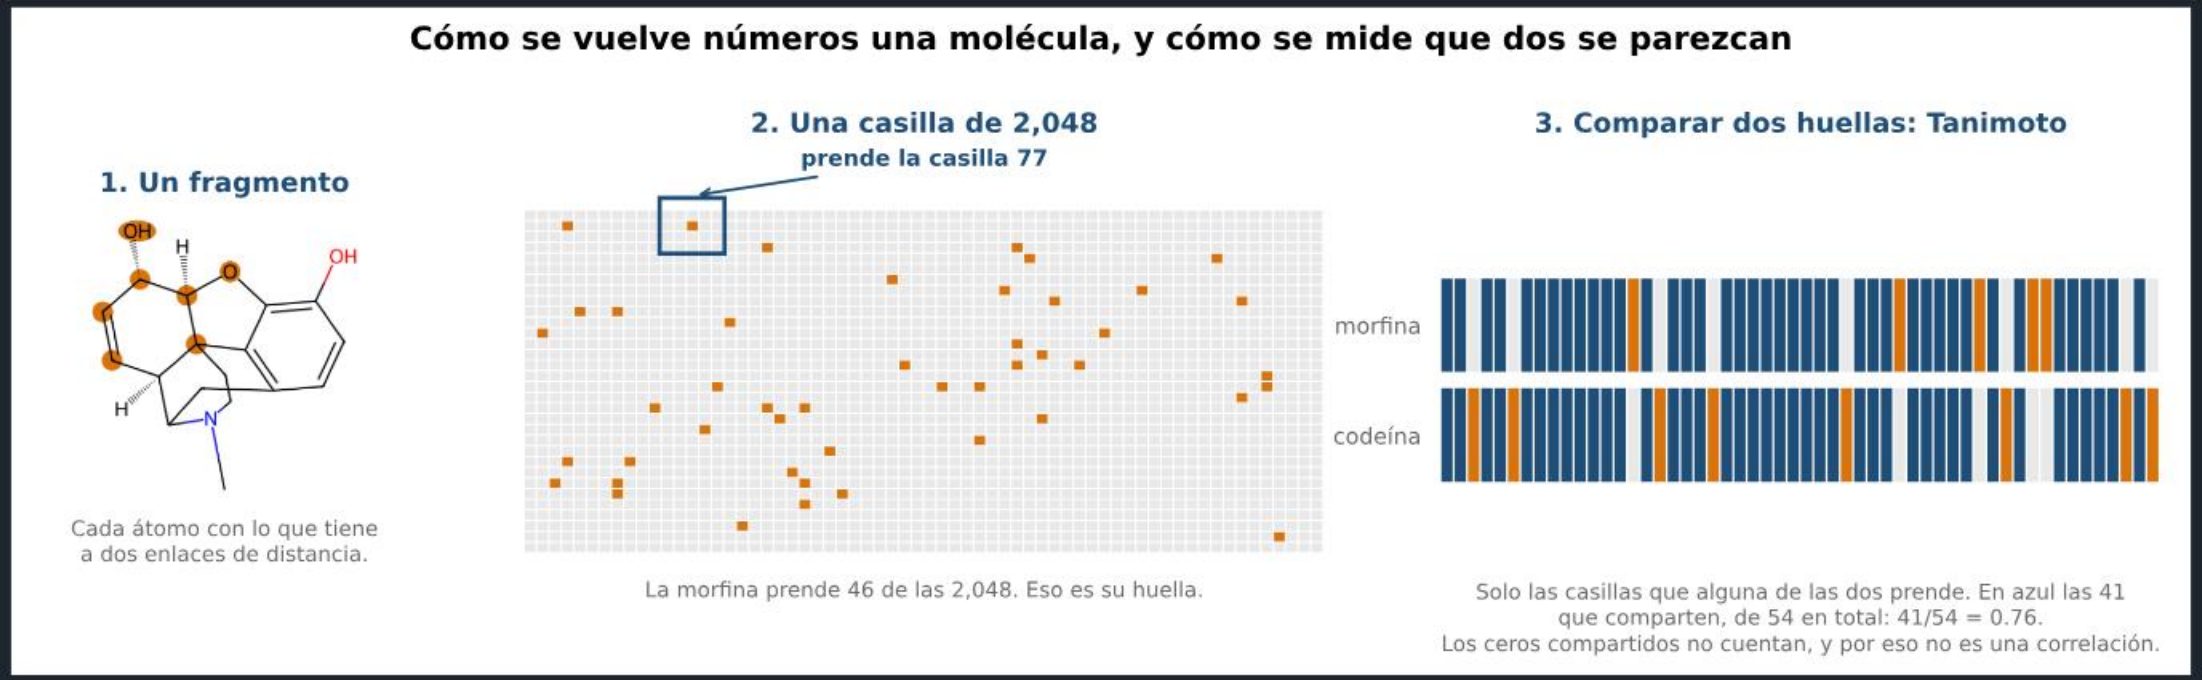
Fase 1 · permeabilidad

- **7,805** compuestos con clase; **63.5%** permeables (65.0% en las filas de ajuste).
- **1,499** reservados para la prueba.

Fase 2 · potencia

- **202,647** registros de tres fuentes: ChEMBL, NPASS y CMAUP.
- Guardamos el **intervalo de potencia**, no una etiqueta: el corte de «activo» puede cambiar.

Cómo se vuelve números una molécula

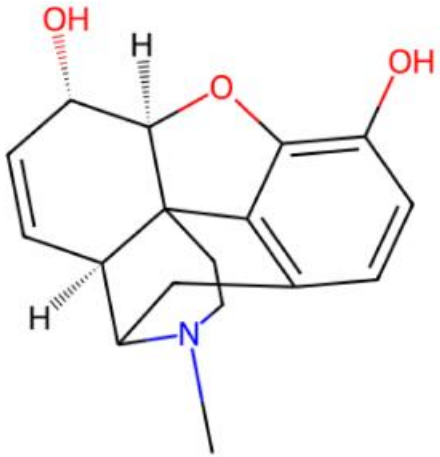


- **Descriptores:** propiedades que calcula RDKit (peso, superficie polar, donadores de hidrógeno y doscientas más). Quedan **151**: fuera las casi constantes y las redundantes, elegidas sobre los **valores crudos** para que la selección no cambie si cambia el escalado.
- **Huellas:** las medimos aparte, y ayudan en la fase 2 y en la fase 1 no (respaldo). Los dos modelos finales corren sobre descriptores; en la fase 2 se suma la diana.

Cómo medimos sin engañarnos

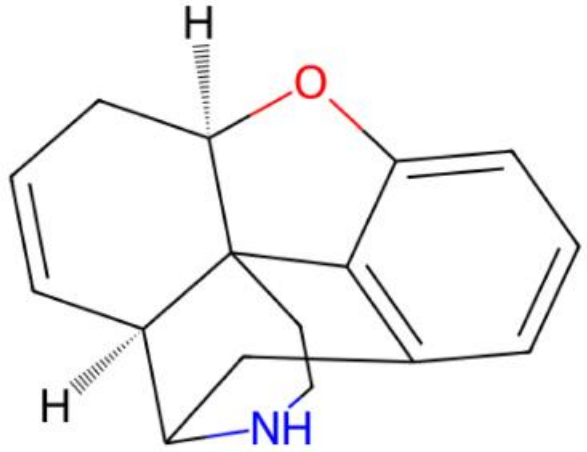
Dos formas de agrupar la misma molécula, y ninguna contiene a la otra

La molécula



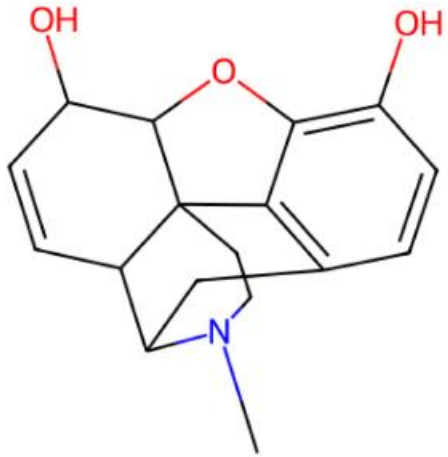
Morfina, un alcaloide natural que sí llega al cerebro. Entra como SMILES, una cadena de texto.

Su andamio (Bemis-Murcko)



Los anillos, sin las cadenas colgantes. Lo comparten 7 compuestos del archivo (codeína, heroína, nalorfina…): 39 registros, y los 39 son BBB+. Si cae entero de un lado, al modelo le basta con reconocerlo.

Su esqueleto de conectividad



La misma molécula sin estereoquímica. Junta los 8 registros de la morfina, que el andamio repartiría en 6 grupos. Por eso agrupamos por los dos.

- **Agrupamos por andamio y por esqueleto, nunca al azar.** Quedan **1,048 grupos**. Partir al azar da cifras demasiado optimistas (Sheridan, 2013): con el `svm_rbf`, el MCC baja de 0.752 con pliegues al azar a 0.702 al agrupar.
- **Qué medimos, y qué dice cada medida. Fase 1**, clasificar: el **MCC** resume en un número los aciertos y los errores de las dos clases, y el **AUROC** dice si pone a los permeables por encima sin fijar ningún corte. También el AUPRC. **Fase 2**, predecir potencia: la **concordancia**, que mide si ordena bien los pares, donde el azar da 0.5.
- Cada prueba se **planteó antes** de ver su resultado, y la prueba reservada solo sirvió **para medir**.

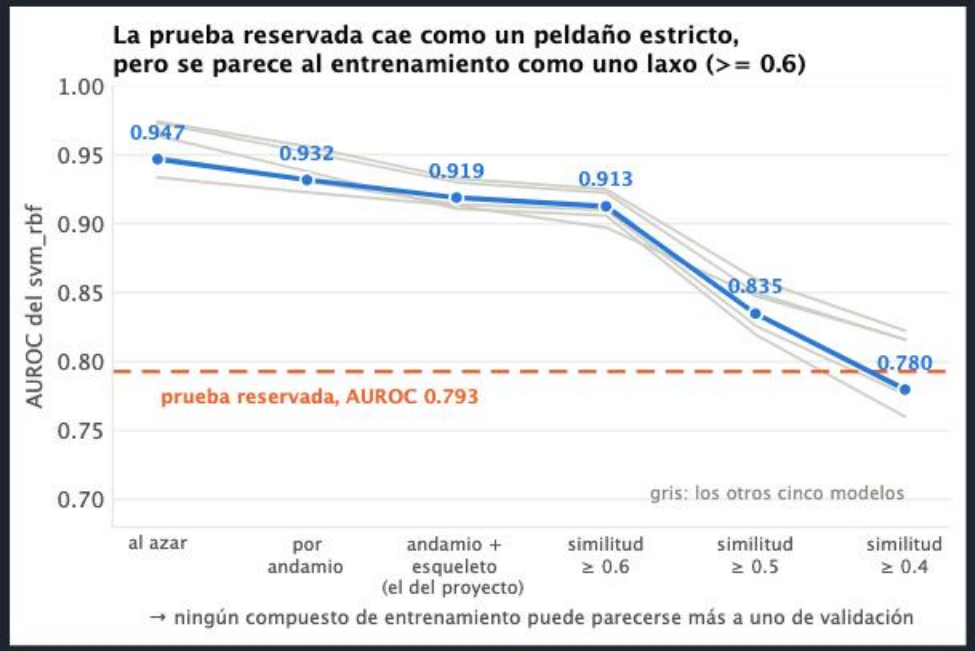
El modelo no es la palanca

- **Permeabilidad: probamos once modelos y todos valen casi lo mismo.** Del mejor al peor hay **4.2 puntos** de MCC, y el mejor **iguala** al modelo sencillo de referencia (0.70) sin superarlo.
- **Potencia: pasa igual.** De los nueve modelos, los siete que compiten de verdad caben en **0.015** de concordancia. Pedirle química más nueva cuesta **siete veces más**.

Pista 1

No es el modelo.

La escalera de semejanza · fase 1



Cómo se parte	Parecido al vecino	AUROC	MCC
Al azar	0.90	0.947	**0.752**
Por andamio	0.75	0.932	0.721
Andamio + esqueleto	0.50	0.919	0.702
Tanimoto < 0.6	0.42	0.913	0.688
Tanimoto < 0.5	0.33	0.835	0.486
Tanimoto < 0.4	0.28	0.780	**0.419**

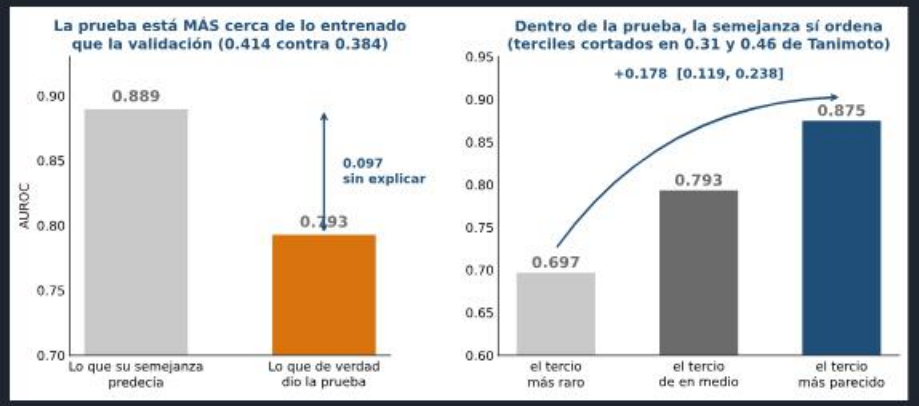
33 puntos de MCC y 17 de AUROC, contra **4.2** de MCC y **2.2** de AUROC entre los once modelos.

En azul el `svm_rbf`, el modelo que entregamos; en gris los otros cinco.

Pista 2

Importa qué tan nueva es la molécula.

La semejanza ordena, pero no clasifica · fase 1



La prueba es **más familiar** que la validación, no más nueva. Debería haber dado 0.889 y dio 0.793.

En los de equivalente natural exacto rinde parecido: AUROC **0.780** en 446 compuestos, contra 0.793 en toda la prueba. Ahí la semejanza también ordena, pero con 446 no se distingue: +0.086, con el cero dentro.

Tres formas de darle más química rara, las tres con la **regla escrita antes de correr**:

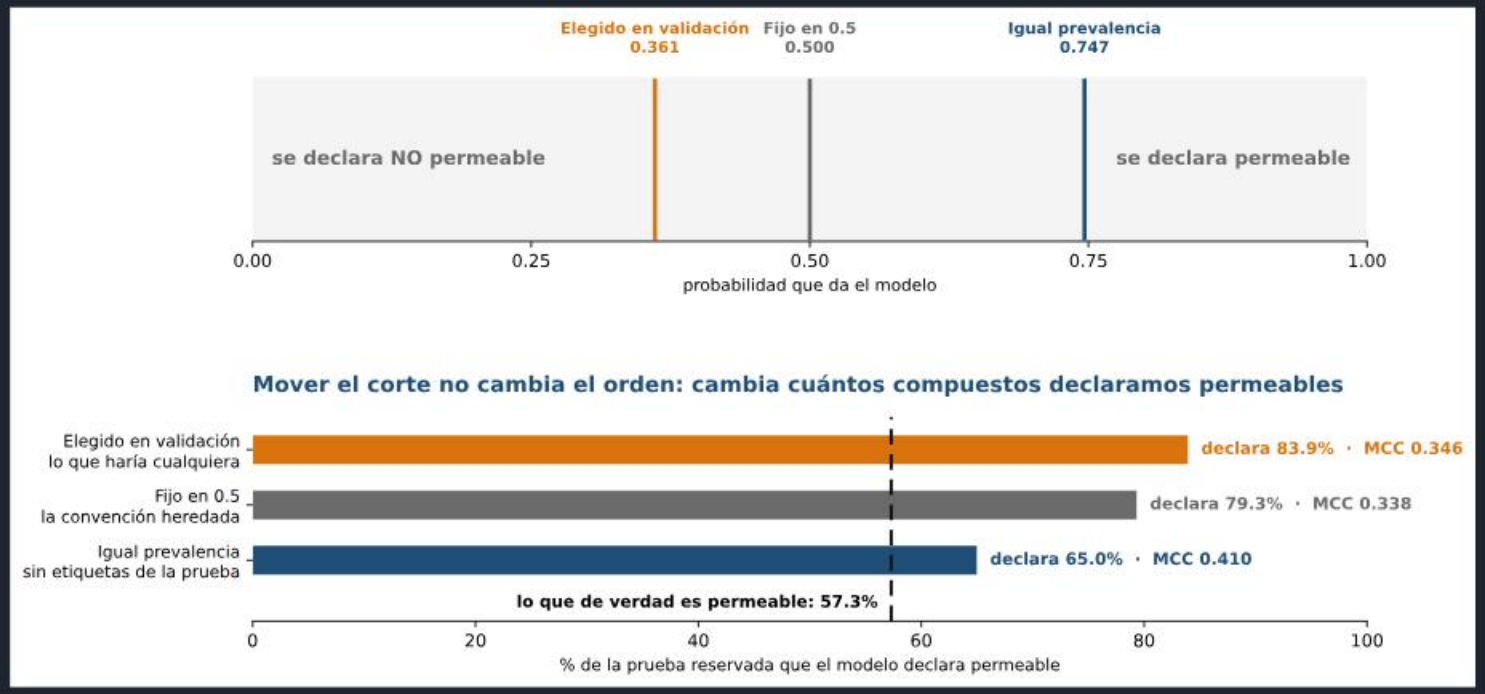
Qué le dimos	Qué pasó
Más peso a las filas raras que ya tenía	**−0.0005**; los mismos pesos al azar mueven igual
Filas raras de la prueba, devolviendo comunes	MCC +0.035 pero AUROC **+0.002**: movió el corte
Otra composición del ajuste, mismo tamaño	**−0.060** con el 25%; con el 75% da igual

Y de paso, lo más útil: con el mismo modelo y sin reentrenar, las filas **comunes** se miden con AUROC **0.94** y las **raras** con **0.68**.

Pista 3

La semejanza dice **qué compuestos** serán más difíciles, no **cuánto** rinde el conjunto: ordena, pero no clasifica. Y recomponer la prueba cambia el número que se reporta, no lo que el modelo sabe.

El corte explica una parte, no la caída · fase 1



- El corte en **0.5** es la convención que trae la librería, no una decisión: con él el modelo declara permeable al **79.3%** de la prueba, cuando lo real es **57.3%**.
- Igualar la tasa declarada a una prevalencia supuesta sube el MCC de **0.34 a 0.41**, sin usar etiquetas de la prueba. Y supusimos la prevalencia del ajuste, 65%, cuando era 57%: aguanta el error.
- Elegir el corte con validación **no sirve** (+0.0065): lo mueve hacia abajo, y la prueba lo necesitaba hacia arriba.

Qué explica la caída: el corte explica una parte y se puede corregir: recupera 0.07 de los 0.36 de MCC que perdimos. El resto es real: el orden también cayó, 12.6 puntos de AUROC (0.919 a 0.793).

El modelo de potencia · fase 2



La misma escalera: de 0.807 por molécula a 0.695 con semejanza menor de 0.6. En gris, solo los pares de NPASS.

Predice la **potencia de cada par compuesto-diana**, no una clase. El `aft` aprende de las mediciones **censuradas**, las que solo dicen «menos potente que esto», y que los otros nueve modelos descartan.

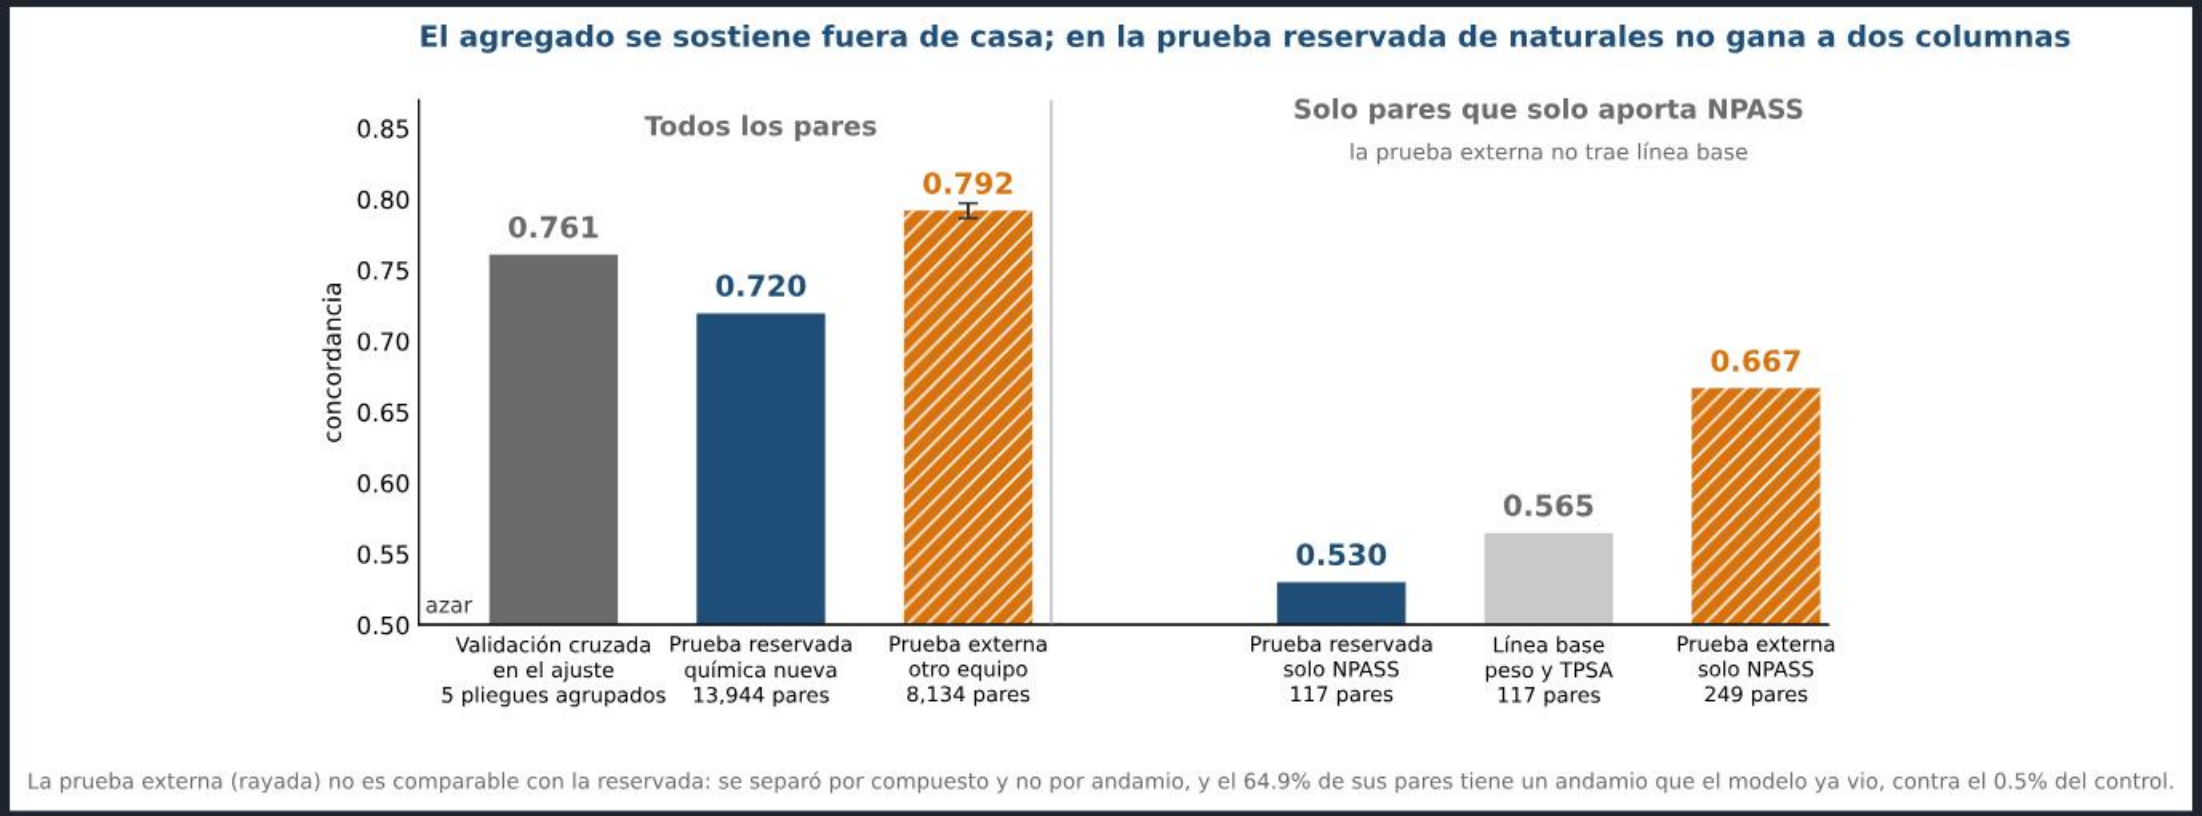
Concordancia	
Validación cruzada	0.761
Prueba reservada	**0.720**
117 pares naturales	**0.530**
Línea base de peso y TPSA	0.565

Acierta cuál de dos pares es más potente. El azar da 0.5.

Pista 4

El agregado lo domina ChEMBL. En productos naturales el orden de potencia **no está demostrado**.

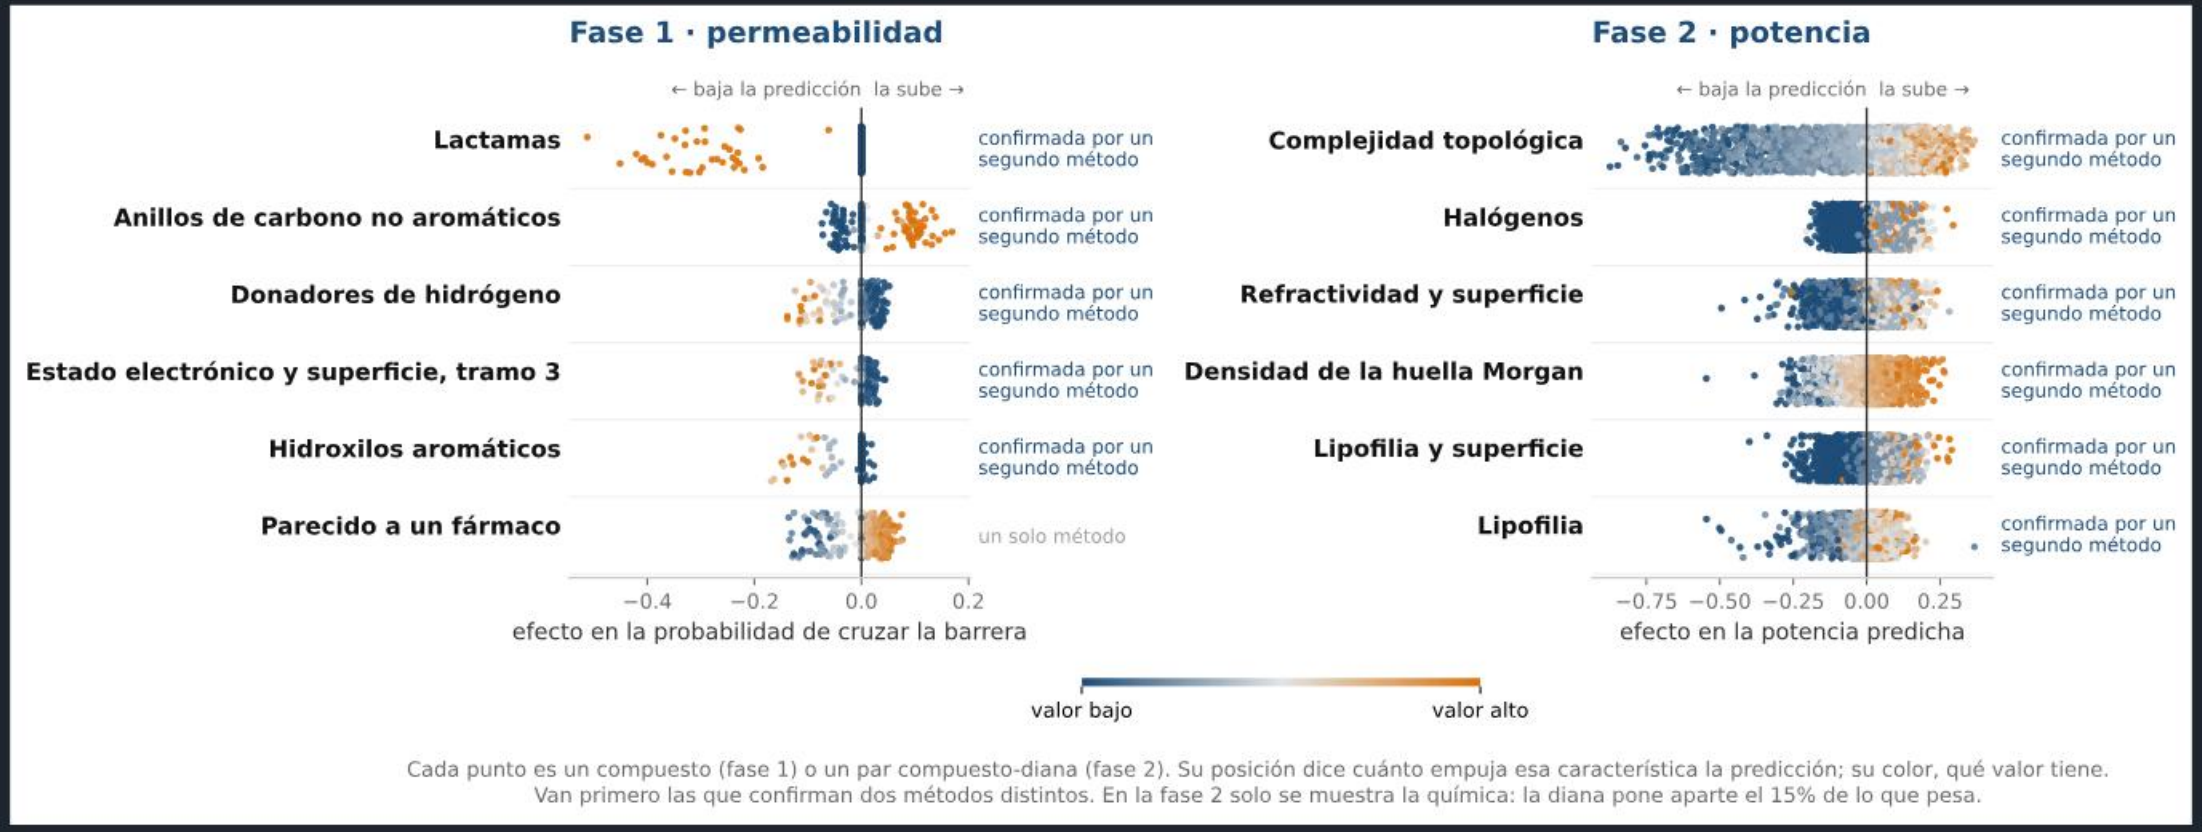
Qué mide de verdad · fase 2



La prueba externa (rayada) no es comparable con la reservada: se separó por compuesto y no por andamio, y el 64.9% de sus pares tiene un andamio que el modelo ya vio, contra el 0.5% del control.

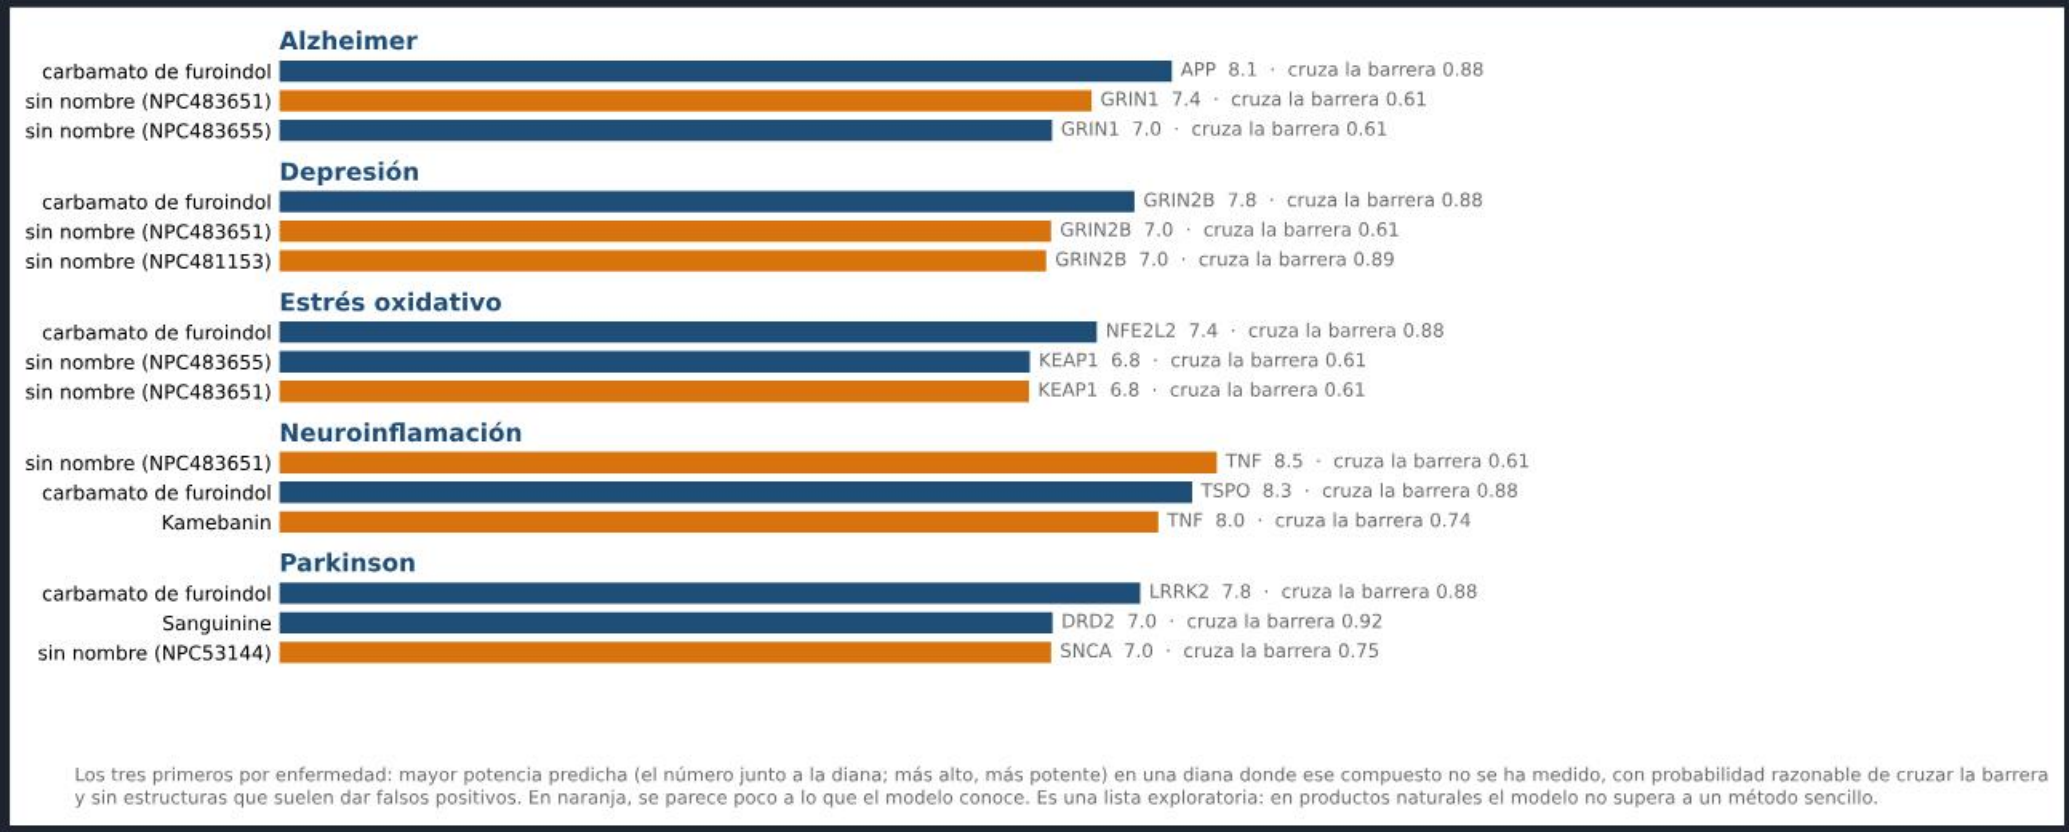
- **La diana manda.** El enriquecimiento del `aft` ya está en el techo (1.40 con 71.4% de activos) y un control que **solo usa la diana** llega a 1.36: el orden global mide sobre todo **qué diana es**, no qué molécula.
- **La procedencia lleva señal de la etiqueta.** Un modelo que solo ve **de dónde viene** el compuesto, sin mirar la molécula, llega a 0.280 de MCC: el **65%** de lo que logra la química (0.428), en la versión de clasificación. Por eso cada métrica se reporta por procedencia.

Qué características pesan en cada fase



- **Permeabilidad:** tener lactamas (un tipo de anillo) o más grupos que ceden hidrógeno **baja** la probabilidad de cruzar la barrera.
- **Potencia:** pesa sobre todo la **complejidad de la molécula**, y es casi igual para todas las dianas. Es lo que usa el modelo, no una explicación del mecanismo.

Lo que entregamos



- **Un cuaderno** para usar los modelos con compuestos propios: da la probabilidad de cruzar la barrera, la potencia contra cada diana y un aviso si la molécula es muy distinta de lo conocido. Está en el sitio.
- **Una lista de naturales para probar primero**, por enfermedad y por diana (completa en el sitio). Son **hipótesis**, no resultados: en naturales el modelo no supera a un método sencillo.
- **Una guía** para medir si unas columnas nuevas mejoran la predicción.

Qué concluimos

- **Qué encontramos:** podemos estimar si un compuesto cruza la barrera y con qué potencia actúa sobre cada diana. Con moléculas nuevas el acierto (MCC) cae de 0.70 a 0.34 y **no sabemos explicar** buena parte de esa caída.
- **Qué no está demostrado:** en productos naturales, el orden de potencia no supera a un método sencillo (0.530 frente a 0.565). Es evidencia para priorizar, no una decisión.
- **Qué entregamos:** el cuaderno, la lista y la guía. La continuidad queda en manos de la patrocinadora y su grupo.
- **Qué sigue:** medir la potencia con muestras propias de productos naturales, y combinar las dos fases en un solo orden.

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos