Tecnológico de Monterrey | Posgrados

Maestría en Inteligencia Artificial Aplicada (MNA)

Presentación del Proyecto Integrador

Bioactive

Cuánto confiar en una predicción depende de la molécula, no del modelo

Presenta(n):

- Ingrid Pamela Ruiz Puga
- Artemio Santiago Padilla Robles
- José Antonio Vázquez Martínez

Asesora: Dra. Grettel Barceló Alonso

Patrocinadora: Dra. Mariana Martínez Ávila

13 de noviembre de 2026

Tecnológico de Monterrey | Posgrados

Qué buscamos

- Priorizar **compuestos naturales** con potencial neuroprotector.
- Para servir, un compuesto tiene que **llegar al cerebro** y **actuar sobre su diana**.
- Lo que producimos es *evidencia para priorizar*, no una decisión automática.

Tecnológico de Monterrey | Posgrados

Dos preguntas, en paralelo

Fase 1

¿**Cruza la barrera** hematoencefálica?

Clasificación: permeable o no.

Fase 2

¿Con qué **potencia** actúa sobre cada una de **26 dianas**?

Regresión.

> **Nota**
>
> Pensamos **encadenarlas**. No hay datos para comprobarlo: solo **612 esqueletos** están medidos en las dos. Y un «no permeable» predicho se equivoca: descartar con él perdería candidatos reales.

Tecnológico de Monterrey | Posgrados

Dos números que no cuadran

Validación

0.70

MCC

→

Prueba reservada

0.34

MCC

Fase 1, permeabilidad, con el modelo final. El **MCC** resume aciertos y errores de las dos clases, y 0 es azar.

La fase 2 se cae de otro modo. La concordancia apenas baja, de 0.76 a 0.72, pero en los **117 pares** que solo tiene la base de productos naturales llega a **0.53**, bajo una línea base de peso y superficie polar (0.565).

¿Por qué se cae a la mitad una, y la otra solo donde importa? El resto de la charla busca la respuesta.

Tecnológico de Monterrey | Posgrados

Los datos

Fase 1 · permeabilidad

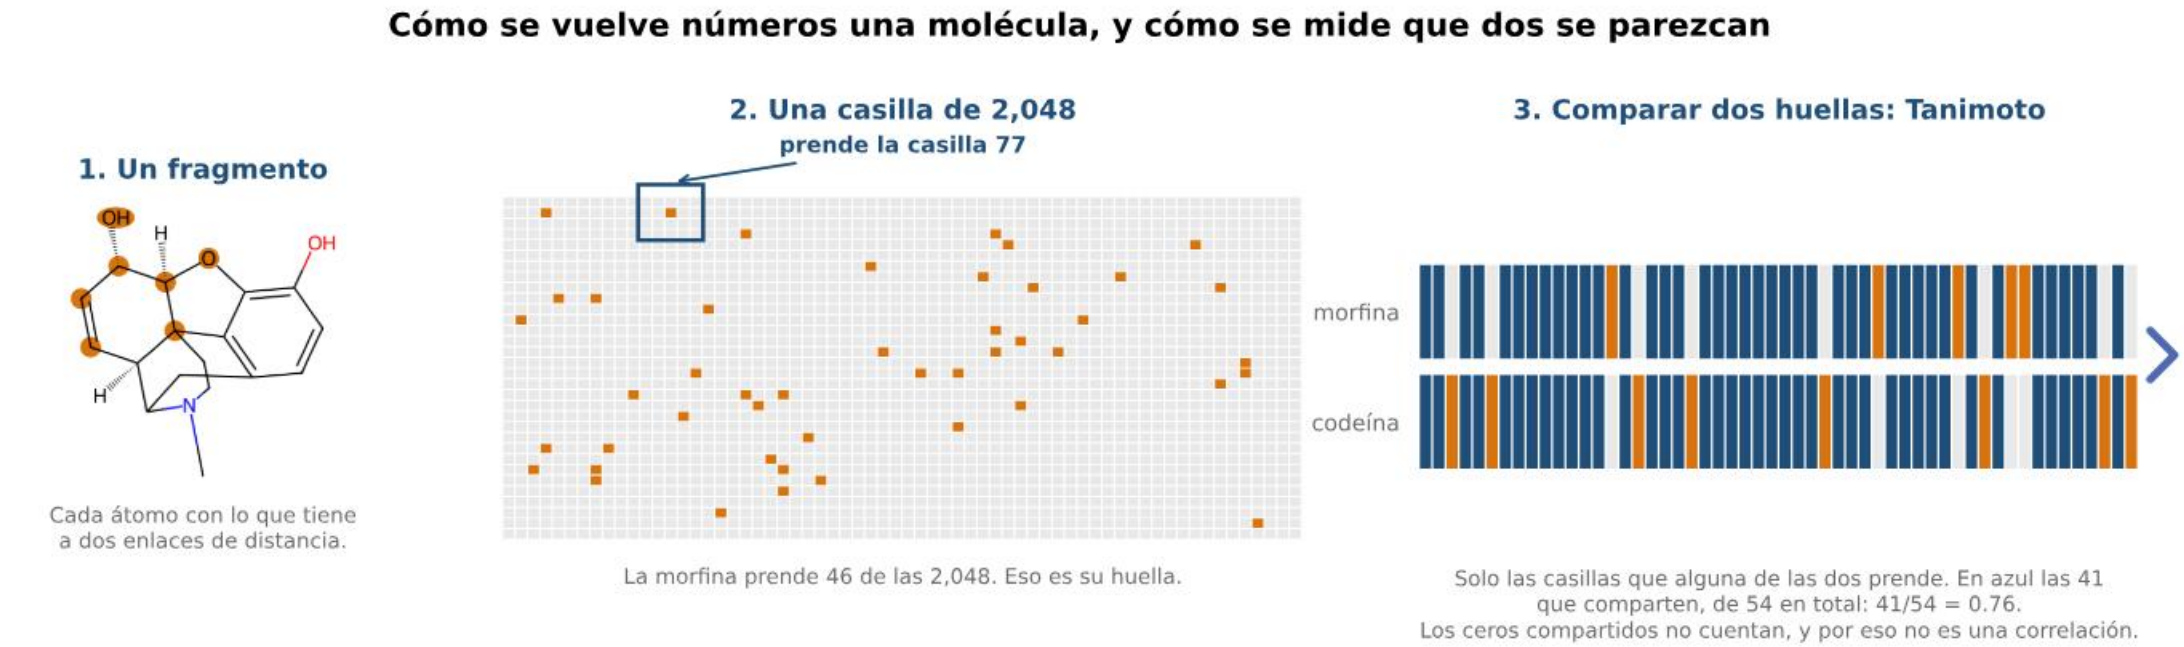
- **7,805** compuestos con clase; **63.5%** permeables (65.0% en las filas de ajuste).
- **1,499** reservados para la prueba.

Fase 2 · potencia

- **202,647** registros de tres fuentes: ChEMBL, NPASS y CMAUP.
- Guardamos el **intervalo de potencia**, no una etiqueta: el corte de «activo» puede cambiar.

Tecnológico de Monterrey | Posgrados

Cómo se vuelve números una molécula



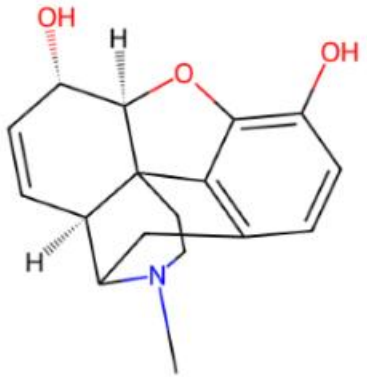
- **Descriptores:** propiedades que calcula RDKit (peso, superficie polar, donadores de hidrógeno y doscientas más). Quedan **151**: fuera las casi constantes y las redundantes, elegidas sobre los **valores crudos** para que la selección no cambie si cambia el escalado.
- **Huellas:** las medimos aparte, y ayudan en la fase 2 y en la fase 1 no (respaldo). Los dos modelos finales corren sobre descriptores; en la fase 2 se suma la diana.

Tecnológico de Monterrey | Posgrados

Cómo medimos sin engañarnos

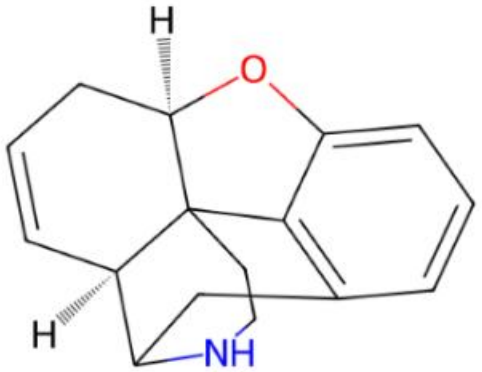
Dos formas de agrupar la misma molécula, y ninguna contiene a la otra

La molécula



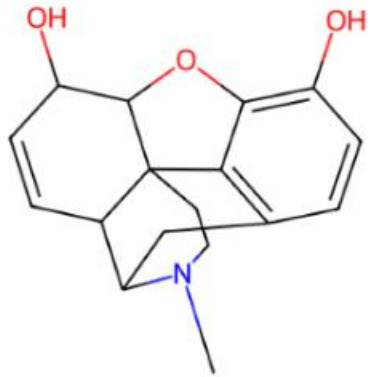
Morfina, un alcaloide natural que sí llega al cerebro. Entra como SMILES, una cadena de texto.

Su andamio (Bemis-Murcko)



Los anillos, sin las cadenas colgantes. Lo comparten 7 compuestos del archivo (codeína, heroína, nalorfina…): 39 registros, y los 39 son BBB+. Si cae entero de un lado, al modelo le basta con reconocerlo.

Su esqueleto de conectividad



La misma molécula sin estereoquímica. Junta los 8 registros de la morfina, que el andamio repartiría en 6 grupos. Por eso agrupamos por los dos.

- **Agrupamos por andamio y por esqueleto, nunca al azar.** Quedan **1,048 grupos**. Partir al azar da cifras demasiado optimistas (Sheridan, 2013): con el `svm_rbf`, el MCC baja de 0.752 con pliegues al azar a 0.702 al agrupar.
- **Qué medimos, y qué dice cada medida. Fase 1**, clasificar: el **MCC** resume en un número los aciertos y los errores de las dos clases, y el **AUROC** dice si pone a los permeables por encima sin fijar ningún corte. También el AUPRC. **Fase 2**, predecir potencia: la **concordancia**, que mide si ordena bien los pares, donde el azar da 0.5.
- Cada prueba se **planteó antes** de ver su resultado, y la prueba reservada solo sirvió **para medir**.

Tecnológico de Monterrey | Posgrados

El modelo no es la palanca

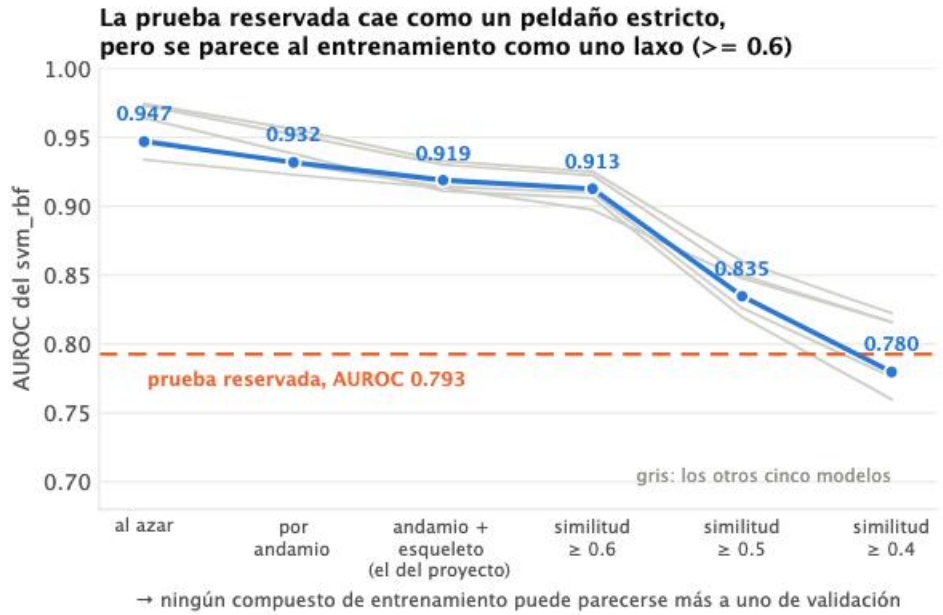
- **Permeabilidad: probamos once modelos y todos valen casi lo mismo.** Del mejor al peor hay **4.2 puntos** de MCC, y el mejor **iguala** al modelo sencillo de referencia (0.70) sin superarlo.
- **Potencia: pasa igual.** De los nueve modelos, los siete que compiten de verdad caben en **0.015** de concordancia. Pedirle química más nueva cuesta **siete veces más**.

Pista 1

No es el modelo.

Tecnológico de Monterrey | Posgrados

La escalera de semejanza · fase 1



Cómo se parte	Parecido al vecino	AUROC	MCC
Al azar	0.90	0.947	**0.752**
Por andamio	0.75	0.932	0.721
Andamio + esqueleto	0.50	0.919	0.702
Tanimoto < 0.6	0.42	0.913	0.688
Tanimoto < 0.5	0.33	0.835	0.486
Tanimoto < 0.4	0.28	0.780	**0.419**

33 puntos de MCC y 17 de AUROC, contra **4.2** de MCC y **2.2** de AUROC entre los once modelos.

En azul el `svm_rbf`, el modelo que entregamos; en gris los otros cinco.

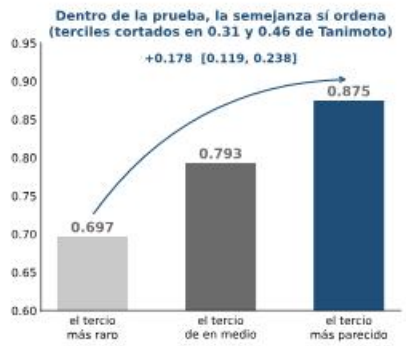
Pista 2

Importa qué tan nueva es la molécula.

Tecnológico de Monterrey | Posgrados

La semejanza ordena, pero no clasifica · fase 1





La prueba es **más familiar** que la validación, no más nueva. Debería haber dado 0.889 y dio 0.793.

En los de equivalente natural exacto rinde parecido: AUROC **0.780** en 446 compuestos, contra 0.793 en toda la prueba. Ahí la semejanza también ordena, pero con 446 no se distingue: +0.086, con el cero dentro.

Tres formas de darle más química rara, las tres con la **regla escrita antes de correr**:

Qué le dimos	Qué pasó
Más peso a las filas raras que ya tenía	**–0.0005**; los mismos pesos al azar mueven igual
Filas raras de la prueba, devolviendo comunes	MCC +0.035 pero AUROC **+0.002**: movió el corte
Otra composición del ajuste, mismo tamaño	**–0.060** con el 25%; con el 75% da igual

Y de paso, lo más útil: con el mismo modelo y sin reentrenar, las filas **comunes** se miden con AUROC **0.94** y las **raras** con **0.68**.

Pista 3

La semejanza dice **qué compuestos** serán más difíciles, no **cuánto** rinde el conjunto: ordena, pero no clasifica. Y recomponer la prueba cambia el número que se reporta, no lo que el modelo sabe.

Tecnológico de Monterrey | Posgrados

El corte explica una parte, no la caída · fase 1



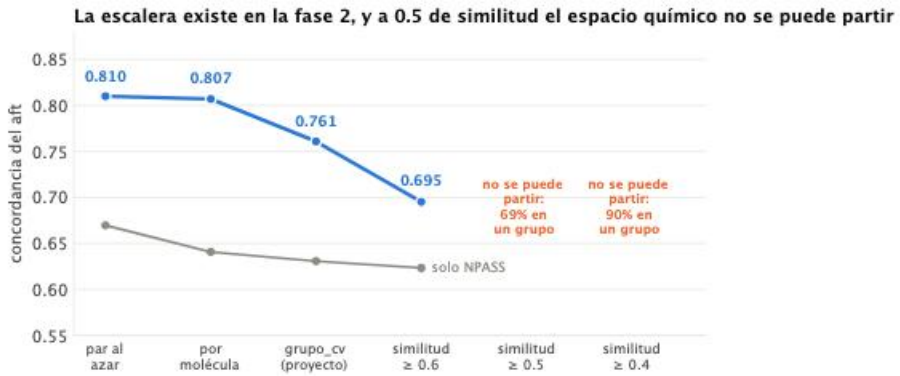


- El corte en **0.5** es la convención que trae la librería, no una decisión: con él el modelo declara permeable al **79.3%** de la prueba, cuando lo real es **57.3%**.
- Igualar la tasa declarada a una prevalencia supuesta sube el MCC de **0.34 a 0.41**, sin usar etiquetas de la prueba. Y supusimos la prevalencia del ajuste, 65%, cuando era 57%: aguanta el error.
- Elegir el corte con validación **no sirve** (+0.0065): lo mueve hacia abajo, y la prueba lo necesitaba hacia arriba.

Qué explica la caída: el corte explica una parte y se puede corregir: recupera 0.07 de los 0.36 de MCC que perdimos. El resto es real: el orden también cayó, 12.6 puntos de AUROC (0.919 a 0.793).

Tecnológico de Monterrey | Posgrados

El modelo de potencia · fase 2



La misma escalera: de 0.807 por molécula a 0.695 con semejanza menor de 0.6. En gris, solo los pares de NPASS.

Predice la **potencia de cada par compuesto-diana**, no una clase. El `aft` aprende de las mediciones **censuradas**, las que solo dicen «menos potente que esto», y que los otros nueve modelos descartan.

Concordancia	
Validación cruzada	0.761
Prueba reservada	**0.720**
117 pares naturales	**0.530**
Línea base de peso y TPSA	0.565

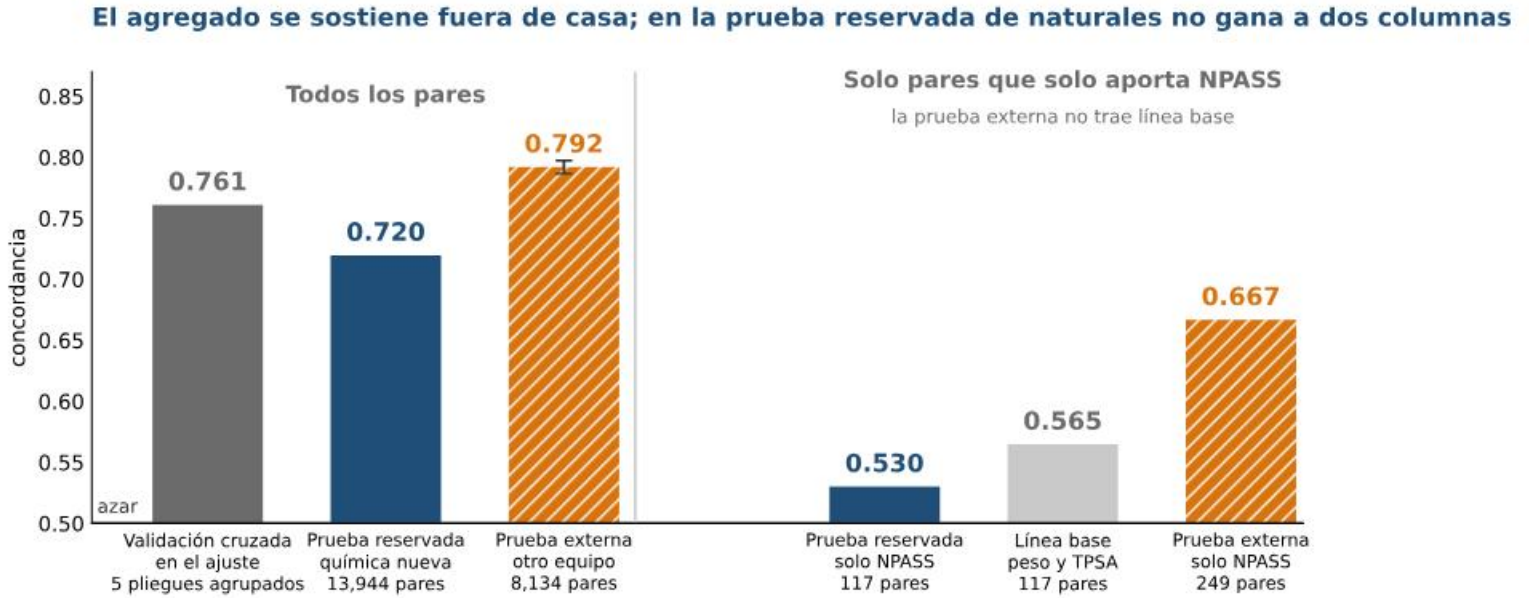
Acierta cuál de dos pares es más potente. El azar da 0.5.

Pista 4

El agregado lo domina ChEMBL. En productos naturales el orden de potencia **no está demostrado**.

Tecnológico de Monterrey | Posgrados

Qué mide de verdad · fase 2

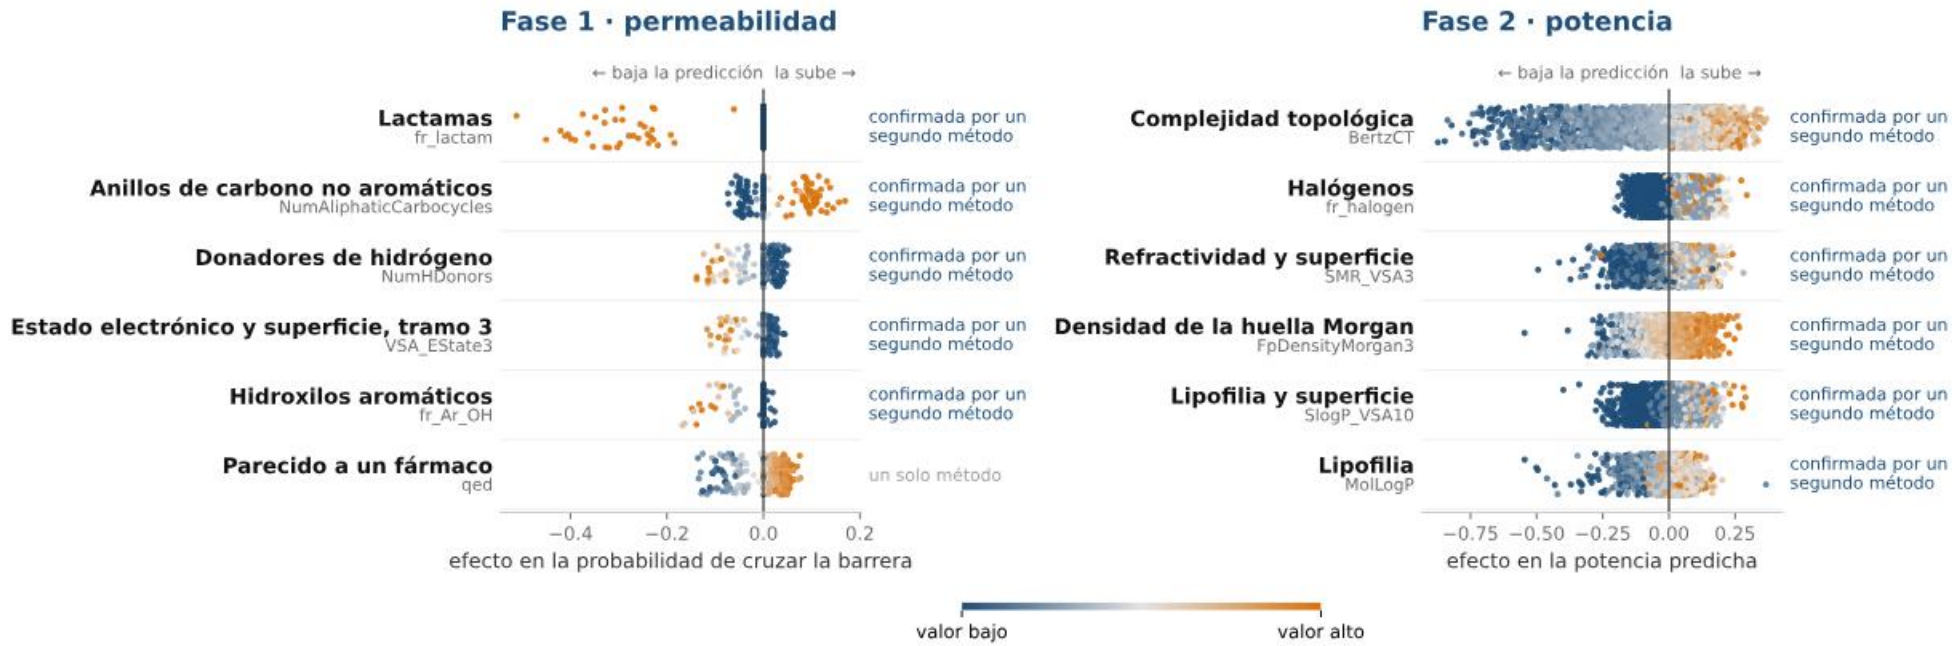


La prueba externa (rayada) no es comparable con la reservada: se separó por compuesto y no por andamio, y el 64.9% de sus pares tiene un andamio que el modelo ya vio, contra el 0.5% del control.

- **La diana manda.** El enriquecimiento del `aft` ya está en el techo (1.40 con 71.4% de activos) y un control que **solo usa la diana** llega a 1.36: el orden global mide sobre todo **qué diana es**, no qué molécula.
- **La procedencia lleva señal de la etiqueta.** Un modelo que solo ve **de dónde viene** el compuesto, sin mirar la molécula, llega a 0.280 de MCC: el **65%** de lo que logra la química (0.428), en la versión de clasificación. Por eso cada métrica se reporta por procedencia.

Tecnológico de Monterrey | Posgrados

Qué características pesan en cada fase

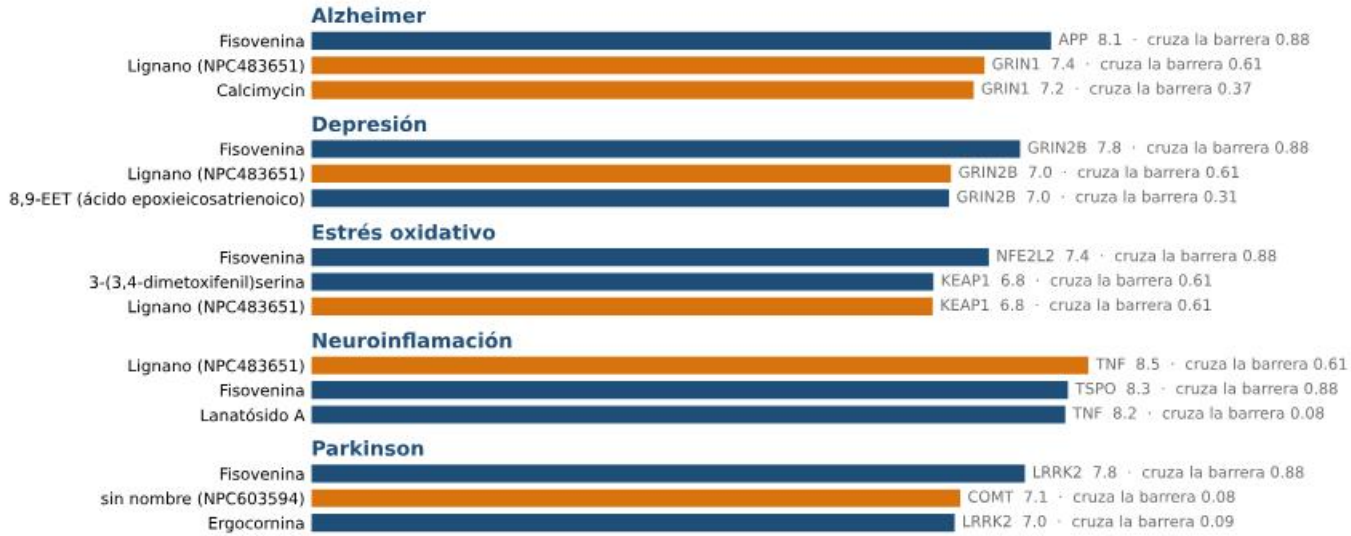


Cada punto es un compuesto (fase 1) o un par compuesto-diana (fase 2). Su posición dice cuánto empuja esa característica la predicción; su color, qué valor tiene. Van primero las confirmadas por dos métodos. En la fase 2, saber qué diana es aporta otro 15% que no se muestra.

- **Permeabilidad:** tener lactamas (un tipo de anillo) o más grupos que ceden hidrógeno **baja** la probabilidad de cruzar la barrera.
- **Potencia:** pesa sobre todo la **complejidad de la molécula**, y es casi igual para todas las dianas. Es lo que usa el modelo, no una explicación del mecanismo.

Tecnológico de Monterrey | Posgrados

Lo que entregamos



Los tres primeros por enfermedad: mayor potencia predicha (el número junto a la diana; más alto, más potente) en una diana donde ese compuesto no se ha medido, sin filtrar por barrera (su probabilidad va al lado: puede entrar por un transportador) y sin estructuras que suelen dar falsos positivos. En naranja, se parece poco a lo que el modelo conoce. Es una lista exploratoria: en productos naturales el modelo no se distingue de una línea base de peso, TPSA y diana.

- **Un cuaderno** para usar los modelos con compuestos propios: da la probabilidad de cruzar la barrera, la potencia contra cada diana y un aviso si la molécula es muy distinta de lo conocido. Está en el sitio.
- **Una lista de naturales para probar primero**, por enfermedad y por diana (completa en el sitio). Son **hipótesis**, no resultados: en naturales el modelo no se distingue de una línea base de peso, TPSA y diana.
- **Una guía** para medir si unas columnas nuevas mejoran la predicción.

Tecnológico de Monterrey | Posgrados

Qué concluimos

- **Qué encontramos:** podemos estimar si un compuesto cruza la barrera y con qué potencia actúa sobre cada diana. Con moléculas nuevas el acierto (MCC) cae de 0.70 a 0.34 y **no sabemos explicar** buena parte de esa caída.
- **Qué no está demostrado:** en productos naturales, el orden de potencia no se distingue de un modelo que solo ve peso, TPSA y diana (117 pares). Es evidencia para priorizar, no una decisión.
- **Qué entregamos:** el cuaderno, la lista y la guía. La continuidad queda en manos de la patrocinadora y su grupo.
- **Qué sigue:** medir la potencia con muestras propias de productos naturales, y combinar las dos fases en un solo orden.

Gracias

¿Preguntas?

Bioactive AI · Tec de Monterrey · Equipo 7

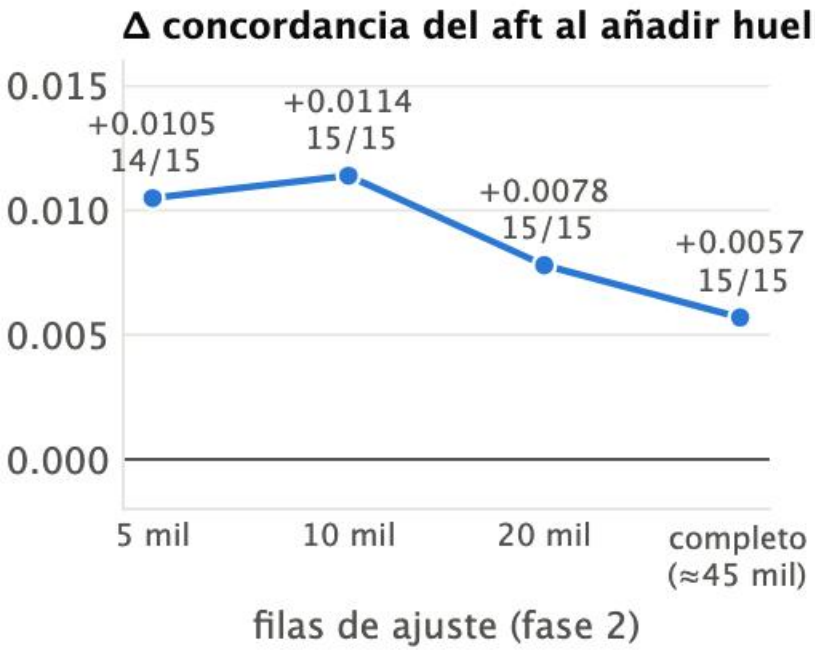
Tecnológico de Monterrey | Posgrados

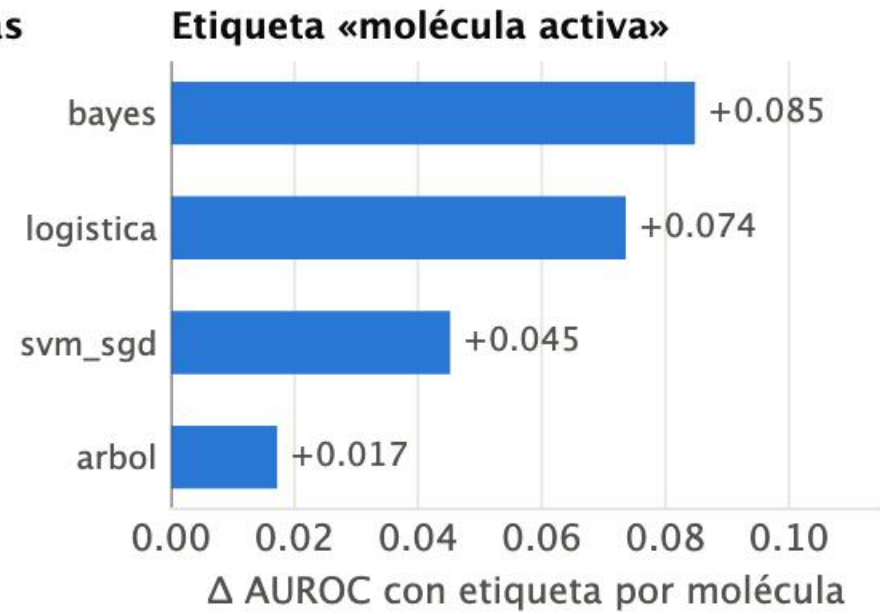
Respaldo

- Las huellas ayudan en una fase y no en la otra
- La ventaja sobre la línea base, por tercil
- El modelo de potencia en NPASS
- Cómo preparamos las columnas
- Qué pesa en cada fase: el detalle
- La diana y la química (fase 2)
- Una herramienta para medir columnas nuevas
- Cómo leer las métricas
- Ejemplo: seis compuestos conocidos

Las huellas ayudan en una fase y no en la otra

Ni el tamaño de datos ni el tipo de etiqueta explican que las huellas ayuden en la fase 2



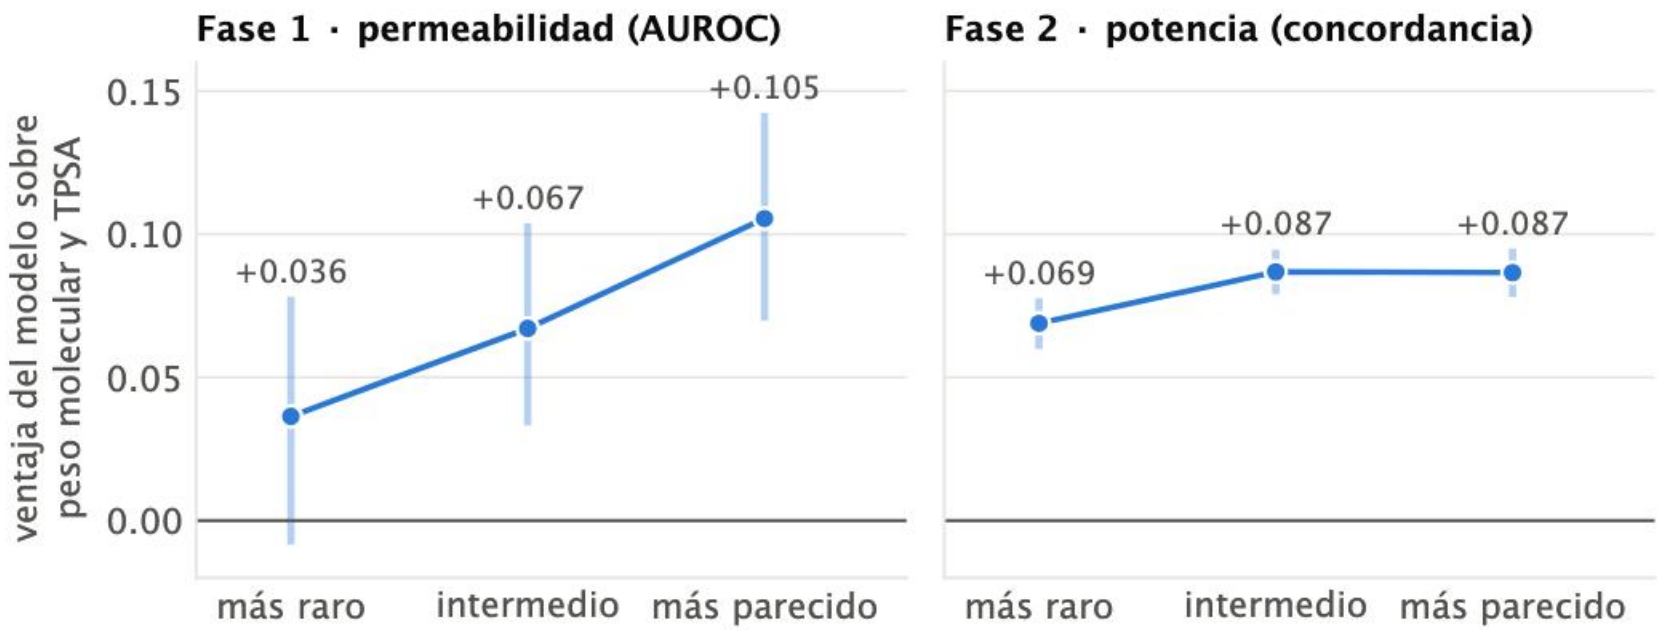


- Ayudan a cinco de seis modelos en la fase 2 y a ninguno en la fase 1.
- No es el tamaño de los datos ni el tipo de etiqueta.

Tecnológico de Monterrey | Posgrados

La ventaja sobre la línea base, por tercil

Lo raro de la química explica la caída en la fase 1, mucho menos en la fase 2

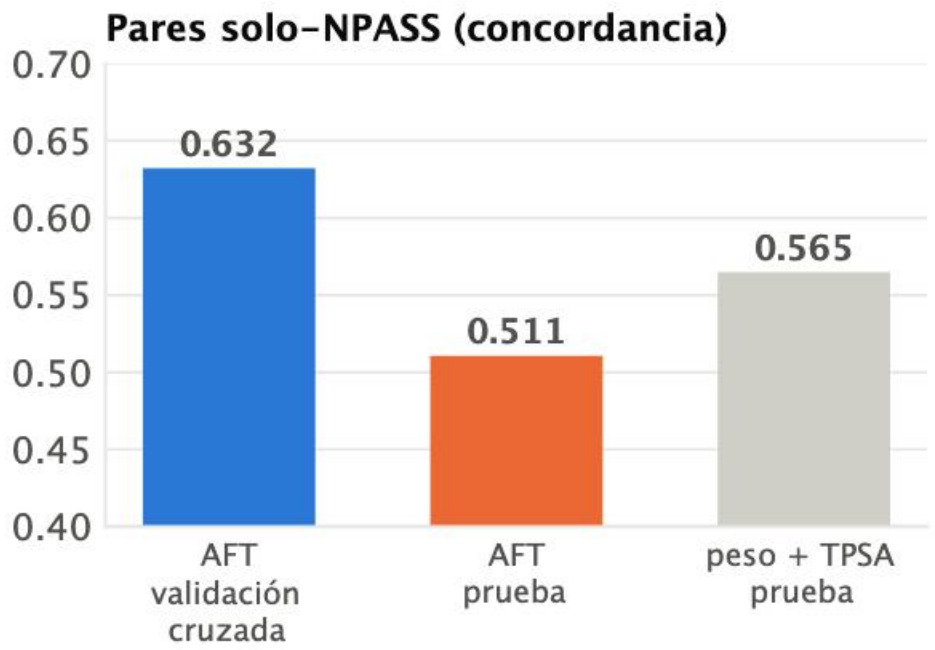


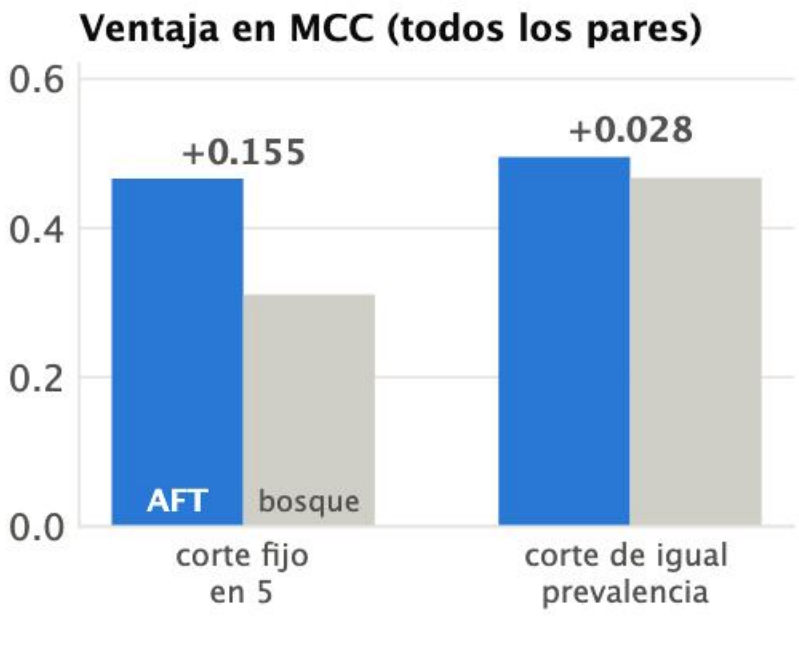
La ventaja del modelo sobre una línea base de peso y TPSA crece con lo parecido que es el compuesto: +0.036 en el tercil más raro y +0.106 en el más parecido (IC95% de la diferencia: 0.011 a 0.124). En la fase 2 la diferencia es cuatro veces menor.

Tecnológico de Monterrey | Posgrados

El modelo de potencia en NPASS

En NPASS el AFT no se sostiene en la prueba, y su ventaja en MCC era colocación





- 117 pares: concordancia 0.530 en la prueba contra 0.632 en validación (la barra de la prueba es el 0.511 del reajuste).
- Con 117 pares no hay potencia: **ni refuta ni confirma**.

Tecnológico de Monterrey | Posgrados

Cómo preparamos las columnas y qué significan las banderas

Las columnas

- Probamos **tres transformaciones** (estandarización, min–max y Yeo-Johnson): salen las mismas **151** columnas con las tres, porque la selección se hace sobre los valores crudos.
- Se quitan las **casi constantes** (un valor domina) y las **redundantes** (correlación de Spearman muy alta).
- Las huellas son bits que marcan fragmentos; el vocabulario se reaprende **dentro de cada pliegue**.

Las banderas

- **Origen**, del cruce con COCONUT: *natural exacto* (coincidencia exacta), *análogo estereoquímico* (mismo esqueleto) y *sin equivalente natural*.
- **Activo**: potencia a 10 µM o menos. Guardamos el **intervalo de potencia**, no la etiqueta, y las mediciones censuradas cuentan.
- **Grupo A a D** del archivo: indica de qué tipo de dato salió la etiqueta, **no es una escala de calidad** (en regresión, A es el de menos respaldo). Sirve para estratificar, **nunca para excluir**.

Qué pesa en cada fase: el detalle

Fase 1 · permeabilidad

- Dos métodos (permutación, que baraja una columna y mide cuánto empeora el modelo, y KernelSHAP) coinciden en seis descriptores: `fr_lactam`, `NumHDonors` (puesto 4 en ambos), `NumAliphaticCarbocycles`, `VSA_EState3`, `fr_Ar_OH` y `fr_ether`.
- **TPSA no domina**: puesto 40 por permutación y 10 por SHAP, porque comparte información con otras columnas.

Fase 2 · potencia

- TreeSHAP y permutación concuerdan (Spearman 0.93). Pesa la **diana** (`MAOA`, `MAOB`, `DRD2`, `LRRK2`, `BCHE`: el 15% de la atribución), la complejidad topológica (`BertzCT`), la lipofilia y los halógenos.
- TPSA y los donadores de hidrógeno, que dominan la permeabilidad, quedan lejos: lugares 44 y 165.

No afirmamos ningún mecanismo: son nombres de columna. Por subestructura solo salen heterociclos nitrogenados, genéricos.

Tecnológico de Monterrey | Posgrados

Fase 2: la diana y la química, por separado

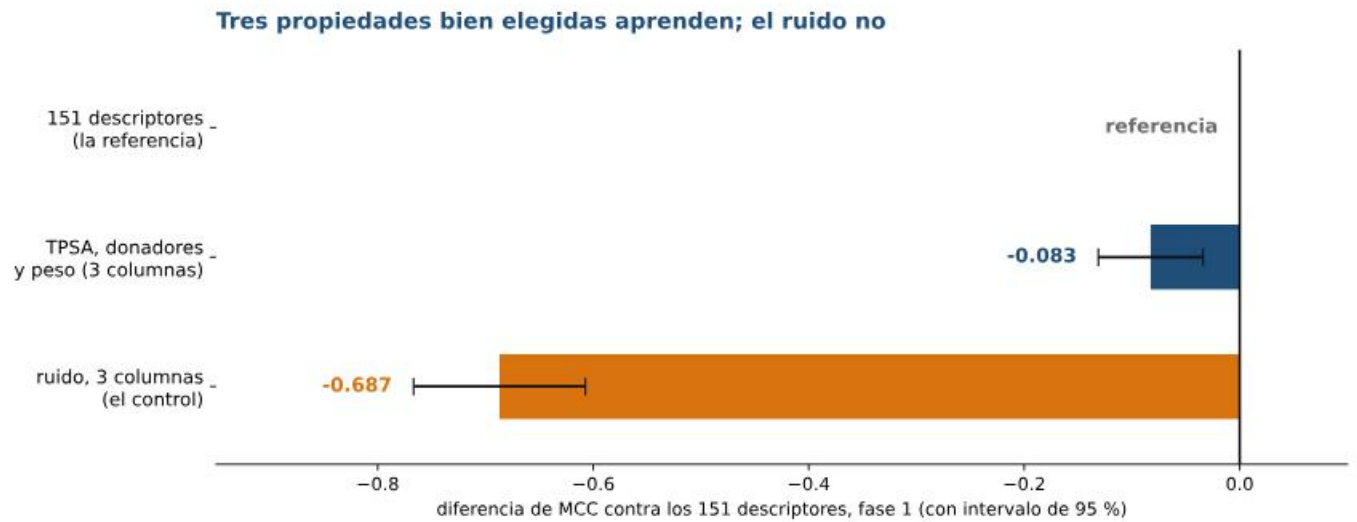


Dianas con 500 pares o más (entre paréntesis, los pares). Cada celda es la media de |SHAP| de esa columna en los pares de esa diana; el color da la dirección.
Son 56,241 pares, cada uno explicado por el modelo que no lo vio. Lo que el modelo aprendió, no un mecanismo.

- **La diana pone el punto de partida.** Entre las 16 dianas con 500 pares o más, ser LRRK2 sube la potencia predicha unas 0.7 unidades de pActividad y ser MAOA la baja unas 0.8. Las columnas de diana son el 15% de la atribución.
- **La química que pesa es casi la misma en todas.** El orden de las columnas coincide entre dianas (Spearman mediano 0.94, mínimo 0.90): complejidad, halógenos, huella y lipofilia.
- **Lo que distingue a una diana pesa poco** (0.03 a 0.06 contra 0.11 a 0.34 de la complejidad): hidrazonas en MAOA, sulfonamidas en PTGS2, cetonas en BCHE. **Solo SHAP: la permutación no las confirma** (puestos 57 a 108 en la permutación). Es lo que aprendió el modelo, no un mecanismo.

Tecnológico de Monterrey | Posgrados

Una herramienta para medir columnas nuevas



- Una tabla de **columnas propias** se compara contra los descriptores con la **misma validación agrupada** y contra un **control de ruido**.
- Ejemplo: tres propiedades de la literatura quedan **unos 0.08 de MCC** por debajo de los 151 descriptores, y el ruido casi 0.69. Aprenden, pero no igualan.
- **Dónde está:** el módulo `src/models/representaciones.py` del repositorio, con su guía en el sitio (*Entrega final*, «Medir una representación nueva»). Es Python, no una interfaz.

Tecnológico de Monterrey | Posgrados

Cómo leer las métricas

Métrica	Qué dice, en una frase	El azar da
MCC	acierto en las dos clases a la vez; exige un corte (aquí 0.5)	0
AUROC	la probabilidad de poner a un permeable por encima de uno que no lo es, sin fijar un corte	0.5
AUPRC	qué tan limpia es la lista al ir recuperando la clase minoritaria; se lee contra su proporción	la proporción de la minoritaria (0.35 en el ajuste de la fase 1)
Concordancia (fase 2)	de dos pares con potencias distintas, qué fracción ordena bien al más potente	0.5
Enriquecimiento	cuántas veces más activos hay en el 1% mejor ordenado que en el total	1

Tecnológico de Monterrey | Posgrados

Ejemplo: seis compuestos conocidos



Seis compuestos que los modelos no habían visto, elegidos al azar entre los que tienen nombre y potencia medida. Son un ejemplo del formato, no candidatos ni una medida de desempeño.
Rombo: la mayor potencia medida. En naranja, se parece poco a lo que el modelo conoce. Cada fase se ordena por separado.

- Seis compuestos que los modelos **no habían visto**, elegidos al azar entre los que tienen nombre y potencia medida.
- A la izquierda, la probabilidad de cruzar la barrera junto a lo que se sabe; a la derecha, la potencia predicha (barra) y la medida (rombo).
- **Lo que enseña:** la leflunomida sale con 0.93 y **no cruza**; y la diana de mayor potencia predicha no coincide con la medida en ninguno de los seis.
- Es un ejemplo del formato, no una lista de candidatos ni una medida de desempeño.