Tecnológico de Monterrey

Bioactive

Resumen ejecutivo: priorizar compuestos naturales con potencial neuroprotector

Integrantes: Ingrid Pamela Ruiz Puga, Artemio Santiago Padilla Robles, José Antonio Vázquez Martínez
Programa: Proyecto Integrador · Maestría en Inteligencia Artificial Aplicada
Asesora: Dra. Grettel Barceló Alonso Patrocinadora: Dra. Mariana Martínez Ávila Fecha: 15 de noviembre de 2026

Un compuesto natural que se considera para una terapia neuroprotectora tiene que cumplir dos condiciones antes de justificar un ensayo: llegar al cerebro, cruzando la barrera hematoencefálica, y actuar sobre una diana, la proteína a la que se une. Confirmarlas una por una cuesta tiempo y dinero, y la lista de candidatos es larga. Construimos dos modelos que ordenan los compuestos a partir de su estructura, con datos públicos (Meng et al., 2021; Zdrazil et al., 2024; Zhao et al., 2023): uno estima la probabilidad de que el compuesto cruce la barrera y otro la potencia con que actúa sobre 26 dianas del sistema nervioso. Los dos dan evidencia para decidir en qué orden confirmar, no una decisión automática: un compuesto que el modelo juzga poco probable de cruzar sigue siendo un candidato, porque esa predicción se equivoca.

0.793
AUROC
orden, prueba reservada

85 %
Conservados
permeables, al ensayar el 70 %

0.339
MCC
corte 0.5; 0.410 ajustado

0.720
Concordancia
potencia, fase 2

Con 1,499 compuestos reservados que ningún modelo vio, el modelo ordena bien: ante un permeable y un no permeable, le da mayor probabilidad al permeable el 79 % de las veces. Con la regla habitual, que declara permeable todo lo que pasa de 0.5, el coeficiente de Matthews (MCC, entre -1 y 1, donde 0 es el azar) es 0.339, lejos del 0.70 que se obtiene al validar con compuestos parecidos a los de entrenamiento. La causa es doble: esa regla declara permeable al 79 % de los compuestos cuando lo es el 57 %, y la química nueva es más difícil. Ajustar la proporción declarada a la esperada sube el MCC a 0.410. Para producción alcanza para ordenar y priorizar, no para descartar.

−30 %
Ensayos de confirmación
% de reducción/mes (supuesto de operación)

−15
Ensayos al mes
ensayos/mes, con 50 compuestos al mes (supuesto)

−$5,250
Costos de ensayo
MXN/mes, a $350 por ensayo (supuesto)

15 %
Permeables que se pierden
riesgo medido: 100 % menos 85 % conservado

Cálculo, escenarios y supuestos en el Anexo A.

Lo medido es el intercambio: ensayar solo el 70 % mejor ordenado evita el 30 % de los ensayos y aun así conserva el 85 % de los permeables reales (intervalo del 95 %, de 84 a 87), contra el 70 % que conservaría un sorteo al azar. Lo supuesto es el volumen, 50 compuestos al mes, y el costo de un ensayo de confirmación, que no conocemos: tomamos 350 pesos como referencia de un servicio universitario (Ohio State University High Throughput Screening Core, 2026). El ahorro crece en proporción directa con ese costo, y por eso la recomendación depende de él.

Mejora en la toma de decisiones. Cada compuesto llega con su probabilidad, su potencia por diana y una advertencia de qué tan parecido es a lo conocido; quien decide sabe cuánto confiar.

Mejora en la calidad. Cada cifra tiene una corrida registrada y repetible, y se valida agrupando por estructura química y no al azar.

Facilidad del trabajo. El cuaderno ordena una lista de compuestos propios en minutos, sin infraestructura que mantener.

Innovación. Una herramienta para medir si columnas propias, como datos ómicos, predicen mejor que las actuales.

El costo total de propiedad de los primeros 12 meses es de $173,340 MXN. De ellos, $121,500 son el desarrollo, que ya se realizó y se valora a la tarifa de un perfil junior ($202.50 por hora, de un sueldo de $24,000 al mes, dentro del rango de $18,000 a $30,000 que reportan las guías salariales (KeepCoding, 2026)); lo que habría que financiar de aquí en adelante es la implementación y la operación, $51,840, unos $4,320 al mes. No hay gasto de nube ni de licencias: el cuaderno corre en un equipo local y los datos de NPASS son de uso no comercial.

$121,500	**$16,200**	**$35,640**	**$173,340**
Desarrollo	Implementación	Operación	TCO 12 meses
600 h, ya realizado	80 h	176 h en 12 meses	MXN

Recomendamos adoptarlo como apoyo a la priorización y no como filtro de descarte, con una condición de arranque: apartar al azar 10 de cada 100 compuestos aunque queden mal ordenados y ensayarlos también, para medir con datos propios cuántos permeables se pierden. La inversión se compensa si cada ensayo de confirmación cuesta más de unos $290 con 50 compuestos al mes, sin contar el desarrollo, o unos $960 contándolo (Anexo B); con un ensayo más barato o menos volumen, no conviene.

Riesgo	**Mitigación**
Química distinta de la entrenada: el AUROC cae de 0.919 a 0.793 entre validación y prueba.	Advertencia de similitud en cada compuesto y reevaluación con cada lote nuevo.
El corte de 0.5 declara permeable al 79 % cuando lo es el 57 %.	Entregar probabilidades y ajustar la proporción declarada a la del lote.
Etiquetas y datos: el corte de actividad de 10 µM viene del cribado heredado, y NPASS es de uso no comercial.	Guardar el intervalo de potencia y no la etiqueta; declarar el uso no comercial.
Continuidad: depende de que alguien lo mantenga y reentrene.	Procedimiento documentado, dependencias fijadas y huella criptográfica de datos y modelos.

Transferencia y continuidad

Se transfieren un cuaderno que recibe estructuras propias y devuelve, por compuesto, la probabilidad de cruzar la barrera, la potencia por diana y qué tan cerca queda de lo conocido; los

dos modelos guardados (unos 3 MB) con un módulo de inferencia que no necesita los datos de entrenamiento; un procedimiento para reentrenar con datos nuevos; y una guía con la herramienta para medir columnas propias. La operación queda a cargo de la patrocinadora, con una revisión mensual de la advertencia de similitud y una reevaluación cuando lleguen compuestos con resultado de ensayo; el equipo acompaña la implementación.

Declaración de uso de inteligencia artificial

Se utilizó Anthropic (2026) con los modelos Claude Opus 5 y Claude Sonnet 5.5, y Claude Sonnet 5 cuando las restricciones de seguridad del modelo en temas de biología y química impidieron usar el 5.5, para redactar y dar formato a este resumen, calcular las cifras de los anexos y escribir el código de las mediciones en que se apoya. Los supuestos, la interpretación de los resultados y las recomendaciones son del equipo, que contrastó cada cifra con su corrida. La responsabilidad final sobre el contenido entregado recae en los autores.

Referencias

Anthropic. (2026). Claude Code [Agente de programación]. https://claude.com/claude-code

Calibre Scientific. (2026). PAMPA-BBB kit BAS-PMBBB-096, 96 pruebas. Consultado el 11 de noviembre de 2026, desde https://us.calibrescientific.com/en/product/BAS-PMBBB-096

KeepCoding. (2026). ¿Cuánto gana un Data Scientist en México? Guía salarial actualizada. Consultado el 11 de noviembre de 2026, desde https://keepcoding.io/blog/cuanto-gana-un-data-scientist-en-mexico/

Meng, F., Xi, Y., Huang, J., & Ayers, P. W. (2021). A curated diverse molecular database of blood-brain barrier permeability with chemical descriptors. *Scientific Data*, *8*(1), 289. https://doi.org/10.1038/s41597-021-01069-5

Ohio State University High Throughput Screening Core. (2026). Cost structure. Consultado el 11 de noviembre de 2026, desde https://u.osu.edu/highthroughputscreeningcore/cost-structure

Texas Tech University Health Sciences Center. (2025). WTPC cost sheet 2025. Consultado el 11 de noviembre de 2026, desde https://cancer.ttuhsc.edu/documents/WTPC_Cost_Sheet_2025.pdf

Zdrazil, B., Felix, E., Hunter, F., Manners, E. J., Blackshaw, J., Corbett, S., de Veij, M., Ioannidis, H., Lopez, D. M., Mosquera, J. F., Magarinos, M. P., Bosc, N., Arcila, R., Kizilören, T., Gaulton, A., Bento, A. P., Adasme, M. F., Monecke, P., Landrum, G. A., & Leach, A. R. (2024). The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Research*, *52*(D1), D1180-D1192. https://doi.org/10.1093/nar/gkad1004

Zhao, H., Yang, Y., Wang, S., Yang, X., Zhou, K., Xu, C., Zhang, X., Fan, J., Hou, D., Li, X., Lin, H., Tan, Y., Wang, S., Chu, X.-Y., Zhuoma, D., Zhang, F., Ju, D., Zeng, X., & Chen, Y. Z. (2023). NPASS database update 2023: quantitative natural product activity and species source database for biomedical research. *Nucleic Acids Research*, *51*(D1), D621-D628. https://doi.org/10.1093/nar/gkac1069

Anexo A. Beneficios: supuestos, escenarios y lo medido

Lo medido. Con las probabilidades que el modelo final dio a los 1,499 compuestos de la prueba reservada, ordenamos de mayor a menor probabilidad de cruzar la barrera y simulamos ensayar solo los mejor ordenados. La Tabla 1 da, para cada fracción ensayada, qué parte de los permeables reales queda dentro (con intervalo del 95 % que remuestrea grupos de andamio) y qué tan seguido acierta lo ensayado, contra una prevalencia de 57.3 %.

Tabla 1: Ensayar solo la fracción mejor ordenada: ensayos que se evitan, permeables que se conservan y aciertos entre lo ensayado.

Fracción ensayada	Ensayos evitados	Permeables conservados	IC95 %	Acierto entre lo ensayado
40 %	60 %	58.8 %	56.3 a 61.1	84.2 %
50 %	50 %	70.9 %	68.5 a 73.1	81.2 %
60 %	40 %	77.5 %	75.4 a 79.9	74.1 %
70 %	30 %	85.3 %	83.5 a 87.5	69.9 %
80 %	20 %	91.6 %	89.7 a 93.5	65.6 %
90 %	10 %	96.5 %	95.3 a 97.7	61.5 %

Los supuestos. Volumen de 50 compuestos considerados al mes. Fracción ensayada de 70 % (30 % de ensayos evitados). Costo de un ensayo de confirmación en tres escenarios, a 17.5 pesos por dólar: *bajo*, \$90 (unos 5 USD por pozo de reactivos de un ensayo de membrana artificial (Calibre Scientific, 2026)); *medio*, \$350 (unos 20 USD, un ensayo en un servicio universitario con curva de dosis, de 1 a 2.5 USD por pozo (Ohio State University High Throughput Screening Core, 2026)); *alto*, \$35,000 (unos 2,000 USD por compuesto en un ensayo ADME de servicio (Texas Tech University Health Sciences Center, 2025)). Son tres puntos de referencia de laboratorios universitarios y no precios de la patrocinadora, que debe confirmar.

Tabla 2: Ahorro mensual de ensayos con 50 compuestos al mes y 30 % de ensayos evitados (15 ensayos).

Escenario de costo por ensayo	Costo (MXN)	Ahorro (MXN/mes)
Bajo (reactivos de membrana artificial)	90	1,350
Medio (servicio universitario)	350	5,250
Alto (ensayo ADME de servicio)	35,000	525,000

El escenario alto es un techo de referencia y no una expectativa: supone que cada ensayo evitado cuesta lo que un ensayo ADME completo. Los beneficios intangibles no se cuantifican.

Anexo B. Costo total de propiedad a 12 meses, por servicio

Todas las horas son supuestos del equipo, a confirmar. La tarifa es \$24,000 al mes por 1.35 de cargas, entre 160 horas, es decir \$202.50 por hora.

Punto de equilibrio. El costo que debe tener un ensayo para que el ahorro compense el gasto es el gasto mensual entre los ensayos evitados al mes (30 % del volumen). La Tabla 4 lo da para varios volúmenes, sin contar el desarrollo (51,840/12 = \$4,320 al mes) y contándolo (173,340/12 = \$14,445 al mes).

Tabla 3: TCO de los primeros 12 meses, por servicio (MXN).

Fase	Servicio	Horas	Costo (MXN)
Desarrollo	Ciencia de datos: modelos y evaluación	400	81,000
	Ingeniería: código, pruebas y herramienta	140	28,350
	Documentación	60	12,150
Implementación	Instalación y entrega del cuaderno	32	6,480
	Capacitación	24	4,860
	Validación con datos propios	24	4,860
Operación (12 meses)	Revisión mensual, 8 h por mes	96	19,440
	Reentrenamiento, dos veces al año	80	16,200
	Nube, cómputo y licencias	—	0
Total		**856**	**173,340**

Tabla 4: Costo mínimo por ensayo (MXN) para que el ahorro compense el gasto, según el volumen mensual.

Compuestos al mes	Ensayos evitados al mes	Sin desarrollo	Con desarrollo
20	6	720	2,408
50	15	288	963
100	30	144	482
200	60	72	241